



# โครงการ การเรียนการสอนเพื่อเสริมประสบการณ์

ชื่อโครงการ      วิธีแนะนำทางสังคมบนพื้นฐานของกราฟแบบถ่วงน้ำหนัก  
Social Recommendation Based on Weighted Graph

ชื่อนิสิต      นายปฐมพงษ์ เมืองทอง      613 373 9423

ภาควิชา      คณิตศาสตร์และวิทยาการคอมพิวเตอร์  
สาขาวิชา วิทยาการคอมพิวเตอร์

ปีการศึกษา      2564

คณะวิทยาศาสตร์ จุฬาลงกรณ์มหาวิทยาลัย

## วิธีแนะนำทางสังคมบนพื้นฐานของกราฟแบบตัวหนังสือ

นายปฐมพงษ์ เมืองทอง

โครงงานนี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรวิทยาศาสตร์บัณฑิต  
สาขาวิชาการคอมพิวเตอร์ ภาควิชาคณิตศาสตร์และวิทยาการคอมพิวเตอร์  
คณะวิทยาศาสตร์ จุฬาลงกรณ์มหาวิทยาลัย  
ปีการศึกษา 2564  
ลิขสิทธิ์ของจุฬาลงกรณ์มหาวิทยาลัย

# Social Recommendation Based on Weighted Graph

Pathompong Muangthong

A Project Submitted in Partial Fulfillment of the Requirements  
for the Degree of Bachelor of Science Program in Computer Science  
Department of Mathematics and Computer Science  
Faculty of Science  
Chulalongkorn University  
Academic Year 2021  
Copyright of Chulalongkorn University

หัวข้อโครงการ

วิธีแนะนำทางสังคมนปั้นฐานของกราฟแบบต่อเนื่องน้ำหนัก

โดย

นาย ปฐมพงษ์ เมืองทอง

สาขาวิชา

วิทยาการคอมพิวเตอร์

อาจารย์ที่ปรึกษาโครงการหลัก

รองศาสตราจารย์.ดร. ศรันญา มณีโรจน์

ภาควิชาคณิตศาสตร์และวิทยาการคอมพิวเตอร์ คณะวิทยาศาสตร์ จุฬาลงกรณ์มหาวิทยาลัย อนุมัติให้นับโครงการฉบับนี้เป็นส่วนหนึ่ง ของการศึกษาตามหลักสูตรปริญญาบัณฑิต ในรายวิชา 2301499 โครงการวิทยาศาสตร์ (Senior Project)

หัวหน้าภาควิชาคณิตศาสตร์

(รองศาสตราจารย์ ดร. รตินันท์ บุญเคลือบ)

และวิทยาการคอมพิวเตอร์

คณะกรรมการสอบโครงการ

อาจารย์ที่ปรึกษาโครงการหลัก

(รองศาสตราจารย์.ดร. ศรันญา มณีโรจน์)

กรรมการ

(ผู้ช่วยศาสตราจารย์ ดร. อาร์ เหี้อิงสตดไฮ)

กรรมการ

(อาจารย์ ดร. นฤมล ประทานวนิช)

ปฐมพงษ์ เมืองทอง: วิธีแนะนำทางสังคมบนพื้นฐานของกราฟแบบถ่วงน้ำหนัก. (Social Recommendation Based on Weighted Graph) อ.ที่ปรึกษาโครงการหลัก : รองศาสตราจารย์ ดร. ศรีวนิษฐ์ มณีโรจน์, 74 หน้า.

โครงการเรื่อง “วิธีแนะนำทางสังคมบนพื้นฐานของกราฟแบบถ่วงน้ำหนัก” จัดทำขึ้นโดยมีจุดประสงค์ในการพัฒนาวิธีแนะนำทางสังคมโดยใช้พื้นฐานของกราฟแบบถ่วงน้ำหนักจากแหล่งข้อมูลสองแหล่งได้แก่ 1. แหล่งข้อมูลจากการอภิชิพลที่มีความสัมพันธ์ระหว่างผู้ใช้และผู้ใช้ และแทนค่าน้ำหนักบนเส้นความสัมพันธ์ระหว่างผู้ใช้และผู้ใช้ด้วยค่าของระดับของความอิทธิพลที่ส่งผลจากผู้ใช้หนึ่งไปยังอีกผู้ใช้หนึ่ง ซึ่งได้จากการเปรียบเทียบค่าน้ำหนักระหว่างผู้ใช้สองคน โดยค่าน้ำหนักของผู้ใช้จะคำนวณได้จากการเปรียบเทียบอัตราส่วนระหว่างจำนวนเส้นเชื่อมทั้งหมดของผู้ใช้ และจำนวนเส้นเชื่อมทั้งหมดของเพื่อนบ้านของผู้ใช้ทุกคน 2. แหล่งข้อมูลจากการสนับนิยมที่มีความสัมพันธ์ระหว่างผู้ใช้และการ ราย การ และแทนค่าน้ำหนักบนเส้นความสัมพันธ์ระหว่างผู้ใช้และการด้วยค่าที่แสดงถึงระดับของความน่าสนใจที่รายการมีต่อผู้ใช้ ซึ่งได้จากการเปรียบเทียบอัตราส่วนกันระหว่างคะแนนที่ผู้ใช้ให้แก่รายการนั้นๆ และผลรวมของคะแนนทั้งหมดที่ผู้ใช้ได้ให้แก่รายการทุกรายการ และมีขอบเขตของโครงการโดยจะทำการเปรียบเทียบการประเมินผลการทดลองกับวิธีการ A Neural Influence and Interest Diffusion Network for Social Recommendation (DiffNet++) บนคลังข้อมูลของ Yelp เท่านั้น โดยมีจำนวนผู้ใช้ไม่ต่ำกว่า 5,000 ผู้ใช้ และจำนวนรายการไม่ต่ำกว่า 40,000 รายการ วิธีการวัดผลการประเมินผลการทดลองจะทำโดยใช้วิธี Hit Ratio และ Normalized Discounted Cumulative Gain จากผลการประเมินแสดงให้เห็นว่าวิธีแนะนำทางสังคมโดยใช้กราฟแบบถ่วงน้ำหนักนั้นช่วยเพิ่มประสิทธิภาพขึ้นได้

ภาควิชา คณิตศาสตร์และวิทยาการคอมพิวเตอร์ ลายมือชื่อนิสิต ..... **ปฐมพงษ์**

สาขาวิชา วิทยาการคอมพิวเตอร์ ลายมือชื่อ อ.ที่ปรึกษาโครงการหลัก ..... **ดร.วนิษฐ์ มณีโรจน์**

ปีการศึกษา 2564

# # 6133739423: MAJOR COMPUTER SCIENCE

KEYWORDS : RECOMMENDER SYSTEM / GRAPH NEURAL NETWORK / SOCIAL RECOMMENDATION / WEIGHTED GRAPH

Pathompong Muangthong: Social Recommendation Based on Weighted Graph.

ADVISOR: ASSOC. PROF. Saranya Maneeroj, Ph.D., 74 pp.

The project “Social Recommendation Based on Weighted Graph” was conducted with the aim of developing a social recommendation method by using the weighted graph from two data sources: 1. Data source from user influence graph which contains the relationship between each user by replacing the weight on the user-user relationship with the value that represents the level of influence affecting one user to another which calculated by comparing the user’s weight values between two users. The user’s weight is calculated by comparing the ratio between the total number of connections of the user and the total number of connections of every user’s neighbors. 2. Data source from user interest graph which contains the relationship between user and item by replacing the weight on the user-item relationship with the value that represents the level of interest the item has to the user, which is calculated by comparing the ratios between the rating that user given to particular item and the sum of all ratings that user has given to every interacted item. The scope of the project is to compare the experimental evaluation with the “A Neural Influence and Interest Diffusion Network for Social Recommendation” or DiffNet++ method on the Yelp dataset only, with a minimum of 5,000 users and a minimum of 40,000 items. The experimental evaluation method was measured using the Hit Ratio and Normalized Discounted Cumulative Gain method. The experimental results on a real-world dataset show that the social recommendation based on weighted graph can improve the effectiveness.

Department : Mathematics and Computer Science Student’s Signature 

Field of Study : Computer Science Advisor’s Signature 

Academic Year : 2021

## กิตติกรรมประกาศ

ในการดำเนินโครงการรายวิชา 2301499 Senior Project สามารถทำให้สำเร็จลุล่วงได้ด้วยการช่วยเหลือ และการได้รับความอนุเคราะห์จากคณาจารย์ และบุคลากรต่างๆ เป็นอย่างดี จึงขอขอบพระคุณไว้ ณ โอกาสนี้

ขอขอบพระคุณรองศาสตราจารย์ ดร.ศรันญา มณีโรจน์ อาจารย์ที่ปรึกษาโครงการ ที่ได้กรุณาให้คำปรึกษา คำแนะนำ รวมถึงการให้กำลังใจมาโดยตลอดระยะเวลาการทำโครงการตั้งแต่วันแรกจนกระทั่งโครงการได้สำเร็จลุล่วงไปด้วยดี

ขอขอบพระคุณคณะกรรมการสอบทั้ง 2 ท่าน ผู้ช่วยศาสตราจารย์ ดร.อาทรส เหลืองสดใส และอาจารย์ ดร.นฤมล ประทานวนิช ที่ได้ให้คำแนะนำ และข้อเสนอแนะ ทำให้เกิดแนวทางในการพัฒนาโครงการให้มีความสมบูรณ์มากยิ่งขึ้น

ขอขอบพระคุณคุณพ่อ และคุณแม่ที่ได้ให้การสนับสนุน และให้กำลังใจมาโดยตลอดระยะเวลาที่ทำโครงการนี้ และตลอดระยะเวลาในการดำเนินชีวิตต่างๆ ทำให้หลายสิ่งหลายอย่างสามารถดำเนินไปได้อย่างราบรื่น

ขอขอบพระคุณอาจารย์ทุกๆ ท่านที่ได้ประสิทธิ์วิชาความรู้ และให้คำแนะนำในหลายๆ เรื่องมาโดยตลอดที่ได้ใช้ชีวิตในรั้วมหาลัย

ขอขอบพระคุณเพื่อนๆ ภาควิชาคณิตศาสตร์ และวิทยาการคอมพิวเตอร์ สาขาวิชาการคอมพิวเตอร์ที่ได้ช่วยเหลือในด้านของความรู้ และความเข้าใจในเนื้อหาที่จำเป็นในการใช้เพื่อพัฒนาโครงการนี้

ท้ายที่สุดนี้ขอขอบคุณทุกความกรุณาอันดียิ่งจากทุกท่านที่ได้กล่าวมาข้างต้น รวมถึงบุคคลท่านอื่นที่อาจไม่ได้เอียนามไว้ ณ ที่นี้อีกครั้งหนึ่ง สำหรับความช่วยเหลือและคำแนะนำ สร่งผลให้โครงการนี้สำเร็จลุล่วงด้วยดี

## สารบัญ

### หน้า

บทคัดย่อภาษาไทย .....	๑
บทคัดย่อภาษาอังกฤษ .....	๑
กิตติกรรมประกาศ .....	๙
สารบัญ .....	๑๒
สารบัญตาราง .....	๑๓
<b>บทที่ 1 บทนำ .....</b>	<b>๑</b>
1.1 หลักการและเหตุผล .....	๑
1.2 วัตถุประสงค์ .....	๕
1.3 ขอบเขตของโครงการ .....	๖
1.4 วิธีการดำเนินงาน .....	๖
1.5 ประโยชน์ที่คาดว่าจะได้รับ .....	๗
1.6 โครงสร้างของรายงาน .....	๗
<b>บทที่ 2 ความรู้ และงานวิจัยที่เกี่ยวข้อง .....</b>	<b>๘</b>
2.1 Recommendation System .....	๘
2.1.1 Content-based Filtering .....	๘
2.1.2 Collaborative Filtering (CF) .....	๙
2.2 Social Recommendation .....	๑๒
2.3 Graph-based Recommendation .....	๑๒
2.3.1 Graph Neural Network (GNN) .....	๑๓
2.3.2 Graph Convolutional Networks (GCN) .....	๑๕
2.3.3 Personal Recommendation using Weighted Bipartite Graph Projection .....	๑๖
2.3.4 A Neural Influence and Interest Diffusion Network for Social Recommendation ....	๑๗
<b>บทที่ 3 วิธีการทดลอง .....</b>	<b>๒๘</b>

3.1 การเก็บรวบรวมข้อมูล.....	28
3.2 การประมวลผลข้อมูลล่วงหน้า (Data Preprocessing).....	29
3.2.1 การเตรียมข้อมูลและทำความสะอาดข้อมูล (Data Cleansing) .....	29
3.2.2 การสร้างเวกเตอร์คุณสมบัติของผู้ใช้และการ (Users and Items Feature Vector) .....	30
3.3 วิธีการที่นำเสนอ.....	33
3.3.1 Embedding Layer .....	33
3.3.2 Fusion Layer .....	33
3.3.3 Influence and Interest Diffusion Layers .....	35
3.3.4 Prediction Layer.....	41
<b>บทที่ 4 การประเมินผลการทดลอง .....</b>	<b>42</b>
4.1 คลังข้อมูลที่ใช้.....	42
4.2 วิธีการพื้นฐาน และวิธีการประเมินผล .....	44
4.2.1 Hit Ratio (HR) .....	44
4.2.2 Normalized Discounted Cumulative Gain (NDCG) .....	44
4.3 การตั้งค่าพารามิเตอร์.....	45
4.4 ผลการประเมินผล .....	45
<b>บทที่ 5 ข้อสรุปและข้อเสนอแนะ .....</b>	<b>46</b>
5.1 ข้อสรุป.....	46
5.2 ปัญหาและอุปสรรค .....	46
5.3 แนวทางการแก้ไขปัญหา .....	47
5.4 ข้อเสนอแนะ .....	47
<b>รายการอ้างอิง .....</b>	<b>48</b>
<b>ภาคผนวก ก แบบเสนอหัวข้อโครงการ รายวิชา 2301399 Project Proposal ปีการศึกษา 2564 .....</b>	<b>50</b>
<b>ภาคผนวก ข ตารางแสดงผลการประเมินในแต่ละรอบของการทดสอบ.....</b>	<b>59</b>
<b>ประวัติผู้เขียน.....</b>	<b>63</b>

## สารบัญภาพ

หน้า

ภาพที่ 1.1	แสดงถึงปฏิสัมพันธ์ระหว่างผู้ใช้ต่อประเภทของหนังในรูปแบบของเมทริกซ์ โดยผู้ใช้ที่ให้คะแนนคล้ายกันในประเภทหนังเดียวกันจะมีรสนิยมที่คล้ายกัน จึงทำการแนะนำประเภทหนังที่ไม่เคยดูให้แก่ผู้ใช้ที่คล้ายกันที่ไม่เคยดูหนังประเภทนั้นมาก่อน .....	1
ภาพที่ 1.2	กราฟโซเชียลเน็ตเวิร์ค (Social Network) ที่ผู้ใช้และรายการต่อ กันจนเป็นเครือข่ายขนาดใหญ่ และมีหลายระดับ .....	2
ภาพที่ 1.3	กราฟแสดงความสัมพันธ์ระหว่างผู้ใช้ U1 และผู้ใช้ U2 และ U3 โดยผู้ใช้ U1 ได้รับอิทธิพลจากผู้ใช้ U4 ผ่านผู้ใช้ U2 และ U3 .....	3
ภาพที่ 1.4	ผู้ใช้ U1 เป็นเพื่อนกับผู้ใช้ U2 และ U3 แต่มีรสนิยมที่คล้ายกับ U2 มากกว่า จึงมีแนวโน้มที่จะมีพฤติกรรมตาม U2 มากกว่า U3.....	4
ภาพที่ 1.5	ผู้ใช้ U1 เป็นเพื่อนกับ U2 และ U3 โดยที่ U1 และ U2 ชอบใช้สินค้า V1 และ U2 กับ U3 ชอบใช้สินค้า V2 ดังนั้นสินค้า V1 และ V2 จึงมีความคล้ายกัน .....	5
ภาพที่ 2.1	แสดงภาพรวมหลักการทำงานของวิธี Content-based Filtering .....	8
ภาพที่ 2.2	แสดงตัวอย่างของลักษณะเมทริกซ์ระหว่างรายการกับลักษณะของรายการ และเมทริกซ์ระหว่างผู้ใช้กับลักษณะของรายการที่ผู้ใช้มีปฏิสัมพันธ์ด้วย .....	8
ภาพที่ 2.3	แสดงตัวอย่างตารางผลตอบรับ หรือตารางคะแนนที่ผู้ใช้ให้การเรียก .....	10
ภาพที่ 2.4	แสดงการทำนายรายการที่คาดว่าผู้ใช้จะมีปฏิสัมพันธ์ด้วย โดยการดูการแยกตัวประกอบเมทริกซ์ .....	10
ภาพที่ 2.5	แสดงตารางผลตอบรับในรูปของเมทริกซ์ระหว่างผู้ใช้และรายการ .....	11
ภาพที่ 2.6	แสดงตัวอย่างลักษณะกราฟบนโซเชียลเน็ตเวิร์คระหว่างผู้ใช้และผู้ใช้ .....	12
ภาพที่ 2.7	แสดงกราฟแสดงความสัมพันธ์ระหว่างผู้ใช้และผู้ใช้บนแพลตฟอร์มโซเชียลมีเดีย .....	13
ภาพที่ 2.8	แสดงตัวอย่างวิธีการสร้างรูปแทนของหนอด (สีทีบ) โดยการรวมกันของรูปแทนของหนอดตัวเอง และรูปแทนจากหนอดเพื่อบ้านที่มีเส้นเชื่อมกัน .....	14
ภาพที่ 2.9	แสดงตัวอย่างลักษณะของรูปแทนในระดับหนอด .....	14
ภาพที่ 2.10	แสดงตัวอย่างลักษณะของรูปแทนในระดับกราฟ .....	15

ภาพที่ 2.11 แสดงตัวอย่างของการสร้างรูปแทนที่ 1 ระดับชั้น (ก) และที่ 2 ระดับชั้น (ข).....	16
ภาพที่ 2.12 แสดงหลักการทำงานของการจัดสรรทรัพยากรบนกราฟสองส่วนระหว่างผู้ใช้และรายการ .....	16
ภาพที่ 2.13 แสดงการใช้ข้อมูลที่มาจากการส่องเหล่เพื่อช่วยในการพัฒนาระบบแนะนำของ DiffNet++ .....	17
ภาพที่ 2.14 แสดงภาพรวมของโครงสร้างการทำงานทั้งหมดของวิธีการ DiffNet++ .....	18
ภาพที่ 2.15 แสดงการภาพรวมการทำงานในเลเยอร์ Embedding.....	18
ภาพที่ 2.16 แสดงภาพรวมการทำงานของเลเยอร์ Fusion .....	19
ภาพที่ 2.17 แสดงภาพรวมของเลเยอร์ Influence and Interest Diffusion ของ DiffNet++ .....	21
ภาพที่ 2.18 แสดงภาพรวมการทำงานในส่วนของกราฟสนับสนุนระหว่างผู้ใช้และรายการ.....	22
ภาพที่ 2.19 แสดงภาพรวมการทำงานในส่วนของกราฟอิทธิพลระหว่างผู้ใช้และรายการ .....	24
ภาพที่ 2.20 แสดงการภาพรวมการทำงานในเลเยอร์ Prediction .....	26
ภาพที่ 3.1 แสดงตัวอย่างคลังข้อมูลคำวิจารณ์ และคุณสมบัติต่างๆภายใน.....	29
ภาพที่ 3.2 แสดงตัวอย่างตารางความสัมพันธ์ระหว่างผู้ใช้และผู้ใช้ .....	29
ภาพที่ 3.3 แสดงตัวอย่างตารางความสัมพันธ์ระหว่างผู้ใช้และรายการ.....	30
ภาพที่ 3.4 แสดงตัวอย่างการสร้างรูปแทนของประโยชน์คำวิจารณ์ .....	31
ภาพที่ 3.5 แสดงตัวอย่างการสร้างรูปแทน หรือเวกเตอร์ลักษณะของผู้ใช้ .....	31
ภาพที่ 3.6 แสดงตัวอย่างรูปแทนของคำว่า ‘delicious’ .....	31
ภาพที่ 3.7 แสดงตัวอย่างของรูปแทนของแต่ละประโยชน์ .....	32
ภาพที่ 3.8 แสดงการทำ t-SNE Visualization ของคำว่า ‘Delicious’(บน) และคำว่า ‘Bad’ (ล่าง) .....	32
ภาพที่ 3.9 แสดงตัวอย่างลักษณะของโครงข่ายประชาทเทียมเชื่อมโยงสมบูรณ์ .....	35
ภาพที่ 4.1 แสดงตารางความสัมพันธ์ระหว่างผู้ใช้และผู้ใช้ (ซ้าย) และตารางความสัมพันธ์ระหว่างผู้ใช้และรายการ (ขวา) ที่มีการแปลงรหัสของผู้ใช้และรายการแล้ว .....	43

## สารบัญตาราง

หน้า

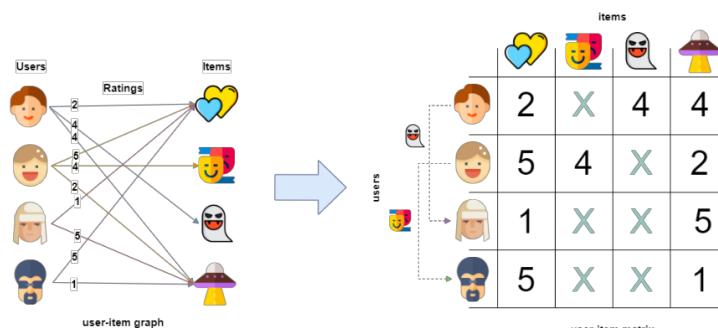
ตารางที่ 3.1	แสดงจำนวนของข้อมูลในแต่ละคลังข้อมูลที่ยังไม่ผ่านการประมวลผลล่วงหน้า .....	28
ตารางที่ 4.1	แสดงจำนวนของข้อมูลที่ผ่านการประมวลผลล่วงหน้าแล้ว .....	43
ตารางที่ 4.2	แสดงจำนวนของความสัมพันธ์ในคลังข้อมูลที่ผ่านการประมวลผลล่วงหน้าแล้ว .....	43
ตารางที่ 4.3	แสดงผลการประเมินผลเปรียบเทียบระหว่างวิธีการที่นำเสนอและวิธีการพื้นฐาน โดยมีค่า top-N ที่แตกต่างกัน ( $D=64$ ) บนคลังข้อมูลของ Yelp .....	45
ตารางที่ ข.1	แสดงผลการประเมินผล HR-Top5 เปรียบเทียบระหว่างวิธีการที่นำเสนอและวิธีการพื้นฐานในแต่ละรอบของการทดสอบ .....	59
ตารางที่ ข.2	แสดงผลการประเมินผล HR-Top10 เปรียบเทียบระหว่างวิธีการที่นำเสนอและวิธีการพื้นฐานในแต่ละรอบของการทดสอบ .....	59
ตารางที่ ข.3	แสดงผลการประเมินผล HR-Top15 เปรียบเทียบระหว่างวิธีการที่นำเสนอและวิธีการพื้นฐานในแต่ละรอบของการทดสอบ .....	60
ตารางที่ ข.4	แสดงผลการประเมินผล HR-Top30 เปรียบเทียบระหว่างวิธีการที่นำเสนอและวิธีการพื้นฐานในแต่ละรอบของการทดสอบ .....	60
ตารางที่ ข.5	แสดงผลการประเมินผล NDCG-Top5 เปรียบเทียบระหว่างวิธีการที่นำเสนอและวิธีการพื้นฐานในแต่ละรอบของการทดสอบ .....	61
ตารางที่ ข.6	แสดงผลการประเมินผล NDCG-Top10 เปรียบเทียบระหว่างวิธีการที่นำเสนอและวิธีการพื้นฐานในแต่ละรอบของการทดสอบ .....	61
ตารางที่ ข.7	แสดงผลการประเมินผล NDCG-Top15 เปรียบเทียบระหว่างวิธีการที่นำเสนอและวิธีการพื้นฐานในแต่ละรอบของการทดสอบ .....	62
ตารางที่ ข.8	แสดงผลการประเมินผล NDCG-Top30 เปรียบเทียบระหว่างวิธีการที่นำเสนอและวิธีการพื้นฐานในแต่ละรอบของการทดสอบ .....	62

## บทที่ 1

### บทนำ

#### 1.1 หลักการและเหตุผล

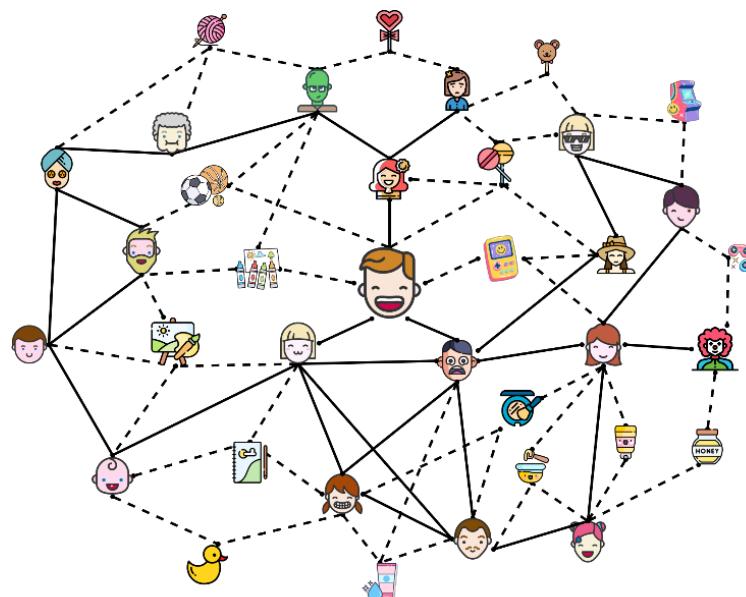
ในปัจจุบัน Recommender System ได้เข้ามามีบทบาทที่สำคัญบนแพลตฟอร์มโซเชียลต่างๆ โดยการแนะนำสินค้า หรือบริการต่างๆ เพื่อปรับปรุงและพัฒนาความพึงพอใจสูงสุดให้แก่ผู้ใช้บริการ เช่น ระบบแนะนำคลิปวิดีโอบน YouTube, ระบบแนะนำหนังบน Netflix หรือระบบแนะนำสินค้านอก online market เป็นต้น ดังนั้ntechnic Collaborative Filtering(CF) จึงได้ถูกนำมาใช้อย่างแพร่หลายในการเรียนรู้พัฒนาระบบ การใช้งานของผู้ใช้แต่ละคน โดย CF จะพิจารณาการแนะนำบนพื้นฐานของผู้ใช้ที่มีพฤติกรรมที่คล้ายกัน ก็จะมีแนวโน้มที่จะมีรสนิยมที่คล้ายกันด้วย กล่าวคือ CF จะนำความเห็นหรือปฏิสัมพันธ์ของผู้ใช้ที่รสนิยมคล้ายกันมาแนะนำให้กันและกัน ซึ่งจะทำการหาผู้ใช้ที่มีพฤติกรรมที่คล้ายกันโดยดูจากพฤติกรรมที่ต่างกัน หรือคล้ายกันในอดีต และทำการแนะนำรายการที่ผู้ใช้มีปฏิสัมพันธ์ที่ดีให้แก่ผู้ใช้ที่คล้ายกันแต่ยังไม่เคยมีปฏิสัมพันธ์ต่อรายการนั้นมาก่อน ตามภาพที่ 1.1 CF สามารถแบ่งได้เป็น 2 ประเภท ประเภทแรกคือ User-based CF คือการสนับสนุนของผู้ใช้ที่คล้ายกัน และทำการแนะนำรายการที่ชอบให้แก่กัน โดยจะพิจารณาว่าผู้ใช้ที่มีรสนิยมคล้ายกันจะมีพฤติกรรมความชอบที่คล้ายกันด้วย ประเภทที่สองคือ Item-based CF โดยจะพิจารณาจากลักษณะของการเป็นหลัก หากผู้ใช้ให้คะแนนรายการนั้นในระดับที่ดี ดังนั้นรายการที่เกี่ยวข้อง หรือคล้ายกับรายการนั้นรวมถึงได้คะแนนในระดับใกล้เคียงกันจากผู้ใช้อื่น จึงจะแนะนำรายการนั้นหากผู้ใช้เป้าหมายไม่เคยมีปฏิสัมพันธ์ต่อรายการนั้นมาก่อน โดย CF นั้นจำเป็นที่จะต้องใช้ข้อมูลพฤติกรรมของผู้ใช้ เช่น คะแนนของรายการต่างๆ ที่ผู้ใช้ได้ให้คะแนนมาเรียนรู้ แต่เนื่องจากการมีข้อมูลเหล่านี้อย่างจำกัด ส่งผลให้ CF มีปัญหาการกระจัดกระจายของข้อมูล จึงทำให้ประสิทธิภาพการแนะนำของ CF นั้นลดลง อย่างไรก็ตาม ได้มีงานวิจัยด้าน CF บางส่วนที่ได้มีการนำแหล่งข้อมูลอื่นมาใช้เพื่อลดปัญหานี้ หนึ่งในแหล่งข้อมูลที่เป็นที่นิยม คือแหล่งข้อมูลจากเครือข่ายโซเชียลเน็ตเวิร์ค โดยได้มีการใช้แหล่งข้อมูลนี้เพื่อมาปรับปรุง และพัฒนา CF ให้มีประสิทธิภาพที่ดีขึ้น



ภาพอักษรแบบโดยใช้แหล่งข้อมูลจาก Flaticon.com

ภาพที่ 1.1 แสดงถึงปฏิสัมพันธ์ระหว่างผู้ใช้ต่อประเภทของหนังในรูปแบบของเมทริกซ์ โดยผู้ใช้ที่ให้คะแนนคล้ายกันในประเภทหนังเดียวกันจะมีรสนิยมที่คล้ายกัน จึงทำการแนะนำประเภทหนังที่ไม่เคยดูให้แก่ผู้ใช้ที่คล้ายกันที่ไม่เคยดูหนังประเภทนั้นมาก่อน

โซเชียลเน็ตเวิร์ค หรือเครือข่ายทางสังคม ซึ่งประกอบไปด้วยโหนดต่างๆของผู้คน หรือรายการ ซึ่งแต่ละโหนดจะมีเส้นเชื่อมระหว่างโหนดหนึ่งไปอีกโหนดหนึ่งที่แสดงถึงความสัมพันธ์ระหว่างโหนดแต่ละโหนด เช่น โซเชียลเน็ตเวิร์คบนแพลตฟอร์มโซเชียลมีเดียที่ผู้ใช้และเพื่อนแต่ละคนจะเชื่อมโยงกันด้วยความสัมพันธ์ของความเป็นเพื่อน โซเชียลเน็ตเวิร์คสามารถแสดงเส้นเชื่อมความสัมพันธ์ที่ซับซ้อน และสามารถแสดงความสัมพันธ์ที่หลากหลายระดับได้ เช่น เพื่อนของเพื่อนเป็นต้น และแต่ละคนสามารถเชื่อมต่อกันจนเป็นเน็ตเวิร์คที่มีขนาดใหญ่ได้ ตามภาพที่ 1.2 ดังนั้นจะเห็นได้ว่าผู้ใช้นั้นมีบทบาทที่สำคัญต่อโซเชียลเน็ตเวิร์ค ใน การเป็นส่วนหนึ่งของการเชื่อมต่อเครือข่ายสังคมขนาดใหญ่ ซึ่งส่งผลให้สามารถแสดงถึงความสัมพันธ์ในหลาย ระดับได้ นอกจากนี้ในบางแพลตฟอร์มสามารถที่จะแสดงความสัมพันธ์ระหว่างผู้ใช้และรายการได้ เช่นบน แพลตฟอร์ม YouTube ที่ผู้ใช้แต่ละคนสามารถติดตามผู้ใช้คนอื่นๆได้ รวมถึงสามารถมีปฏิสัมพันธ์กับรายการ คลิปวิดีโอได้ ดังนั้นเครือข่ายโซเชียลสามารถมีได้ทั้งความสัมพันธ์ระหว่างผู้ใช้กับผู้ใช้ และผู้ใช้กับรายการได้ คล้ายกับ CF เช่นกัน เนื่องจาก CF นั้นพยายามที่จะแสดงความสัมพันธ์ทั้งสองแบบนี้ในรูปของเมทริกซ์ ด้วยเหตุ นี้จึงทำให้การอธิบายความสัมพันธ์ด้วยเมทริกซ์นั้นยังไม่ได้เท่าที่ควร จึงได้มีงานที่มีการนำความสามารถของ กราฟมาช่วยในการอธิบายความสัมพันธ์ที่หลายระดับนี้

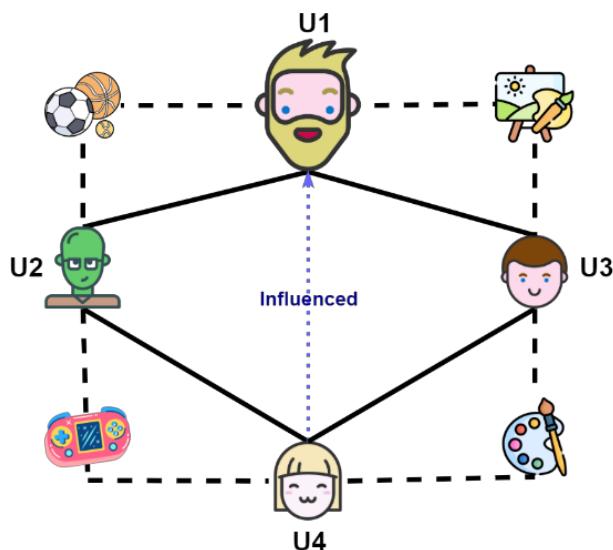


ภาพออกแบบโดยใช้แหล่งข้อมูลจาก Flaticon.com

ภาพที่ 1.1 กราฟโซเชียลเน็ตเวิร์ค (Social Network) ที่ผู้ใช้และการต่อ กันจนเป็นเครือข่ายขนาด ใหญ่ และมีหลายระดับ

การแสดงความสัมพันธ์ของผู้ใช้ต่อผู้ใช้ และผู้ใช้ต่อรายการจากความสัมพันธ์บนโซเชียลเน็ตเวิร์คโดย ใช้กราฟนั้นจะช่วยให้สามารถมองในระดับความสัมพันธ์อื่นๆได้ด้วย เนื่องจากกราฟสามารถมีการเชื่อมต่อ ความสัมพันธ์ได้หลายลำดับ ซึ่งจากการลดความสัมพันธ์หลายระดับในโซเชียลเน็ตเวิร์คเหลือเพียง ความสัมพันธ์ระหว่างคู่ผู้ใช้ที่คล้ายกันมากที่สุดแบบใน CF นั้นไม่สามารถที่จะแสดงถึงผลกระทบ หรืออิทธิพล ของความสัมพันธ์ในระดับอื่นๆซึ่งอาจจะส่งผลต่อพฤติกรรมของผู้ใช้ได้ เนื่องจากการสร้างเครือข่ายโดยมีผู้ใช้

แต่ละคนเป็นศูนย์กลางนั้นเริ่มจากการมีปฏิสัมพันธ์กับผู้ใช้เพื่อนบ้านลำดับแรก และเพื่อนบ้านก็จะขยายความสัมพันธ์ต่อไปอีกเรื่อยๆ ดังนั้นผู้ใช้แต่ละคนจากจากจะได้รับอิทธิพลทางพฤติกรรมจากผู้ใช้เพื่อนบ้านลำดับแรกแล้ว ยังได้รับอิทธิพลจากผู้ใช้ลำดับที่สูงกว่าด้วย เช่น ดังภาพที่ 1.3 หากผู้ใช้ U1 ชี้อินไซค์ตาม U2 และ U3 และ U2 กับ U3 ชี้อินไซค์ตาม U4 ดังนั้นจึงได้ว่าผู้ใช้ U1 นั้นได้รับอิทธิพลจากผู้ใช้ U4 เช่นกัน เนื่องจากมีความสัมพันธ์ลำดับที่สูงกว่าของ U1 ที่เข้มแข็ง U4 ดังนี้ U1 - U2 - U4 และ U1 - U3 - U4 จะเห็นได้ว่าถึงแม้ผู้ใช้จะไม่เคยมีปฏิสัมพันธ์กับผู้ใช้ในลำดับที่สูงกว่าก็ตาม แต่ก็ยังได้รับอิทธิพลต่อพฤติกรรมผ่านผู้ใช้ที่เป็นเพื่อนบ้านลำดับแรกด้วยเช่นกัน ดังนั้นการนำความสัมพันธ์ หรืออิทธิพลต่อพฤติกรรมของผู้ใช้ในลำดับที่สูงกว่ามาช่วยในการแนะนำทางสังคมจะสามารถช่วยในการเรียนรู้ปัจจัยที่ส่งผลต่อพฤติกรรมของผู้ใช้แต่ละคนได้ จึงได้มีการนำโครงสร้างในลำดับที่สูงกว่าของผู้ใช้มาใช้ช่วยในการวิเคราะห์ด้วยในบางงาน



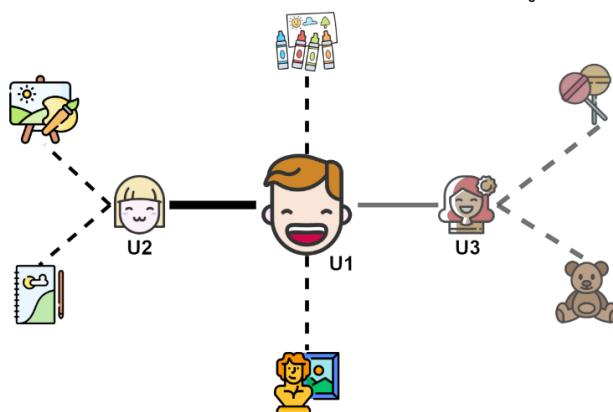
ภาพออกแบบโดยใช้แหล่งข้อมูลจาก Flaticon.com

ภาพที่ 1.2 กราฟแสดงความสัมพันธ์ระหว่างผู้ใช้ U1 และผู้ใช้ U2 และ U3 โดยผู้ใช้ U1 ได้รับอิทธิพลจากผู้ใช้ U4 ผ่านผู้ใช้ U2 และ U3

จากการค้นคว้าข้อมูล ได้มีงานวิจัย A Neural Influence and Interest Diffusion Network for Social Recommendation (DiffNet++) ได้มีการนำประโยชน์ของโซเชียลเน็ตเวิร์คหลายระดับมาใช้ปรับปรุงการสร้างรูปแทนของผู้ใช้ (user modeling) โดยจะพิจารณาว่าพฤติกรรมของผู้ใช้แต่ละคนนั้น จะขึ้นอยู่กับสองด้าน ได้แก่ ด้านอิทธิพลระหว่างผู้ใช้ และด้านสนิยมของตัวผู้ใช้เอง ซึ่ง DiffNet++ ได้มีการวิเคราะห์สนิยมต่อรายการของผู้ใช้ รวมกับการวิเคราะห์อิทธิพลจากผู้ใช้อื่น เพื่อวิเคราะห์ว่าผู้ใช้แต่ละคนนั้นมีแนวโน้มที่จะมีพฤติกรรมไปตามด้านใดในอัตราส่วนเท่าไหร ซึ่ง DiffNet++ แบ่งออกเป็นสองเลเยอร์ได้แก่ เลเยอร์เครือข่ายของอิทธิพลและสนิยม และเลเยอร์การแนะนำ ในเลเยอร์แรกจะมีการแบ่งเครือข่ายออกเป็นสองส่วน ได้แก่ ส่วนของกราฟเครือข่ายสนิยมของผู้ใช้ และส่วนของกราฟเครือข่ายอิทธิพลของผู้ใช้ ซึ่งจะมีการสร้างรูปแทนของผู้ใช้จากการรวมกันของกราฟทั้งสองส่วน และสร้างรูปแทนของรายการจากกราฟเครือข่ายสนิยมของผู้ใช้ โดยรูปแทนของผู้ใช้และรายการจะสร้างโดยใช้ Graph Convolutional Network(GCN)[1]

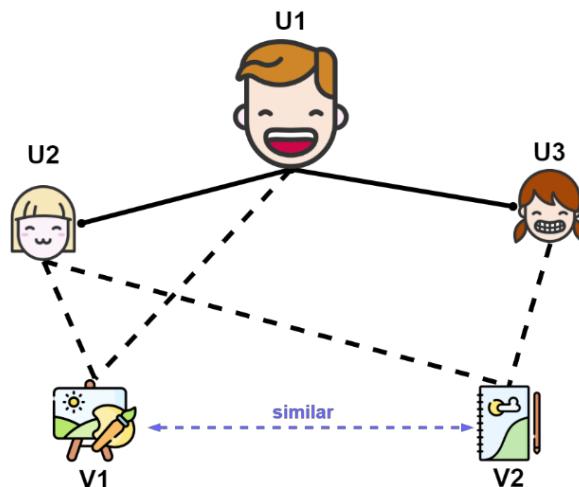
จากการวนซ้ำแต่ละรอบ โดยจะเริ่มจากการสร้างรูปแทนของเพื่อนบ้านลำดับแรก และจะเพิ่มลำดับบนกราฟไปเรื่อยๆ ถ้าลำดับ ซึ่งจะได้รูปแทนมา แบบ และนำรูปแทนในแต่ละลำดับมารวมกันและทำการແນະນຳໃນເລືອກຮັບແນະນຳ ໂດຍການນໍາຮູບແທນຂອງຜູ້ໃຊ້ແລະຮູບແທນຂອງຮາຍກາມທໍາການຄຸນແບບເວັກເຕິອົງ

กราฟຄ່ານໍາຫັກ เป็นกราฟທี่ສັນເຂົ້ມຮວ່າງແຕ່ລະໂທນດຈະມີຄ່ານໍາຫັກຂອງແຕ່ລະສັນ ໂດຍນໍາຫັກແຕ່ລະສັນຈະແສດງຄື່ງອິທີພິລຂອງໂທນດນີ້ທີ່ສັງຜົດຕ່ອົກໂທນດນີ້ ໂດຍໃນເຂົ້ມຮວ່າງແຕ່ລະສັນ ເຮົາສາມາດໃຊ້ຄະແນນ ອ້ອງຈຳນວນຄົງການມີປົກສົມພັນຮັບຜູ້ໃຊ້ແທນນໍາຫັກຂອງຄວາມສັມພັນຮັບຮວ່າງຜູ້ໃຊ້ຕ່ອົງຜູ້ໃຊ້ຫຼືຜູ້ໃຊ້ຕ່ອງຮາຍກາມໄດ້ ເພື່ອແສດງຄື່ງຮັບແນະນຳຂອງອິທີພິລ ອ້ອງຄວາມສຳຄັນຮວ່າງຜູ້ໃຊ້ຕ່ອົງຜູ້ໃຊ້ ແລະຜູ້ໃຊ້ຕ່ອງຮາຍກາມ ອີ່ຢ່າງໄຣກ໌ ຕາມ DiffNet++ ນັ້ນຄື່ງແມ່ຈະມີການນຳຄວາມສັມພັນຮັບທີ່ແບບຜູ້ໃຊ້ຕ່ອົງຜູ້ໃຊ້ ແລະຜູ້ໃຊ້ຕ່ອງຮາຍກາມໃໝ່ໃນການສ້າງຮູບແທນຂອງຜູ້ໃຊ້ ເພື່ອທີ່ຈະຫາຄວາມສັມພັນຮັບຮວ່າງຜູ້ໃຊ້ຕ່ອົງຜູ້ໃຊ້ ແລະຜູ້ໃຊ້ຕ່ອງຮາຍກາມໃໝ່ໃນຫລາຍຮັບແລ້ວກີ່ຕາມ ແຕ່ສັນເຂົ້ມຄວາມສັມພັນຮັບນັ້ນໄດ້ມີການໃຫ້ຄ່ານໍາຫັກຮວ່າງສັນເຂົ້ມທີ່ທ່າກັນ ໃນຄວາມເປັນຈິງແລ້ວ ຄື່ງແມ່ວ່າຜູ້ໃຊ້ຈະມີປົກສົມພັນຮັບກັບຜູ້ໃຊ້ອື່ນໆຫຼືຮາຍການຕ່າງໆ ແຕ່ຮັບແນະນຳຂອງຄວາມສຳຄັນຂອງຄວາມສັມພັນຮັບນັ້ນແຕກຕ່າງກັນຄື່ງແມ່ວ່າຈະອຸ່ນໃນລຳດັບເດີຍກັນບົນໂຫເຊີລເນື້ອຕວີຣີກ໌ຕາມ ຕ້ວຍ່າງເຊັ່ນດັ່ງກາພທີ່ 1.4 ຜູ້ໃຊ້ U1 ເປັນເພື່ອນກັບຜູ້ໃຊ້ U2 ແລະ U3 ແຕ່ U1 ມີຮັບສິນມີຕ່ອງຮາຍການທີ່ຄໍລ້າຍກັບ U2 ດັ່ງນັ້ນ U1 ອາຈະຈະມີແນວໂນັ້ນທີ່ຈະມີພຸດຕິກຣມຕາມ U2 ມາກກວ່າ U3 ຄື່ງຈະເປັນເພື່ອນບ້ານລຳດັບແຮກບົນໂຫເຊີລເນື້ອຕວີຣີກ໌ແມ່ນກັນກີ່ຕາມ ຮວມຄື່ງການໃໝ່ນໍາຫັກບົນສັນເຂົ້ມຄວາມສັມພັນຮັບຮ່າຍສາມາດໃຊ້ໃນການທາຜູ້ໃຊ້ຫຼືຮາຍການທີ່ອາຈະມີລັກຊະນະທີ່ຄໍລ້າຍກັນໃນລຳດັບທີ່ສູງຂຶ້ນບົນໂຫເຊີລເນື້ອຕວີຣີກ໌ໄດ້ອີກດ້ວຍ ຕ້ວຍ່າງເຊັ່ນດັ່ງກາພທີ່ 1.5 ໃຫ້ຜູ້ໃຊ້ U1 ທອບໃໝ່ສິນຄ້າ V1 ແລະເປັນເພື່ອນກັບ U2 ແລະ U3 ໂດຍທີ່ U2 ທອບໃໝ່ສິນຄ້າ V1 ແລະ V2 ແລະ U3 ທອບໃໝ່ສິນຄ້າ V2 ດັ່ງນັ້ນສິນຄ້າ V1 ແລະ V2 ຈຶ່ງອາຈະມີຄວາມຄໍລ້າຍກັນ ແລະການທາຜູ້ໃຊ້ທີ່ມີຮັບສິນມີຄໍລ້າຍກັນແຕ່ອຸ່ນກີ່ໄດ້ເຊັ່ນກັນ ການມີຄ່ານໍາຫັກບົນຄວາມສັມພັນຮັບຮ່າຍຈະສາມາດເພີ່ມປະສິທິພາບການແນະນຳ ແລະສ້າງຄວາມພຶງພອໃຈໃຫ້ແກ່ຜູ້ໃຊ້ເດີມາຂຶ້ນໄດ້



ກາພອອກແບບໂດຍໃຊ້ແລ່ງຂໍ້ມູນຈາກ Flaticon.com

ກາພທີ່ 1.4 ຜູ້ໃຊ້ U1 ເປັນເພື່ອນກັບຜູ້ໃຊ້ U2 ແລະ U3 ແຕ່ມີຮັບສິນທີ່ຄໍລ້າຍກັບ U2 ມາກກວ່າ ຈຶ່ງມີແນວໂນັ້ນທີ່ຈະມີພຸດຕິກຣມຕາມ U2 ມາກກວ່າ U3



ภาพออกแบบโดยใช้แหล่งข้อมูลจาก Flaticon.com

ภาพที่ 1.5 ผู้ใช้ U1 เป็นเพื่อนกับ U2 และ U3 โดยที่ U1 และ U2 ชอบใช้สินค้า V1 และ U2 กับ U3 ชอบใช้สินค้า V2 ดังนั้นสินค้า V1 และ V2 จึงมีความคล้ายกัน

ดังนั้นในงานนี้ เราจึงได้เสนอวิธีแนะนำทางสังคมบนพื้นฐานของกราฟถ่วงน้ำหนัก ที่มีการใช้แหล่งข้อมูลจากโซเชียลเน็ตเวิร์ค โดยภายในกราฟโซเชียลเน็ตเวิร์คแบ่งออกเป็น 2 ส่วน ได้แก่ กราฟความสัมพันธ์ด้านอิทธิพลต่อผู้ใช้ และกราฟสนับสนุนของผู้ใช้ ซึ่งทั้งสองแบบจะถูกนำมาเสนอเป็นกราฟแบบถ่วงน้ำหนัก เพื่อแสดงถึงระดับความสัมพันธ์ระหว่างผู้ใช้ต่อผู้ใช้ กับผู้ใช้ต่อรายการที่อยู่ในกราฟเดียวกัน ดังนี้

1. กราฟผู้ใช้อิทธิพลระหว่างผู้ใช้และผู้ใช้ โดยจะมีค่าของระดับอิทธิพลที่ส่งผลจากผู้ใช้หนึ่งไปยังอีกผู้ใช้หนึ่ง ซึ่งได้จากการเปรียบเทียบค่าน้ำหนักระหว่างผู้ใช้สองคน โดยค่าน้ำหนักของผู้ใช้จะคำนวณได้จากการเปรียบเทียบอัตราส่วนระหว่างจำนวนเส้นเชื่อมทั้งหมดของผู้ใช้ และจำนวนเส้นเชื่อมทั้งหมดของเพื่อนบ้านของผู้ใช้ทุกคนเป็นน้ำหนักของเส้นเชื่อมระหว่างผู้ใช้กับผู้ใช้
2. กราฟผู้ใช้สนับสนุนระหว่างผู้ใช้และรายการ โดยจะมีค่าที่แสดงถึงระดับของความน่าสนใจที่รายการมีต่อผู้ใช้ ซึ่งได้จากการเปรียบเทียบอัตราส่วนกันระหว่างคะแนนที่ผู้ใช้ให้แก่รายการนั้นๆ และผลรวมของคะแนนทั้งหมดที่ผู้ใช้ได้ให้แก่รายการทุกรายการมาเป็นน้ำหนักของเส้นเชื่อมระหว่างผู้ใช้กับรายการ

## 1.2 วัตถุประสงค์

เพื่อเสนอวิธีแนะนำทางสังคมบนพื้นฐานของกราฟแบบถ่วงน้ำหนัก จากแหล่งข้อมูลดังนี้

- 1.2.1 กราฟผู้ใช้อิทธิพลผู้ใช้ต่อผู้ใช้ โดยจะมีค่าของระดับของความอิทธิพลที่ส่งผลจากผู้ใช้หนึ่งไปยังอีกผู้ใช้หนึ่งเป็นน้ำหนักของเส้นเชื่อมระหว่างผู้ใช้กับผู้ใช้
- 1.2.2 กราฟผู้ใช้สนับสนุนของผู้ใช้ต่อรายการ โดยจะมีค่าที่แสดงถึงระดับของความน่าสนใจที่รายการมีต่อผู้ใช้เปรียบเทียบกับรายการอื่นๆ เป็นน้ำหนักของเส้นเชื่อมระหว่างผู้ใช้กับรายการ

### 1.3 ขอบเขตของโครงการ

- 1.3.1 เปรียบเทียบกับวิธีการ DiffNet++ บนคลังข้อมูล Yelp เท่านั้น
  - 1.3.2 ใช้จำนวนผู้ใช้ไม่ต่ำกว่า 5,000 ผู้ใช้ และรายการไม่ต่ำกว่า 40,000 รายการ
  - 1.3.3 การแทนผู้ใช้จะสร้างมาจากการอธิบายระหว่างผู้ใช้ และกราฟสนับสนุนของผู้ใช้

#### 1.4 วิธีการดำเนินงาน

- 1.4.1 ศึกษาและค้นคว้าข้อมูลที่เกี่ยวกับระบบ และวิธีแนะนำแบบต่างๆ
  - 1.4.2 ศึกษาและค้นคว้าข้อมูลแบบวิธีต่างๆที่มีการใช้กราฟ
  - 1.4.3 ทำการนำเสนอแบบวิธีพื้นฐานมาใช้
  - 1.4.4 ทำการพัฒนาวิธีแนะนำ
  - 1.4.5 ทดสอบและวัดประสิทธิภาพของวิธีที่พัฒนา
  - 1.4.6 ปรับปรุงวิธีเพื่อเพิ่มประสิทธิภาพ
  - 1.4.7 สรุปผลการดำเนินงาน ข้อเสนอแนะ และการจัดทำเอกสาร

## ตารางเวลาการดำเนินการ

## 1.5 ประโยชน์ที่คาดว่าจะได้รับ

- 1.5.1 ในด้านความรู้และประสบการณ์ต่อตัวนิสิตเอง
  - 1.5.1.1 ได้รับความรู้เกี่ยวกับระบบแนะนำ (Recommender System)
  - 1.5.1.2 ได้รับความรู้ และประสบการณ์เกี่ยวกับการใช้งานเครื่องมือที่เกี่ยวข้อง
- 1.5.2 ความรู้ ความเข้าใจที่นำไปสู่การแก้ไขปัญหาของสังคมหรือสภาพแวดล้อม
  - 1.5.2.1 สามารถทำการแนะนำรายการให้แก่ผู้ใช้แต่ละคนได้
  - 1.5.2.2 สามารถสร้างประสบการณ์และความพึงพอใจแก่ผู้ใช้

## 1.6 โครงสร้างของรายงาน

บทที่ 2 จะกล่าวถึงความรู้ และงานวิจัยที่เกี่ยวข้อง

บทที่ 3 จะกล่าวถึงวิธีการทดลอง ซึ่งประกอบไปด้วยการเก็บรวบรวมข้อมูล การประมวลผลข้อมูล ล้วงหน้า และวิธีการที่นำเสนอ

บทที่ 4 จะกล่าวถึงผลการประเมินผลทดลอง

บทที่ 5 จะกล่าวถึงข้อสรุป และข้อเสนอแนะ

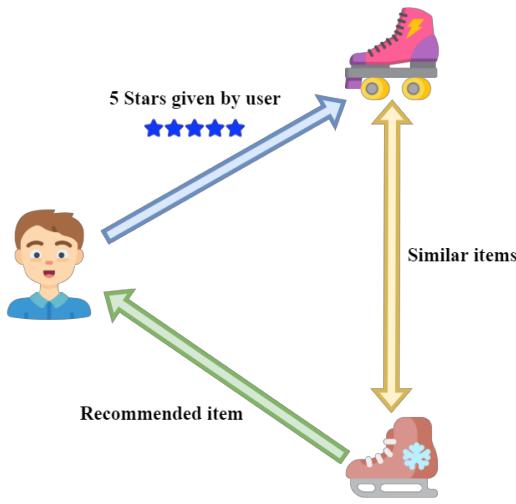
## บทที่ 2

### ความรู้ และงานวิจัยที่เกี่ยวข้อง

#### 2.1 Recommendation System

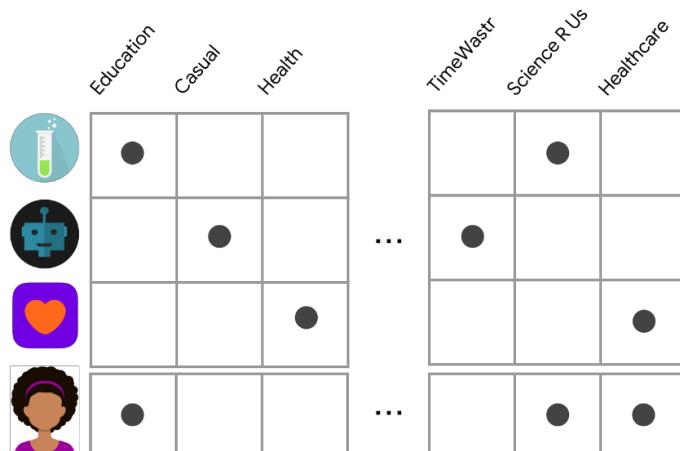
##### 2.1.1 Content-based Filtering

Content-based Filtering เป็นวิธีการหนึ่งของระบบแนะนำ โดยจะดูจากลักษณะของรายการที่ผู้ใช้เคยมีปฏิสัมพันธ์ด้วยมาก่อนเพื่อทำการแนะนำรายการที่มีลักษณะคล้ายกันให้แก่ผู้ใช้โดยอาศัยการดูจากผลตอบรับ (Feedback) ของผู้ใช้ต่อรายการหนึ่งๆ จากตัวอย่างในภาพที่ 2.1



ภาพอອກແບບໂດຍໃຫ້ແລ່ງຂໍ້ມູນຈາກ Flaticon.com

ภาพที่ 2.1 แสดงภาพรวมหลักการทำงานของวิธี Content-based Filtering



อ้างอิง: Content-based Filtering | Recommendation Systems | Google Developers.

(2022). Retrieved 25 April 2022, from <https://developers.google.com/machine-learning/recommendation/content-based/basics>

ภาพที่ 2.2 แสดงตัวอย่างของลักษณะเมทริกซ์ระหว่างรายการกับลักษณะของรายการ และเมทริกซ์ระหว่างผู้ใช้กับลักษณะของรายการที่ผู้ใช้มีปฏิสัมพันธ์ด้วย

จากราพที่ 2.2 แสดงตารางเมทริกซ์ระหว่างรายการและลักษณะของการ และเมทริกซ์ระหว่างผู้ใช้และลักษณะของการที่ผู้ใช้ให้ผลตอบรับกลับมา content-based filtering จะทำการหาค่าความคล้ายกัน (similarity) ระหว่างรายการแต่ละรายการ และทำการแนะนำรายการที่ผู้ใช้ไม่เคยมีปฏิสัมพันธ์มาก่อน และมีค่าความคล้ายกันกับรายการที่ผู้ใช้เคยมีปฏิสัมพันธ์มาก่อนและให้ผลตอบรับที่ดี ในการหาค่าความคล้ายกันระหว่างสองเวกเตอร์สามารถทำได้โดยการใช้ Cosine Similarity ดังนี้

### Cosine Similarity

$$COS(\theta) = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}} \quad \text{สมการที่ 1}$$

*A* เวกเตอร์ของรายการ A

*B* เวกเตอร์ของรายการ B

โดยค่าที่คำนวนได้มาจากการคำนวณ cosine similarity กันระหว่างสองเวกเตอร์จะมีค่าอยู่ระหว่าง [0-1] โดยที่ 0 หมายถึงเวกเตอร์ทั้งสองไม่มีความคล้ายกันเลย และ 1 หมายถึงเวกเตอร์ทั้งสองมีความเหมือนกัน ยิ่งค่าที่ได้มากเท่าไหร่ หมายถึงสองเวกเตอร์นั้นมีความคล้ายกันมาก (มุม  $\theta$  ระหว่างเวกเตอร์ทั้งสองมีค่าน้อย ค่า cosine จะมีค่ามาก) โดย content-based filtering สามารถที่จะแนะนำรายการให้แก่ผู้ใช้ได้โดยที่ไม่จำเป็นต้องมีข้อมูลของผู้ใช้คนอื่นๆ และสามารถแนะนำรายการที่ผู้ใช้มีความสนใจได้อย่างเฉพาะเจาะจง ในขณะเดียวกัน content-based filtering จำเป็นที่จะต้องใช้ข้อมูลคุณสมบัติของรายการเพื่อใช้ในการแนะนำรายการได้ และยังมีข้อจำกัดในการแนะนำที่แนะนำได้เฉพาะรายการที่มีคุณสมบัติที่ผู้ใช้เคยมีปฏิสัมพันธ์แล้วเท่านั้น

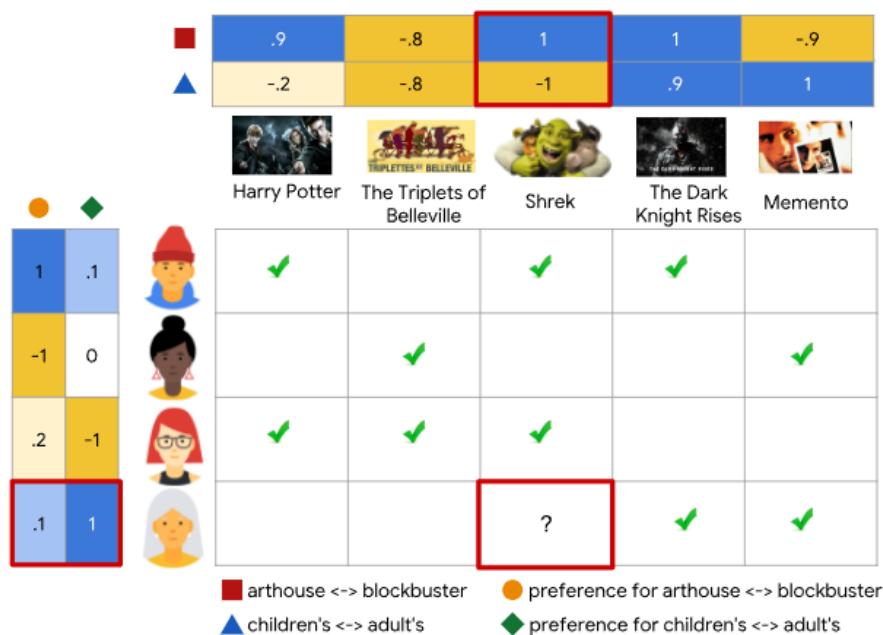
### 2.1.2 Collaborative Filtering (CF)

Collaborative Filtering หรือ CF เป็นวิธีที่พัฒนามาเพื่อลดข้อจำกัดของวิธีการ content-based filtering โดยจะพิจารณาค่าความคล้ายกันระหว่างผู้ใช้และรายการเพื่อช่วยในการแนะนำรายการต่างๆให้แก่ผู้ใช้ CF สามารถที่จะแนะนำรายการให้แก่ผู้ใช้โดยพิจารณาจากลักษณะความสนใจของผู้ใช้คนอื่นที่มีความสนใจหรือพฤติกรรมที่คล้ายกันได้

	4		2	1	
		5	4		
		3	1	4	3
	5		4	3	
	5	1		2	4

ภาพออกแบบโดยใช้แหล่งข้อมูลจาก Flaticon.com

ภาพที่ 2.3 แสดงตัวอย่างตารางผลตอบรับ หรือตารางคะแนนที่ผู้ใช้ให้แก่รายการ



อ้างอิง: Collaborative Filtering | Recommendation Systems | Google Developers. (2022). Retrieved 25 April 2022, from <https://developers.google.com/machine-learning/recommendation/collaborative/basics>

ภาพที่ 2.4 แสดงการทำนายรายการที่คาดว่าผู้ใช้จะมีปฏิสัมพันธ์ด้วย โดยการถูกการแยกตัวประกอบเมทริกซ์



อ้างอิง: *Collaborative Filtering | Recommendation Systems | Google Developers.* (2022). Retrieved 25 April 2022, from <https://developers.google.com/machine-learning/recommendation/collaborative/matrix>

ภาพที่ 2.5 แสดงตารางผลตอบรับในรูปของเมทริกซ์ระหว่างผู้ใช้และรายการ

การเรียนรู้ในการสร้างรูปแทนของผู้ใช้และรายการสามารถใช้วิธีการแยกตัวประกอบของเมทริกซ์ (Matrix Factorization) ได้ดังนี้

จากภาพที่ 2.5 ตารางทางฝั่งซ้ายแสดงถึงตารางผลตอบรับของผู้ใช้ต่อรายการ โดยมีผู้ใช้ในแต่ละแถว และมีรายการในแต่ละคอลัมน์ โดยตารางผลตอบรับของผู้ใช้ต่อรายการนี้สามารถแสดงได้ในรูปของเมทริกซ์ในทางฝั่งขวา โดยเมทริกซ์ที่ได้จะเกิดจากการคูณกันระหว่างสองเมทริกซ์ คือเมทริกซ์รูปแทนของผู้ใช้ และเมทริกซ์รูปแทนของรายการ การสร้างเมทริกซ์รูปแทนจากการเรียนรู้โดยตัวโมเดลจะทำการปรับค่าของเมทริกซ์รูปแทนทั้งของผู้ใช้และของรายการไปพร้อมๆ กัน เพื่อให้ได้ผลลัพธ์จากการคูณของสองเมทริกซ์รูปแทนนี้ให้มีค่าใกล้เคียงกับเมทริกซ์เดิมมากที่สุด โดยจะได้ค่าการประมาณการของคุณลักษณะของแต่ละผู้ใช้ และแต่ละรายการอีกมา ซึ่งสามารถนำมาหาค่าความคล้ายกันได้ โดยใช้ cosine similarity หรือ cosine distance ได้ CF สามารถแบ่งได้เป็น 2 ประเภทได้แก่

#### 2.1.2.1 User-based

จะทำการแนะนำรายการให้ผู้ใช้โดยเลือกมาจากผู้ใช้อื่นที่มีพฤติกรรมหรือลักษณะความชอบที่คล้ายกัน และจะทำการคำนวณค่าของคะแนนที่คาดว่าผู้ใช้จะให้แก่รายการที่ไม่เคยมีปฏิสัมพันธ์มาก่อนบนพื้นฐานของคะแนนจากผู้ใช้อื่นที่คล้ายกัน

#### 2.1.2.2 Item-based

จะทำการแนะนำรายการให้แก่ผู้ใช้โดยดูจากรายการอื่นๆ ที่มีความคล้ายกัน และจะคำนวณค่าของคะแนนที่คาดว่าผู้ใช้จะให้แก่รายการที่ไม่เคยมีปฏิสัมพันธ์มาก่อนบนพื้นฐานของคะแนนจากการที่คล้ายกัน

## 2.2 Social Recommendation

อิทธิพลทางสังคมสามารถเกิดขึ้นได้หากผู้ใช้งานนั่นๆ มีพฤติกรรมที่ได้รับผลมาจากผู้ใช้คนอื่นๆ ในสังคม โดยอิทธิพลทางสังคมเป็นกระบวนการหนึ่งที่ผู้ใช้จะมีการแนะนำ หรือการเผยแพร่ลักษณะพฤติกรรมของตนไปสู่ผู้ติดตามคนอื่นๆ เช่น การเผยแพร่รายการที่ตนเองใช้ เผยแพร่ลักษณะการใช้ชีวิต หรือการแต่งกายของตนเองบนแพลตฟอร์มโซเชียลต่างๆ ซึ่งอาจจะมีอิทธิพลต่อผู้ที่ติดตามผู้ใช้คนนั่นๆ จนอาจจะเกิดแนวโน้ม (trend) ใหม่ๆ ขึ้นโดยมีอิทธิพลมาจากผู้ใช้คนอื่นในสังคม การแนะนำทางสังคม ไม่เพียงแต่การพิจารณาพฤติกรรมของผู้ใช้แต่ละคนเท่านั้น แต่จะมีการพิจารณาถึงพฤติกรรมของผู้ใช้อื่น ที่อาจจะมีอิทธิพลต่อพฤติกรรมของผู้ใช้ด้วย โดยผู้ใช้งานอาจจะนิยมในการมีปฏิสัมพันธ์ต่อรายการที่กำลังมีแนวโน้มเป็นที่นิยมกันในสังคม หรือผู้ใช้งานอาจจะนิยมในการมีปฏิสัมพันธ์ต่อรายการเฉพาะรายการที่มีลักษณะที่ผู้ใช้สนใจเท่านั้น



ภาพอักษรโดยใช้แหล่งข้อมูลจาก Flaticon.com

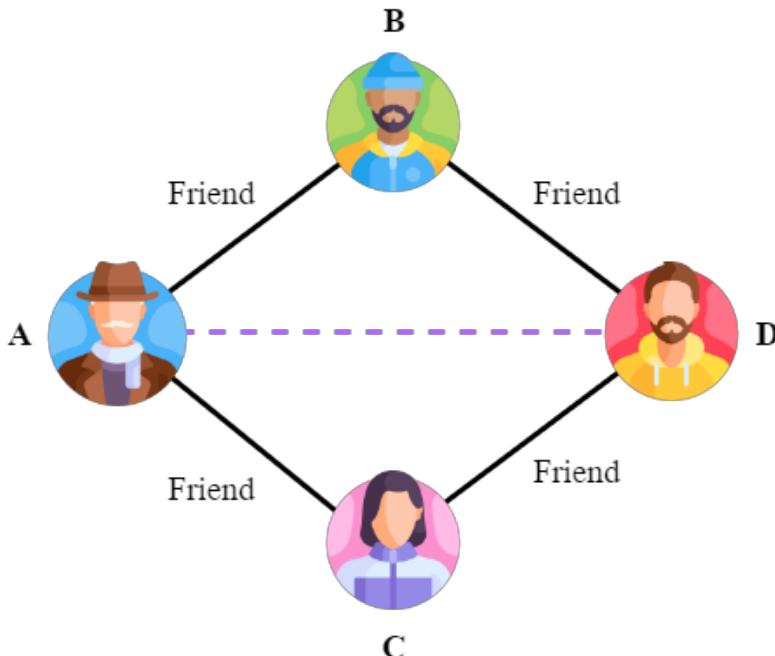
ภาพที่ 2.6 แสดงตัวอย่างลักษณะกราฟบนโซเชียลเน็ตเวิร์คระหว่างผู้ใช้และผู้ใช้

## 2.3 Graph-based Recommendation

เนื่องจากโซเชียลเน็ตเวิร์ค หรือเครือข่ายทางสังคม สามารถที่จะอธิบาย หรือแสดงออกมาในรูปแบบของกราฟได้ เช่น โหนดแต่ละโหนดแทนผู้ใช้แต่ละคน และมีเส้นเชื่อมที่แสดงถึงความสัมพันธ์บางอย่างระหว่างผู้ใช้งาน คน อย่างการเป็นเพื่อน การกดติดตาม หรือการแสดงความคิดเห็นเป็นต้น กราฟสามารถที่จะแสดงความสัมพันธ์ของสิ่งต่างๆ เหล่านี้ออกมาได้อย่างชัดเจน โดยความสัมพันธ์ที่เกิดขึ้นระหว่างสิ่งต่างๆ สามารถนำมาใช้ในกระบวนการของการแนะนำได้ ตัวอย่างเช่น

จากภาพที่ 2.7 แสดงถึงความสัมพันธ์ที่เกิดขึ้นระหว่างผู้ใช้และผู้ใช้งานแพลตฟอร์มโซเชียลมีเดีย ซึ่งแสดงถึงความสัมพันธ์ของความเป็นเพื่อนระหว่างกัน เราสามารถที่จะทำนายการเชื่อมโยงของเส้นความสัมพันธ์ได้ โดยดูจากเพื่อนของผู้ใช้คนนั้นว่ามีเพื่อนที่มีร่วมกันหรือไม่ ซึ่งจะเห็นได้ว่าผู้ใช้ A ที่มี

ความสัมพันธ์ความเป็นเพื่อนกับผู้ใช้ B และ C และทั้งผู้ใช้ B และ C ต่างมีผู้ใช้ D เป็นเพื่อนร่วมกันทั้งสองคน ดังนั้นอาจจะเป็นไปได้ว่าผู้ใช้ A อาจจะมีเส้นเชื่อมความสัมพันธ์กับผู้ใช้ C ได้เช่นกัน นอกจากนี้ความสัมพันธ์ระหว่างสิ่งต่างๆสามารถที่จะแสดงออกมาในรูปแบบของกราฟได้ด้วยเช่นกัน ไม่ว่าจะเป็นความสัมพันธ์ระหว่างเหตุการณ์ต่างๆ หรือความสัมพันธ์ระหว่างผู้ใช้และรายการเป็นต้น



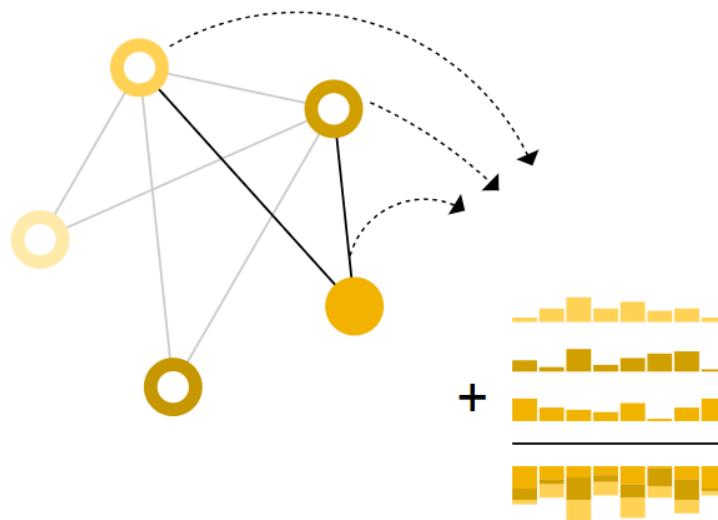
ภาพอักษรแบบโดยใช้แหล่งข้อมูลจาก Flaticon.com

ภาพที่ 2.7 แสดงกราฟแสดงความสัมพันธ์ระหว่างผู้ใช้และผู้ใช้บนแพลตฟอร์มโซเชียลมีเดีย

### 2.3.1 Graph Neural Network (GNN)

โดยปกติแล้ว กรา芬น์อยู่ในชีวิตประจำวันทั่วไป ซึ่งเราสามารถที่จะมองสิ่งต่างๆในรูปแบบของกราฟได้ เช่น ความสัมพันธ์ของสิ่งต่างๆที่เกิดขึ้น คำต่างๆที่ต่อ กันเป็นประโยค หรือเหตุการณ์ต่างๆที่เชื่อมโยงกันก็สามารถที่จะแสดงออกมาในรูปแบบของกราฟได้เช่นกัน โดยโครงสร้างของกราฟนั้นจะประกอบไปด้วยจุด (Vertex) และเส้น หรือขอบ (Edge) เชื่อมต่อกัน หรือสามารถเขียนได้เป็นดังนี้  $\text{Graph} = (V, E)$  กราฟนั้นไม่มีรูปแบบที่ตายตัว มีรูปแบบที่หลากหลาย กราฟที่มีลักษณะต่างกันแต่เมื่อแสดงกราฟในรูปแบบของเมทริกซ์อาจจะได้ว่ากราฟนั้นมีลักษณะเหมือนกัน

ในปัจจุบันนี้ได้มีวิธีการที่นำมาใช้ในการจัดการกับปัญหาด้านกราฟ หรือการวิเคราะห์กราฟ เพื่อนำประโยชน์ และจุดเด่นของกราฟออกมามากที่สุดในการนำไปใช้งานในงานด้านลักษณะต่างๆ ไม่ว่าจะเป็นด้านการวิเคราะห์รูปภาพ ด้านการตรวจจับสิ่งผิดปกติ หรือด้านระบบแนะนำเป็นต้น Graph Neural Network จึงได้เข้ามามีบทบาทในการนำสิ่งที่สามารถแสดงได้ในรูปแบบของกราฟมาแปลงให้อยู่รูปของเวกเตอร์ (Vector) ที่สามารถนำไปใช้ประโยชน์ต่อในหลายๆด้านดังที่กล่าวไว้ข้างต้น

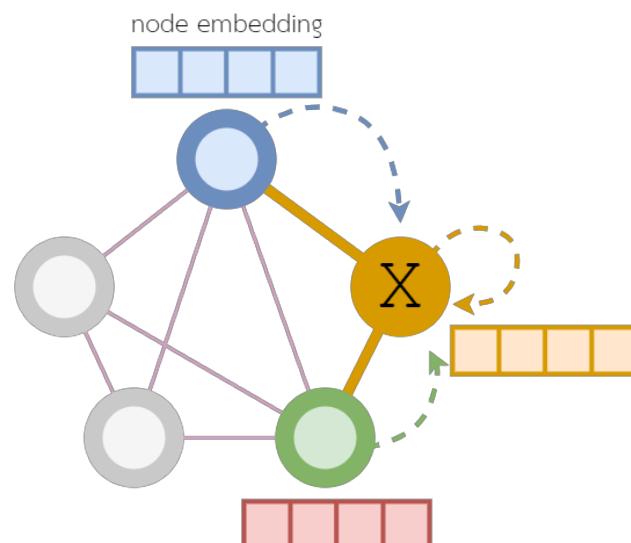


อ้างอิง: Sanchez-Lengeling, et al., “A Gentle Introduction to Graph Neural Networks”, Distill, 2021.

ภาพที่ 2.8 แสดงตัวอย่างวิธีการสร้างรูปแทนของโนนด (สีทึบ) โดยการรวมกันของรูปแทนของโนนดตัวเอง และรูปแทนจากโนนดเพื่อนบ้านที่มีเส้นเชื่อมกัน

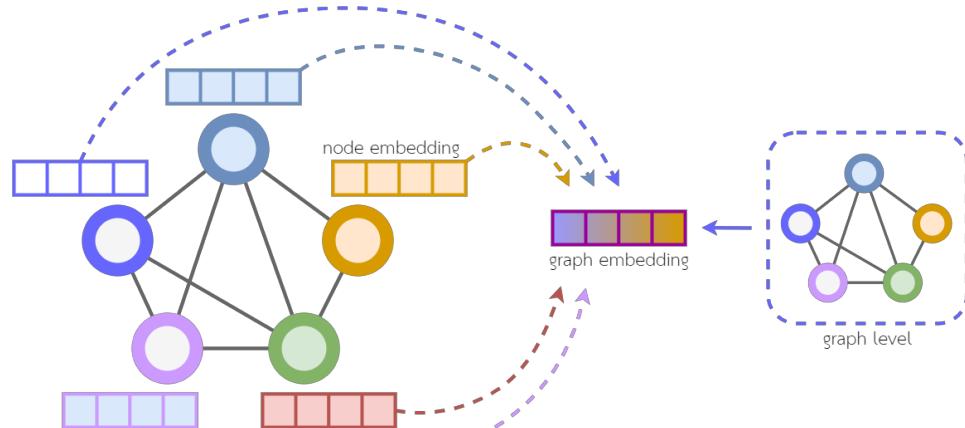
โดยหลักการทำงานของ GNN นั้นคือการรับกราฟเข้ามา และทำการประมวลผลและเรียนรู้ แต่ละส่วนของกราฟในลักษณะของเวกเตอร์ที่มีความสัมพันธ์เกี่ยวข้องกันภายในกราฟนั้นๆ โดยการสร้างรูปแทน (Embedding) หรือเวกเตอร์ของแต่ละจุดที่เกิดจากจุดรอบๆ ดังตัวอย่างในภาพที่ 2.8 ซึ่ง GNN นั้นจะแบ่งการสร้างรูปแทนออกเป็น 2 ระดับ ได้แก่

**2.3.1.1 ระดับโนนด (Node-level)** หรือระดับจุด โดยการสร้างรูปแทนในระดับจุดแต่ละจุด จะเกิดจากการนำรูปแทนของจุดที่มีเส้นขอบเชื่อมต่อกัน หรือเรียกว่าอย่างว่าจุดเพื่อนบ้าน (Neighbors) มารวมกันจนเกิดเป็นรูปแทนของจุดเป้าหมาย (Target) นั้นๆ ดังตัวอย่าง ภาพที่ 2.9



ภาพที่ 2.9 แสดงตัวอย่างลักษณะของรูปแทนในระดับโนนด

**2.3.1.2 ระดับกราฟ (Graph-level)** การสร้างรูปแทนของทั้งกราฟนั้นๆ จะใช้วิธีเดียวกัน กับการสร้างรูปแทนในระดับตัว โดยการสร้างรูปแทนระดับกราฟนั้นจะเกิดจากการนำรูป แทนในระดับจุดทั้งหมดมารวมกันจนเกิดเป็นรูปแทนของกราฟนั้นๆ ดังตัวอย่างภาพที่ 2.10

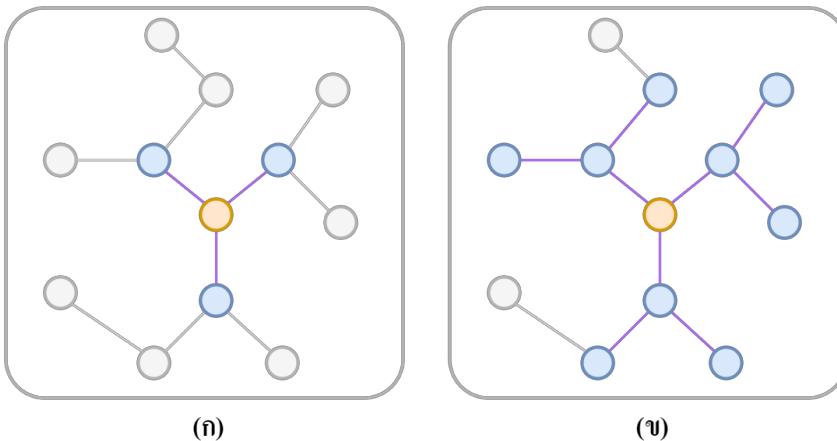


ภาพที่ 2.10 แสดงตัวอย่างลักษณะของรูปแทนในระดับกราฟ

### 2.3.2 Graph Convolutional Networks (GCN)

Graph Convolutional Network[1] หรือ GCN เป็นหนึ่งในรูปแบบของ Convolutional Neural Network แต่เป็นในลักษณะของการนำมาใช้กับกราฟ โดยแนวคิดหลักของ GCN คือการ สร้างรูปแทนหรือสร้างชุดข้อมูลคุณลักษณะของแต่ละโหนดโดยนำข้อมูลจากตัวโหนดตัวมันเอง และ จากโหนดที่เป็นโหนดเพื่อนบ้านมาใช้ในการสร้าง ในที่นี้โหนดเพื่อนบ้านหมายถึงโหนดที่มีเส้นเชื่อม (Edge) โดยตรงกับโหนดที่เราต้องการสร้างรูปแทน โดยจะทำเหมือนกับทุกโหนดในกราฟ

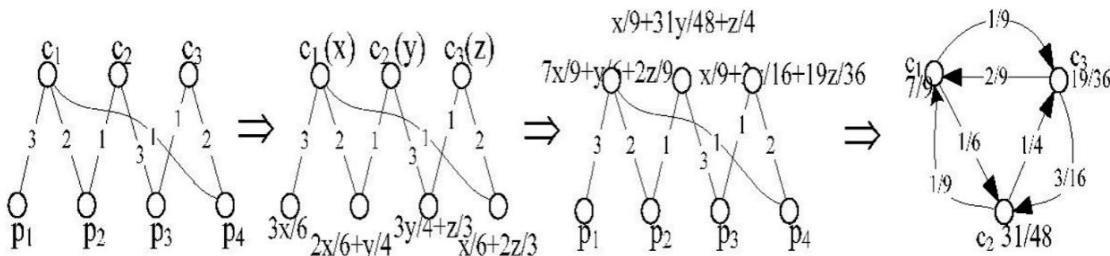
โดยในการสร้างรูปแทนของแต่ละโหนดสามารถทำได้ในหลายวิธีการ เช่นการสร้างรูปแทน ของแต่ละโหนดจากข้อมูลบนโหนดตัวเองและโหนดเพื่อนบ้าน และนำเข้าฟังก์ชันในการหาค่าเฉลี่ย และนำเข้าสู่โครงข่ายประสาทเทียม (Neural Network) เป็นต้น นอกจากนี้ GCN ยังสามารถที่จะ สร้างรูปแทนของโหนดที่มาจากการนำข้อมูลของโหนดในหลายระดับซึ่งได้โดยการนำเข้าข้อมูลที่ได้จากชั้น ก่อนหน้าเข้าไปด้วยในการทำชั้นถัดไป ซึ่งจะทำให้ได้การสร้างรูปแทนโดยใช้ GCN ที่มีความลึกมากขึ้น มีความซับซ้อนมากขึ้น โดย GCN จะมีการให้ค่าน้ำหนักของผู้ใช้แต่ละคนที่เท่ากันในทุกๆเส้นเชื่อม ความสัมพันธ์ ดังตัวอย่างภาพที่ 2.11



ภาพที่ 2.11 แสดงตัวอย่างของการสร้างรูปแบบที่ 1 ระดับชั้น (ก) และที่ 2 ระดับชั้น (ข)

### 2.3.3 Personal Recommendation using Weighted Bipartite Graph Projection

Personal Recommendation using Weighted Bipartite Graph Projection[3] เป็นงานที่ศึกษาทางด้านของวิธีแนะนำราย履歴เฉพาะบุคคล (Personal Recommendation) โดยการใช้ประโยชน์จากการใช้ค่าน้ำหนักบนกราฟสองส่วน (Bipartite Graph) ของความสัมพันธ์ระหว่างผู้ใช้ และรายการ โดยค่าน้ำหนักบนเส้นเชื่อมแต่ละเส้นคือคะแนนที่ผู้ใช้ได้ให้แก่รายการนั้นๆ ในงานนี้ อาศัยหลักการของการจัดสรรทรัพยากร (Resource Allocation) มาใช้ในการปรับค่าข้อมูลของผู้ใช้ และหาค่าความคล้ายกันของผู้ใช้ทุกคู่



อ้างอิง: Shang, M. S., Fu, Y., & Chen, D. B. (2008, December). Personal recommendation using weighted bipartite graph projection. In 2008 International Conference on Apperceiving Computing and Intelligence Analysis (pp. 198-202). IEEE..

ภาพที่ 2.12 แสดงหลักการทำงานของการจัดสรรทรัพยากรบนกราฟสองส่วนระหว่างผู้ใช้และรายการ

จากภาพที่ 2.12 เป็นกราฟสองส่วนที่แสดงถึงความสัมพันธ์ระหว่างผู้ใช้ ( $c$ ) และรายการ ( $p$ ) โดยมีค่าน้ำหนักบนเส้นเชื่อมเป็นคะแนนที่ผู้ใช้ให้แก่รายการนั้นๆ กำหนดให้ข้อมูลตั้งต้นของผู้ใช้  $c_1$ ,  $c_2$  และ  $c_3$  เป็น  $x, y, z$  ตามลำดับ ดังนั้นการทำ resource allocation จะทำการส่งข้อมูลของผู้ใช้ไปยังรายการทุกรายการที่ผู้ใช้ได้ให้คะแนน โดยมีการให้ค่าน้ำหนักของการส่งไปเป็นค่าคะแนนที่ผู้ใช้ให้แก่รายการนั้น เช่น จากผู้ใช้  $c_1, c_2$  และ  $c_3$  ส่งไปยังรายการ  $p_1, p_2, p_3$  และ  $p_4$  จะได้ค่าของรายการเป็น  $3x/6, 2x/6 + y/4, 3y/4 + z/3$  และ  $x/6 + 2z/3$  ตามลำดับ จากนั้นจะทำการส่งข้อมูล

จากแต่ละรายการไปยังผู้ใช้แต่ละคนอีกครั้ง ซึ่งจะได้ตามภาพ และทำการหาอัตราส่วนที่ผู้ใช้แต่ละคน จะส่งไปยังผู้ใช้คนอื่น โดยใช้สมการดังนี้

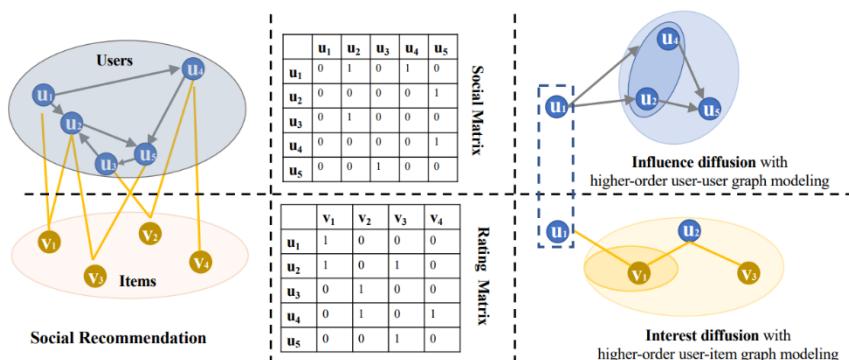
$$rp(u, v) = \sum_{p \in P} \frac{r_{v,p}}{R_p} \frac{r_{u,p}}{R_u} = \frac{1}{R_u} \sum_{p \in P} \frac{r_{u,p} r_{v,p}}{R_p} \quad \text{สมการที่ 2}$$

จากสมการประกอบด้วย

$rp(u, v)$	อัตราส่วนของข้อมูลที่ผู้ใช้ u จะส่งไปผู้ใช้ v
$r_{v,p}$	คะแนนที่ผู้ใช้ v ได้ให้แก่รายการ p
$R_p$	ผลรวมของคะแนนทั้งหมดที่รายการ p ได้รับมาทั้งหมด
$R_u$	ผลรวมของคะแนนทั้งหมดที่ผู้ใช้ u ได้ให้แก่ทุกรายการ

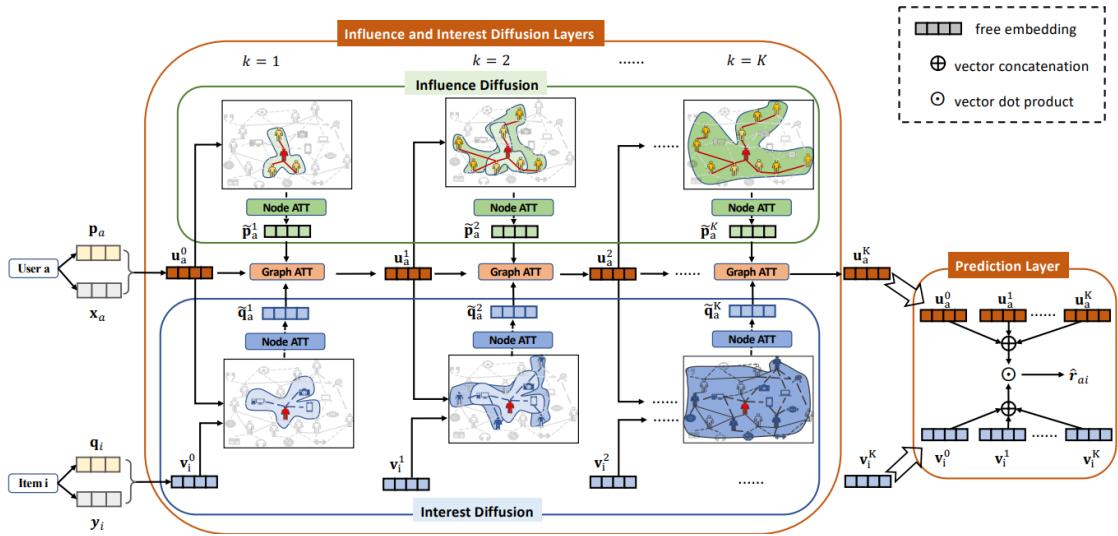
### 2.3.4 A Neural Influence and Interest Diffusion Network for Social Recommendation (DiffNet++)

A Neural Influence and Interest Diffusion Network for Social Recommendation[4] หรือ DiffNet++ เป็นหนึ่งในวิธีการที่ได้ใช้แหล่งข้อมูล และใช้ประโยชน์จากกราฟโซเชียลเน็ตเวิร์ค โดยนำมาใช้ในการพัฒนาและปรับปรุงในงานด้านระบบแนะนำ โดยให้ความสำคัญในการสร้างรูปแบบของผู้ใช้ (user embedding) มาจากแหล่งที่มาของพฤติกรรมของผู้ใช้ จาก 2 แหล่ง ได้แก่ พฤติกรรมของผู้ใช้ที่ได้รับอิทธิพลมาจากผู้ใช้อื่น และพฤติกรรมของผู้ใช้ที่มาจากการสนับสนุนการใช้รายการของผู้ใช้อื่น ดังภาพที่ 2.13 โดยการใช้หลักการเรียนรู้ของกราฟแบบ Graph Convolutional Network (GCN) มาใช้ช่วยในการสร้างรูปแบบของผู้ใช้ และรูปแบบของการบันกราฟโซเชียลเน็ตเวิร์คเพื่อนำมาใช้ในการทำนายคะแนนของรายการที่ผู้ใช้ยังไม่เคยให้เห็นมาก่อน



อ้างอิง: L. Wu, J. Li, P. Sun, R. Hong, Y. Ge and M. Wang, "DiffNet++: A Neural Influence and Interest Diffusion Network for Social Recommendation," in IEEE Transactions on Knowledge and Data Engineering.

ภาพที่ 2.13 แสดงการใช้ข้อมูลที่มาจากการส่องแหล่งเพื่อช่วยในการพัฒนาระบบแนะนำของ DiffNet++

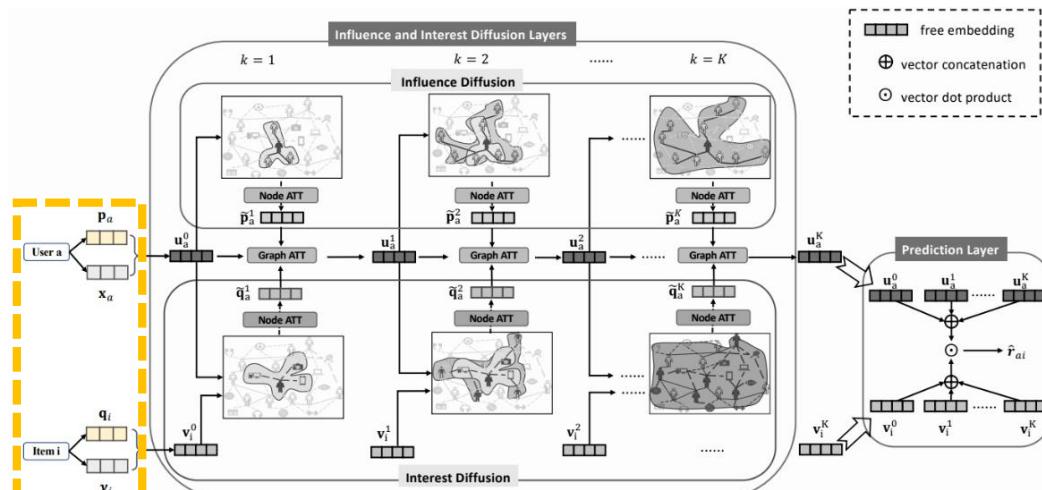


อ้างอิง: L. Wu, J. Li, P. Sun, R. Hong, Y. Ge and M. Wang, "DiffNet++: A Neural Influence and Interest Diffusion Network for Social Recommendation," in IEEE Transactions on Knowledge and Data Engineering.

ภาพที่ 2.14 แสดงภาพรวมของโครงสร้างการทำงานทั้งหมดของวิธีการ DiffNet++

จากภาพที่ 2.14 โครงสร้างสถาปัตยกรรมของ DiffNet++ ประกอบไปด้วย 4 เลเยอร์หลักๆ ได้แก่ เลเยอร์ Embedding, เลเยอร์ Fusion, เลเยอร์ Influence and Interest Diffusion และเลเยอร์ Prediction โดยแต่ละเลเยอร์มีรายละเอียดการทำงานดังนี้

### 2.3.4.1 Embedding Layer



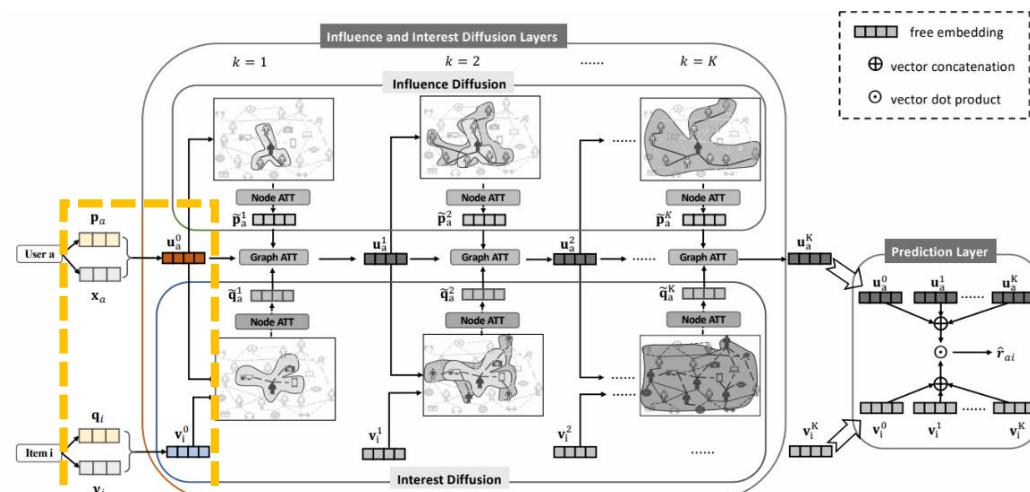
อ้างอิง: L. Wu, J. Li, P. Sun, R. Hong, Y. Ge and M. Wang, "DiffNet++: A Neural Influence and Interest Diffusion Network for Social Recommendation," in IEEE Transactions on Knowledge and Data Engineering.

ภาพที่ 2.15 แสดงการภาพรวมการทำงานในเลเยอร์ Embedding

Embedding layer เป็นเลเยอร์ที่รับข้อมูลรายละเอียดของคลังข้อมูล (Dataset) ของผู้ใช้ (User) และรายการ (Item) โดยในเลเยอร์นี้จะทำการสร้างรูปแทนของผู้ใช้ ( $p_a$ ) และของรายการ ( $q_i$ ) แบบตั้งต้น โดยจะทำการสุ่มค่าของรูปแทนของผู้ใช้และของรายการขึ้นมาจากการแจกแจงแบบปกติ (Normal Distribution) ใช้โดยมีขนาดของรูปแทนดังนี้

รูปแทนตั้งต้นของผู้ใช้ $p_a$	[จำนวนของผู้ใช้, ขนาดของมิติ]
รูปแทนตั้งต้นของรายการ $q_i$	[จำนวนของรายการ, ขนาดของมิติ]

### 2.3.4.2 Fusion Layer



อ้างอิง: L. Wu, J. Li, P. Sun, R. Hong, Y. Ge and M. Wang, "DiffNet++: A Neural Influence and Interest Diffusion Network for Social Recommendation," in IEEE Transactions on Knowledge and Data Engineering.

ภาพที่ 2.16 แสดงภาพรวมการทำงานของเลเยอร์ Fusion

Fusion layer จะรับข้อมูลเข้ามาเป็นรูปแทนของผู้ใช้  $p_a$  และเวกเตอร์คุณสมบัติ (Feature Vector)  $x_a$  โดย เวกเตอร์คุณสมบัติของผู้ใช้แต่ละคนจะมาจากการรวมเวกเตอร์คุณสมบัติต่างๆของผู้ใช้คนนั้นๆ เช่น การนำรูปแทนของคำวิจารณ์ทั้งหมดที่ผู้ใช้คนนั้นได้ให้แก่รายการต่างๆมารวมกันเป็นเวกเตอร์คุณสมบัติ ของผู้ใช้คนนั้นๆ โดยในเลเยอร์นี้จะทำการรวมรูปแทนของผู้ใช้ที่ได้จากเลเยอร์ Embedding และเวกเตอร์คุณสมบัติ ซึ่งจะได้เป็นรูปแทนผสม (Fusion Embedding) ของผู้ใช้  $u_a^0$  โดยใช้สมการดังนี้

$$u_a^0 = g(W_1 \times [p_a, x_a]) \quad \text{สมการที่ 3}$$

จากสมการประกอบด้วย

$W_1$  เมทริกซ์การแปลง (Transformation Matrix)

$g(x)$  พัฟ์ชันการแปลง ในที่นี้จะใช้เป็นพัฟ์ชันแบบไม่เชิงเส้นตรง (non-linear function)

$p_a$  รูปแทนของผู้ใช้ a ที่ได้จากการเลเยอร์ Embedding

$x_a$  เวกเตอร์คุณสมบัติของผู้ใช้ a

$u_a^0$  รูปแทนผู้สมของผู้ใช้ a ที่ระดับชั้นที่ 0 (Initialize State)

และการสร้างรูปแทนผู้สมของรายการ  $v_i^0$  ก็ทำเช่นเดียวกันดังนี้

$$v_i^0 = g(W_2 \times [q_i, y_i]) \quad \text{สมการที่ 4}$$

จากสมการประกอบด้วย

$W_2$  เมทริกซ์การแปลง (Transformation Matrix)

$g(x)$  พัฟ์ชันการแปลง ในที่นี้จะใช้เป็นพัฟ์ชันแบบไม่เชิงเส้นตรง (non-linear function)

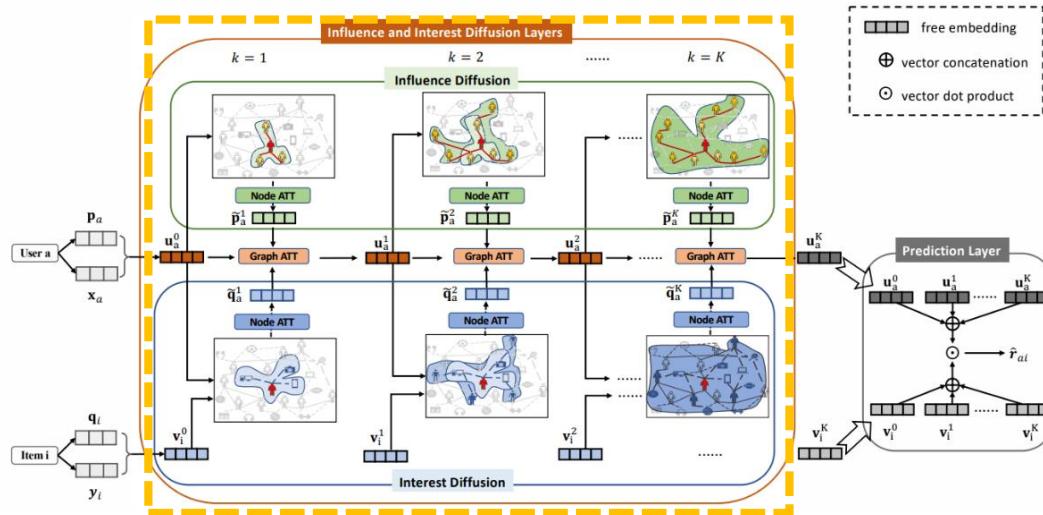
$q_i$  รูปแทนของรายการ i ที่ได้จากการเลเยอร์ Embedding

$y_i$  เวกเตอร์คุณสมบัติของรายการ i

$v_i^0$  รูปแทนผู้สมของรายการ i ที่ระดับชั้นที่ 0 (Initialize State)

จากสมการจะได้ว่ารูปแทนผู้สม หรือ Fusion Embedding ได้มาจากการนำเข้าข้อมูลรูปแทนของแต่ละผู้ใช้  $p_a$  และเวกเตอร์คุณสมบัติ  $x_a$  ของผู้ใช้แต่ละคนเข้าโครงข่ายประสาทเทียมเชื่อมโยงสมบูรณ์แบบ 1 ชั้น (one-layer fully connected neural network) ซึ่งจะได้ออกมาเป็นเวกเตอร์รูปแทนผู้สมของผู้ใช้  $u_a^0$  และทำเช่นเดียวกันกับรูปแทนผู้สมของรายการ  $v_i^0$  โดยนำเข้ารูปแทนของรายการ  $q_i$  และเวกเตอร์คุณสมบัติของรายการ  $y_i$  เข้าโครงข่ายประสาทเทียมเชื่อมโยงสมบูรณ์แบบ 1 ชั้น

### 2.3.4.3 Influence and Interest Diffusion Layers

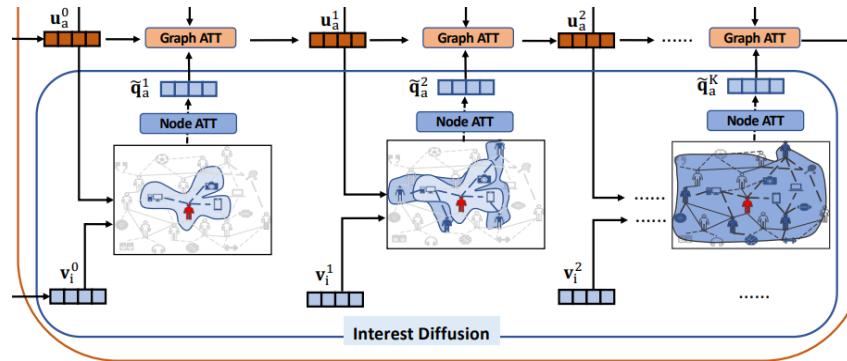


อ้างอิง: L. Wu, J. Li, P. Sun, R. Hong, Y. Ge and M. Wang, "DiffNet++: A Neural Influence and Interest Diffusion Network for Social Recommendation," in IEEE Transactions on Knowledge and Data Engineering.

ภาพที่ 2.17 แสดงภาพรวมของเลเยอร์ Influence and Interest Diffusion ของ DiffNet++

ในเลเยอร์ Influence and Interest Diffusion จะมีการทำงานแบบเรียกซ้ำเพื่อหารูปแทนของผู้ใช้และรายการในแต่ละระดับของกราฟ โดยจะทำการรับข้อมูลรูปแทนของผู้ใช้แต่ละคน และรูปแทนของรายการแต่ละรายการเข้าสู่ในเลเยอร์นี้ โดยในแต่ละระดับชั้น  $k+1$  จะทำการรับข้อมูลของรูปแทนผู้ใช้ และรูปแทนของรายการมาจากระดับชั้น  $k$  ก่อนหน้า และทำการปรับค่ารูปแทนของทั้งผู้ใช้และรายการในแต่ละเลเยอร์โดยการใช้การดำเนินการของการแพร่กระจาย โดยจะแบ่งออกเป็นสองส่วน ได้แก่ ส่วนของกราฟสนับสนุนระหว่างผู้ใช้และการ และรายการ และส่วนของกราฟอิทธิพลระหว่างผู้ใช้และผู้ใช้ โดยมีรายละเอียดการทำงานในแต่ละส่วนดังนี้

### 2.3.4.3.1 ส่วนของกราฟสนับสนุนระหว่างผู้ใช้และการรับรู้ (Interest Diffusion)



อ้างอิง: L. Wu, J. Li, P. Sun, R. Hong, Y. Ge and M. Wang, "DiffNet++: A Neural Influence and Interest Diffusion Network for Social Recommendation," in IEEE Transactions on Knowledge and Data Engineering.

ภาพที่ 2.18 แสดงภาพรวมการทำงานในส่วนของกราฟสนับสนุนระหว่างผู้ใช้และการรับรู้

มีสมการการดำเนินการของการแพร่กระจายดังนี้

$$\tilde{v}_i^{k+1} = AGG_u(u_a^k, \forall a \in R_i) = \sum_{a \in R_i} \eta_{ia}^{k+1} u_a^k \quad \text{สมการที่ 5}$$

$$v_i^{k+1} = \tilde{v}_i^{k+1} + v_i^k \quad \text{สมการที่ 6}$$

กำหนดให้

$G_S$  กราฟอิทธิพลระหว่างผู้ใช้และผู้ใช้ (Influence Social Network Graph)

$G_I$  กราฟสนับสนุนระหว่างผู้ใช้และการรับรู้ (Interest Network Graph)

จากสมการประกอบด้วย

$\tilde{v}_i^{k+1}$  รูปแทนของรายการ  $i$  ที่ระดับชั้น  $k+1$  ซึ่งคำนวณมาจากรูปแทนของผู้ใช้ที่มีปฏิสัมพันธ์กับรายการนั้นจากราฟสนับสนุนระหว่างผู้ใช้และการรับรู้  $G_I$

$u_a^k$	รูปแทนของผู้ใช้ a ที่ระดับชั้น k (ชั้นก่อนหน้า k+1) โดยผู้ใช้ a ทุกคนคือผู้ใช้ที่มีปฏิสัมพันธ์กับรายการ i (เช่น ผู้ใช้ทุกคนที่ให้คะแนนรีวิวแก่รายการ i)
$\eta_{ia}^{k+1}$	ค่าน้ำหนักร่วม (Aggregation Weight) ในการสร้างรูปแทนของรายการ i ที่มีส่วนเชื่อมกับผู้ใช้ a ที่ระดับชั้น k+1
$v_i^{k+1}$	รูปแทนของรายการ i ที่ระดับชั้น k+1 ที่ผ่านกับปรับปรุงค่าแล้ว

จากสมการจะได้ว่าในการปรับค่ารูปแทนของรายการ i ที่ระดับ k+1 ( $v_i^{k+1}$ ) จะต้องสร้างรูปแทนของรายการ i ที่ระดับชั้น k+1 ( $\tilde{v}_i^{k+1}$ ) โดยการหาผลรวมของผลคูณระหว่างรูปแทนของผู้ใช้ทุกคนที่มีปฏิสัมพันธ์กับรายการ i ที่ระดับชั้น k ( $u_a^k$ ) กับค่าน้ำหนักร่วมของความสัมพันธ์แต่ละความสัมพันธ์ ( $\eta_{ia}^{k+1}$ ) จากนั้นทำการปรับค่ารูปแทนของรายการ i ที่ระดับชั้น k+1 ( $v_i^{k+1}$ ) โดยการนำรูปแทนที่ได้จากระดับชั้น k ( $v_i^k$ ) บวกกับรูปแทนที่ได้จากการระดับชั้น k+1 ( $\tilde{v}_i^{k+1}$ ) ซึ่งจะได้เป็นค่าของรูปแทนรายการ i ที่ระดับชั้น k+1 ( $v_i^{k+1}$ )

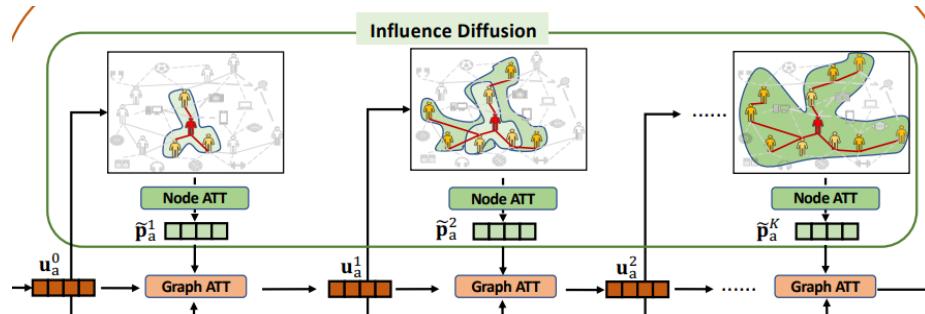
สมการในการหาค่าน้ำหนักร่วม เป็นดังนี้

$$\eta_{ia}^{k+1} = MPL_1([v_i^k, u_a^k]) \quad \text{สมการที่ 7}$$

ค่าน้ำหนักร่วม หรือเรียกว่าค่าน้ำหนักความสนใจ (Attention Weight) ของรายการที่มีต่อแต่ละความสัมพันธ์ระหว่างผู้ใช้ ซึ่งหาได้จากการใช้โครงข่ายประสาทเทียม (Multilayer Perceptron, MLP) ในการเรียนรู้ค่าน้ำหนักตรงนี้ ออกมา และนำค่าน้ำหนักที่ได้มาทำการปรับให้มีค่าอยู่ในช่วงที่เหมาะสม (Normalization) โดยใช้สมการดังนี้

$$\eta_{ia}^{k+1} = \frac{\exp(\eta_{ia}^{k+1})}{\sum_{b \in R_i} \exp(\eta_{ib}^{k+1})} \quad \text{สมการที่ 8}$$

### 2.3.4.3.2 ส่วนของกราฟอิทธิพลระหว่างผู้ใช้และผู้ใช้ (Influence Diffusion)



อ้างอิง: L. Wu, J. Li, P. Sun, R. Hong, Y. Ge and M. Wang, "DiffNet++: A Neural Influence and Interest Diffusion Network for Social Recommendation," in IEEE Transactions on Knowledge and Data Engineering.

ภาพที่ 2.19 แสดงภาพรวมการทำงานในส่วนของกราฟอิทธิพลระหว่างผู้ใช้และรายการ

โดยในส่วนของกราฟอิทธิพลระหว่างผู้ใช้และผู้ใช้นั้นจะมีหลักการทำงานที่คล้ายกับฝั่งของกราฟสนิมระหว่างผู้ใช้และรายการ ใน การสร้างรูปแทนเพื่อแสดงถึงผู้ใช้แต่ละคน หรืออาจจะแสดงถึงพฤติกรรมของผู้ใช้แต่ละคนนั้นจะเกิดจากปัจจัยที่มาจากการส่องแผลง ได้แก่ พฤติกรรมของผู้ใช้ที่เกิดจากการได้รับอิทธิพลมาจากการผู้ใช้คนอื่นบนกราฟอิทธิพล  $G_S$  และพฤติกรรมของผู้ใช้ที่เกิดจากการสนิมของตัวผู้ใช้เองบนกราฟสนิม  $G_I$  โดยจะทำการรวมรูปแทนของผู้ใช้ที่เกิดจากทั้งสองแหล่งเข้าด้วยกัน และเนื่องจากผู้ใช้แต่ละคน อาจจะได้มีพฤติกรรมที่มาจากการปัจจัยสองแหล่งที่ไม่เท่ากัน จึงให้มีการให้ค่าน้ำหนักที่มาจากการแต่ละแหล่งที่แตกต่างกัน หลังจากนั้นจึงนำไปบวกกับรูปแทนของผู้ใช้ที่ได้จากระดับชั้นก่อนหน้า เพื่อให้ได้ค่าของรูปแทนของผู้ใช้ในระดับชั้นปัจจุบัน

มีสมการการคำนวณการของกราฟอิทธิพลที่มีดังนี้

$$u_a^{k+1} = u_a^k + (\gamma_{a1}^{k+1} \tilde{p}_a^{k+1} + \gamma_{a2}^{k+1} \tilde{q}_a^{k+1}) \quad \text{สมการที่ 9}$$

$$\tilde{p}_a^{k+1} = \sum_{b \in S_a} \alpha_{ab}^{k+1} u_b^k \quad \text{สมการที่ 10}$$

$$\tilde{q}_a^{k+1} = \sum_{i \in R_a} \beta_{ai}^{k+1} v_i^k \quad \text{สมการที่ 11}$$

	จากสมการประกอบด้วย
$u_a^{k+1}$	รูปแทนของผู้ใช้ a ที่ระดับชั้น k+1
$\tilde{p}_a^{k+1}$	รูปแทนของผู้ใช้ a ที่ระดับชั้น k+1 ที่คำนวณมาจากรูปแทนของผู้ใช้ที่มีปฏิสัมพันธ์ด้วยทุกคนของผู้ใช้ a ในกราฟอิทธิพลระหว่างผู้ใช้และผู้ใช้ $G_S$
$\tilde{q}_a^{k+1}$	รูปแทนของผู้ใช้ a ที่ระดับชั้น k+1 ที่คำนวณมาจากรูปแทนของรายการที่ผู้ใช้ a มีปฏิสัมพันธ์ด้วยทุกรายการในกราฟสนิยมระหว่างผู้ใช้และรายการ $G_I$
$\alpha_{ab}^{k+1}$	ค่าน้ำหนักที่แสดงถึงระดับอิทธิพลของผู้ใช้ b ที่ส่งผลต่อผู้ใช้ a ที่ระดับชั้น k+1 ในกราฟอิทธิพล $G_S$
$\beta_{ai}^{k+1}$	ค่าน้ำหนักที่แสดงถึงระดับความดึงดูดของรายการ i ที่มีต่อผู้ใช้ a ที่ระดับชั้น k+1 ในกราฟสนิยม $G_I$
$\gamma_{a1}^{k+1}, \gamma_{a2}^{k+1}$	ค่าน้ำหนักระดับกราฟที่แสดงถึงระดับความสำคัญที่แต่ละผู้ใช้ให้ระหว่างกราฟอิทธิพลกับกราฟสนิยมตามลำดับ

จากสมการ การหารูปแทนของผู้ใช้ a ที่เกิดจากการได้รับปัจจัยพฤติกรรมมาจากอิทธิพลของผู้ใช้คนอื่นที่ระดับชั้น k+1 ( $\tilde{p}_a^{k+1}$ ) ได้จากการหาผลรวมของผลคูณระหว่างค่าน้ำหนัก  $\alpha_{ab}^{k+1}$  และรูปแทนผู้ใช้  $u_b^k$  โดยที่ b แทนผู้ใช้แต่ละคนที่มีปฏิสัมพันธ์กับผู้ใช้ a ที่ระดับ k และการหารูปแทนของผู้ใช้ a ที่เกิดจากการได้รับปัจจัยพฤติกรรมมาจากกราฟสนิยมต่อรายการที่ระดับชั้น k+1 ( $\tilde{q}_a^{k+1}$ ) ได้จากการหาผลรวมของผลคูณระหว่างค่าน้ำหนัก  $\beta_{ai}^{k+1}$  และรูปแทนรายการ  $v_i^k$  โดยที่ i แทนรายการแต่ละรายการที่ผู้ใช้ a มีปฏิสัมพันธ์ด้วยที่ระดับชั้น k หลังจากนั้นจะทำการปรับค่าของรูปแทนผู้ใช้ a ที่ระดับชั้น k+1 ( $u_a^{k+1}$ ) โดยการนำรูปแทนผู้ใช้จากระดับชั้น k และรูปแทนที่มาจากการหักลบกัน โดยจะมีการกำหนดค่าน้ำหนัก ( $\gamma_{al}^{k+1}$ ) ให้แก่รูปแทนที่มาจากการหักลบกันเป็นต้นไป สมการที่ใช้ในการคำนวณค่าน้ำหนักระดับกราฟ ( $\gamma_{al}^{k+1}$ ) เป็นดังนี้

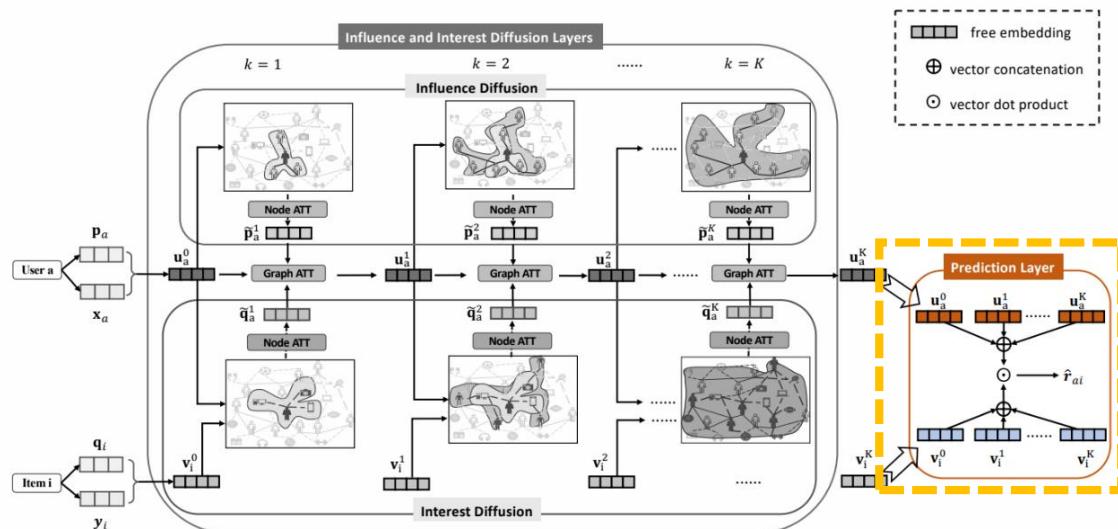
$$\gamma_{a1}^{k+1} = MLP_4([u_a^k, \tilde{p}_a^k]) \quad \text{สมการที่ 12}$$

$$\gamma_{a2}^{k+1} = MLP_4([u_a^k, \tilde{q}_a^k]) \quad \text{สมการที่ 13}$$

ค่าน้ำหนักระดับกราฟจะแสดงถึงค่าน้ำหนักที่ผู้ใช้แต่ละคนให้ความสำคัญ หรือได้รับปัจจัยทางพฤติกรรมมาจากห้องสองแหล่งที่แตกต่างกัน หากผู้ใช้มีค่าน้ำหนักของรูปแทนผู้ใช้ที่มาจากการฝึกอิทธิพล ( $\gamma_{a1}^{k+1}$ ) สูง หมายถึงพฤติกรรมหรือรูปแทนของผู้ใช้คนนั้นค่อนข้างที่จะได้รับอิทธิพลมาจากอิทธิพลระหว่างผู้ใช้มาก ในทางกลับกันหากค่าน้ำหนักของรูปแทนผู้ใช้ที่มาจากการฝึกสนิยม ( $\gamma_{a2}^{k+1}$ ) มีค่ามาก จะหมายถึงพฤติกรรมหรือรูปแทนของผู้ใช้คนนั้นค่อนข้างที่จะได้รับอิทธิพลมาจากการสนิยมของผู้ใช้ที่มีต่อรายการที่ผู้ใช้ให้ความสนใจมากกว่ามาจากผู้ใช้คนอื่น

จากสมการการหาค่าน้ำหนักของปัจจัยแต่ละผู้ หาได้จากการใช้โครงข่ายประสาทเทียม (MLP) และรับข้อมูลเข้าเป็นรูปแทนของผู้ใช้จากระดับชั้นก่อนหน้าที่เชื่อม (concatenate) กับรูปแทนของผู้ใช้ที่ได้รับปัจจัยมาจากการแต่ละผู้

#### 2.3.4.4 Prediction Layer



อ้างอิง: L. Wu, J. Li, P. Sun, R. Hong, Y. Ge and M. Wang, "DiffNet++: A Neural Influence and Interest Diffusion Network for Social Recommendation," in IEEE Transactions on Knowledge and Data Engineering.

ภาพที่ 2.20 แสดงการภาระรวมการทำงานในเลเยอร์ Prediction

Prediction layer เป็นเลเยอร์สุดท้ายของการวิธีการ DiffNet++ โดยจะรับข้อมูลต่อมากาเลเยอร์ Influence and Interest Diffusion ซึ่งจะอุปกรณ์ในรูปของรูปแทนของผู้ใช้ และรูปแทนของรายการที่ผ่านกระบวนการวนซ้ำมาแล้วเป็นจำนวน  $K$  ระดับชั้น โดยจะทำการนำรูปแทนของผู้ใช้แต่ละคนที่หาได้จาก GCN ในแต่ละรอบ หรือในแต่ละระดับ นำรูป

แทนที่ต้องหุ่นระดับชั้นมาเข้ามาร่วมต่อเข้าด้วยกันด้วยการ Concatenation เช่นเดียวกันกับรูปแทนของราย โดยการนำรูปแทนของแต่ละรายการที่ได้จาก GCN ในแต่ละระดับชั้นมาทำการเข้ามาร่วมต่อเข้าด้วยกันทั้งหมดโดยการ Concatenation หลังจากนั้นจะทำการคำนวณค่าแนวที่คาดว่าผู้ใช้จะให้แก่รายการหนึ่งๆโดยการทำผลคูณภายใน (inner product) ระหว่างเวกเตอร์รูปแทนของผู้ใช้ และเวกเตอร์รูปแทนของรายการ ตามสมการดังนี้

$$\hat{r}_{ai} = [u_a^o || u_a^1 || \dots || u_a^K]^T [v_i^o || v_i^1 || \dots || v_i^K] \quad \text{สมการที่ 14}$$

จากสมการประกอบด้วย

$\hat{r}_{ai}$  ค่าแนวที่ผู้ใช้ a น่าจะให้แก่รายการ i ที่ซึ่งเป็นรายการที่ผู้ใช้ยังไม่เคยให้ค่าแนวมาก่อน

$u_a^K$  รูปแทนของผู้ใช้ a ที่ระดับชั้น K

$v_i^K$  รูปแทนของรายการ i ที่ระดับชั้น K

### บทที่ 3

#### วิธีการทดลอง

ในบทนี้จะกล่าวถึงวิธีการศึกษาวิธีแนะนำทางสังคมบนพื้นฐานของกราฟแบบต่อเนื่องน้ำหนัก เพื่อใช้ในการพัฒนาวิธีการ โดยมีทั้งหมด 3 ขั้นตอนหลักๆ ดังนี้

- 1) การเก็บรวบรวมข้อมูล
- 2) การประมวลผลข้อมูลล่วงหน้า
- 3) วิธีการที่นำเสนอ

#### 3.1 การเก็บรวบรวมข้อมูล

ในการศึกษาวิจัยนี้ ทางผู้จัดทำ ได้ใช้แหล่งข้อมูลที่ได้เก็บรวบรวมไว้แล้วของ Yelp จาก [www.yelp.com/dataset](http://www.yelp.com/dataset) ซึ่งสามารถนำข้อมูลนี้มาใช้เพื่อการศึกษาได้ โดยภายในจะประกอบด้วยคุณสมบัติ ต่างๆ (attributes) ของแต่ละข้อมูล คลังข้อมูล Yelp ที่ได้นำมาใช้ในการศึกษาและพัฒนาวิธีการแนะนำใน การพัฒนานี้ได้แก่

- 3.1.1 คลังข้อมูลธุรกิจ (Business) ประกอบด้วยข้อมูลต่างๆ ของแต่ละธุรกิจ เช่น ชื่อธุรกิจ ประเภท ที่อยู่ คะแนนวิจารณ์เฉลี่ย จำนวนการวิจารณ์ที่ได้รับ เป็นต้น
- 3.1.2 คลังข้อมูลผู้ใช้ (User) ประกอบด้วยข้อมูลต่างๆ ของผู้ใช้แต่ละคน เช่น รหัสประจำตัวผู้ใช้ ชื่อผู้ใช้ รายชื่อเพื่อนของผู้ใช้ จำนวนครั้งการวิจารณ์ วันที่สมัครสมาชิก จำนวนผู้ติดตาม เป็นต้น
- 3.1.3 คลังข้อมูลคำวิจารณ์ (Review) ประกอบด้วยข้อมูลต่างๆ ของแต่ละการวิจารณ์ของผู้ใช้ต่อธุรกิจ หนึ่งๆ เช่น รหัสประจำตัวผู้ใช้ที่ให้คำวิจารณ์นั้น คะแนนการวิจารณ์ที่ผู้ใช้นั้นให้ รหัสประจำธุรกิจ ที่รับคำวิจารณ์ วันที่ ข้อความที่วิจารณ์ เป็นต้น

จำนวนห้องหมอดในคลังข้อมูล Yelp สรุปได้ดังตารางต่อไปนี้

ตารางที่ 3.1 แสดงจำนวนของข้อมูลในแต่ละคลังข้อมูลที่ยังไม่ผ่านการประมวลผลล่วงหน้า

คลังข้อมูล	จำนวน
ข้อมูลธุรกิจ(รายการ)	160,585 รายการ
ข้อมูลผู้ใช้	2,189,457 ผู้ใช้
ข้อมูลคำวิจารณ์	8,635,403 คำวิจารณ์

	review_id	user_id	business_id	stars	useful	funny	cool	text	date
0	IWC-xP3rd6obsecCYsGZRg	ak0TdvMgKo4pwqdJSTLwWw	buF9drUCbujLX526sGELQ	4.0	3	1	1	Apparently Prides Osteria had a rough summer a...	2014-10-11 03:34:02
1	8bFej1QE5LXp4O05qjGqXA	YoVfDbnISIw07abNQAClg	RA4V8pr014UyUbDvL-W2A	4.0	1	0	0	This store is pretty good. Not as great as Wal...	2015-07-03 20:38:25
2	NDhkczzKjLshODbqDoNLsg	eC5evKn1TWDyHCyQAwguUw	_sS2LBIGNT5NQb6PD1Vtjw	5.0	0	0	0	I called WVM on the recommendation of a couple...	2013-05-28 20:38:06
3	T5fAqjjFooT4V0eZyuk1w	SFQ1jcnGguO0LYWnbffAA	0AzLzHfOJgL7ROwhdww2ew	2.0	1	1	1	I've stayed at many Marriott and Renaissance M...	2010-01-08 02:29:15
4	sjm_uUcQVxb_EeLCqsYLG	0KA0PAJ8QFMeveQWHFqz2A	8zehGz9jnxFqXOc7KaJxA	4.0	0	0	0	The food is always great here. The service fro...	2011-07-28 18:05:01
...	...	...	...	...	...	...	...	...	...
8635398	PHnqMOU1pzHbnUMk3Cg2zA	6oIZ0y9oW9azON61AhwxYg	yyTtwWQ4JnQMj2rn3W0S0g	1.0	0	0	0	In December, I called in (as a returning custo...	2021-01-26 04:07:14
8635399	dViF8gg9745CspekkNvp2g	EPYNZQFuSKqLi-on3U9dFg	RDgwjgbu5xzIFIAaNn3WCQ	1.0	13	1	0	This guy is a moron that will stalk and harass...	2019-05-01 21:21:43
8635400	7VNKRIClt-9fZMXItMXA	tr13Jb83h2llyXVwaO5eA	rbuj2XASXlc3MDul4dcxA	5.0	39	13	34	Yummy, great chew on the bagel\nfriendly staff...	2020-06-13 02:39:26
8635401	Ho57jz6U-JjiGHpGWIGLNg	HqdmRMpNvScFxjGAB40vgQ	IRzjEZ2pX4lCpnBG7oZJ7g	2.0	2	0	0	This used to be my car wash of choice. They di...	2020-06-22 21:54:10
8635402	YNyurWy1ZIYEy1vXI7azOg	HsT8bz3-SKM7YldwLLM6Q	pxwyYla1jZzHJ4R0Sp1chFw	5.0	11	4	5	This is so highly rated for a reason. If you'r...	2019-04-17 04:27:39

ภาพที่ 3.1 แสดงตัวอย่างคลังข้อมูลคำวิจารณ์ และคุณสมบัติต่างๆภายใน

### 3.2 การประมวลผลข้อมูลล่วงหน้า (Data Preprocessing)

#### 3.2.1 การเตรียมข้อมูลและทำความสะอาดข้อมูล (Data Cleansing)

ไฟล์คลังข้อมูลที่ได้จาก [www.yelp.com/dataset](http://www.yelp.com/dataset) จะเป็นไฟล์ที่อยู่ในรูปของไฟล์ JSON ผู้จัดทำได้ทำการแปลงไฟล์ดังกล่าวเป็นในรูปของ Data Frame ที่ประกอบด้วยข้อมูลในแคลและคอลัมน์ ดังตัวอย่างในภาพที่ 3.1 และทำการตัดผู้ใช้และรายการที่ไม่มีการให้คำวิจารณ์ และไม่เคยได้ได้รับคำวิจารณ์มาก่อน และทำการตัดผู้ใช้บางคนออกจากรายชื่อเพื่อน โดยที่ผู้ใช้คนนั้นปรากฏอยู่ในรายชื่อเพื่อน แต่ไม่ปรากฏอยู่ในคลังข้อมูลของผู้ใช้ รวมถึงตัดคำวิจารณ์ของผู้ใช้ที่ไม่ปรากฏในคลังข้อมูลผู้ใช้ด้วยเช่นกัน

##### 3.2.1.1 Data Frame ความสัมพันธ์ระหว่างผู้ใช้และผู้ใช้

	user_id	friend_id
0	q_QQ5kBBlCcbL1s4NVK3g	xBDpTUbai0DXrvxCe3X16Q
1	q_QQ5kBBlCcbL1s4NVK3g	7GPNBO496aecrjJfW6UWtg
2	q_QQ5kBBlCcbL1s4NVK3g	gUfhciSP7BbxZd5gj-c4xw
3	q_QQ5kBBlCcbL1s4NVK3g	NXw0bCLF5ZtFMfhcj7CFSw
4	q_QQ5kBBlCcbL1s4NVK3g	OGjmMxPuloLTJ3O-CO2A4g
...	...	...
8238162	GI_gT89dFPIJp-W6930PRA	4yVDdFFcVAVf9RvfHkje5Q
8238163	GI_gT89dFPIJp-W6930PRA	6H4Zj-c7FqM9mCsXvwaEQw
8238164	GxkabC0uq4yzb55VK2ybqw	YtR_9uhYxFzlDyomWQxvKQ
8238165	GxkabC0uq4yzb55VK2ybqw	nUYRP2Mf-vbTXhNNXd1zbA
8238166	GxkabC0uq4yzb55VK2ybqw	zqMB5fi81GNVCgItaMqgfQ

8238167 rows × 2 columns

ภาพที่ 3.2 แสดงตัวอย่างตารางความสัมพันธ์ระหว่างผู้ใช้และผู้ใช้

### 3.2.1.2 Data Frame ความสัมพันธ์ระหว่างผู้ใช้และรายการ

	user_id	business_id	stars
0	q_QQ5kBBwlCcbL1s4NVK3g	mxjV5rvPNhzYe_vt3OSQA	4.0
1	q_QQ5kBBwlCcbL1s4NVK3g	IdXHHEUH4ebcxdrxCo3JNw	4.0
2	q_QQ5kBBwlCcbL1s4NVK3g	URevDyPG55mGTJrZGd1vcg	2.0
3	q_QQ5kBBwlCcbL1s4NVK3g	AWsOwlOrVHRSpqPJy1l0eg	4.0
4	q_QQ5kBBwlCcbL1s4NVK3g	z9oCxeqOKp2QMfM24m7bUw	4.0
...	...	...	...
364748	5K0fBWj5bek3vGU3Svf61Q	VDmV3tPEQqFxzqQJRJazNw	4.0
364749	r_yqznDjBQfjPMpoOGS72w	qOEHThsLNVFPAAsle_FvzQ	5.0
364750	ytYMkiTi8ZvJGC2G8xKS1A	wrExYMc1FFDjp2IK-chZRg	1.0
364751	ytYMkiTi8ZvJGC2G8xKS1A	msBEMPAcn7eiD8GrXuHKGA	4.0
364752	Gl_gT89dFPIUp-W6930PRA	xlbM9DsOUYvUMeH5NJ7pcw	4.0

364753 rows × 3 columns

ภาพที่ 3.3 แสดงตัวอย่างตารางความสัมพันธ์ระหว่างผู้ใช้และรายการ

### 3.2.2 การสร้างเวกเตอร์คุณสมบัติของผู้ใช้และรายการ (Users and Items Feature Vector)

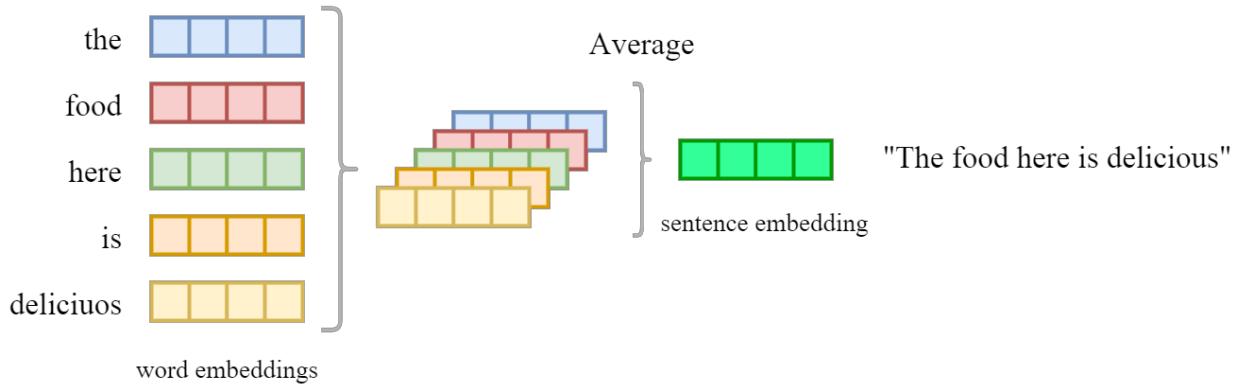
การสร้างเวกเตอร์คุณสมบัติของผู้ใช้และรายการ ผู้จัดทำได้ใช้ไลบรารี Word2Vec[2] ขนาด มิติ 150 ในการสร้างรูปแบบโดยใช้หลักการดังนี้

#### 3.2.2.1 เวกเตอร์คุณสมบัติของผู้ใช้ (User Feature Vector)

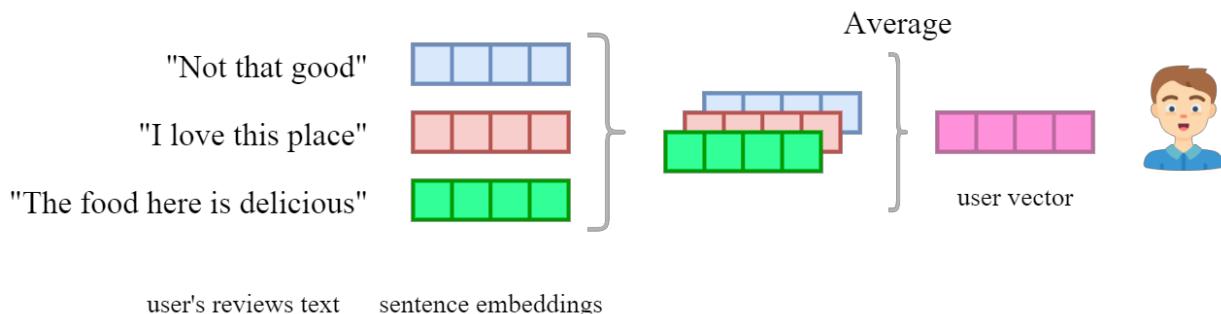
เริ่มต้นโดยการสร้างรูปแบบของแต่ละคำ (Word Embedding) ที่ปราภภูอยู่ในคำ วิจารณ์ทุกคำวิจารณ์ในคลังข้อมูลจากนั้นทำการหารูปแบบของทั้งประโยคคำวิจารณ์ (Sentence Embedding) โดยการเฉลี่ยรูปแบบของคำทุกคำที่ปราภภูอยู่ในคำวิจารณ์นั้น และสร้างเวกเตอร์ลักษณะของผู้ใช้โดยการเฉลี่ยรูปแบบของประโยคคำวิจารณ์ทุกประโยคที่ผู้ใช้คนนั้นเคยให้แก่ทุกรายการ ดังตัวอย่างในภาพที่ 3.4 และภาพที่ 3.5

#### 3.2.2.2 เวกเตอร์คุณสมบัติของรายการ (Item Feature Vector)

การสร้างเวกเตอร์คุณสมบัติของรายการจะทำคล้ายกับการสร้างเวกเตอร์คุณสมบัติของผู้ใช้ โดยการนำรูปแบบของประโยคคำวิจารณ์ทุกประโยคที่รายการนั้นได้รับมาเฉลี่ยเพื่อสร้างเป็นเวกเตอร์คุณสมบัติของรายการ รูปแบบของแต่ละประโยคจะใช้อันเดียวกับเวกเตอร์คุณสมบัติของผู้ใช้



ภาพที่ 3.4 แสดงตัวอย่างการสร้างรูปแทนของประโยคคำวิจารณ์



user's reviews text      sentence embeddings

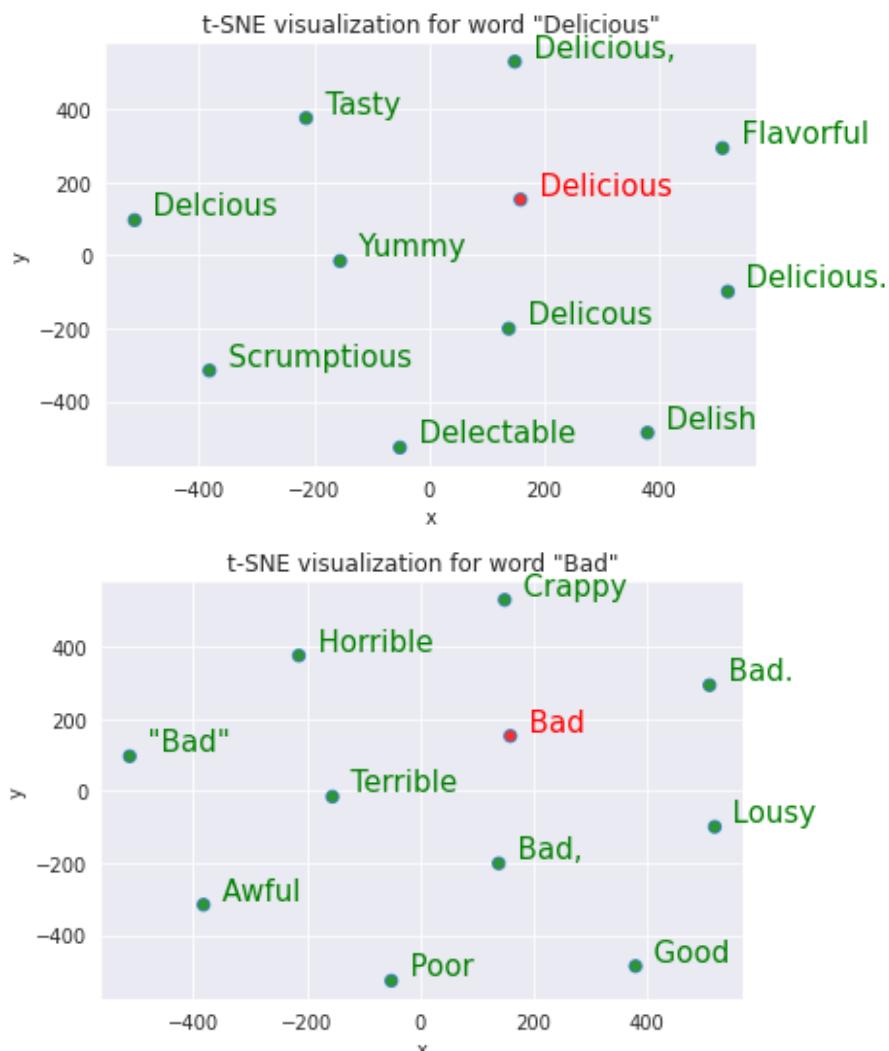
ภาพที่ 3.5 แสดงตัวอย่างการสร้างรูปแทน หรือเวกเตอร์ลักษณะของผู้ใช้

```
1 model0_1['delicious']
/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:1: Deprecation
    """Entry point for launching an IPython kernel.
array([-0.35363823, -0.14156207, -0.1899373 ,  3.399011 , -1.2607585 ,
       0.830143 , -0.81365144,  1.2284764 ,  0.0801782 ,  1.0403391 ,
      3.1580522 , -1.7711629 ,  0.758352 ,  1.494522 , -1.7540317 ,
     -0.23019277,  1.9246113 , -0.17450742,  2.7874196 , -0.6916403 ,
     -0.68475074, -0.25230482,  0.37906337,  2.040992 , -0.02518571 ,
     -0.88417764,  2.0566607 , -1.8453441 ,  0.6402995 , -0.8291323 ,
     -0.79154706,  1.4047234 ,  1.7006382 , -0.3780701 , -0.81065714 ,
     -0.1553294 ,  1.5595108 ,  2.3421423 ,  1.0945201 ,  1.9618185 ,
      2.7847338 , -2.0914223 ,  1.028796 , -0.24027403, -1.673929 ,
     -4.098271 , -0.7325293 , -0.02626123,  0.17645723,  0.3624898 ,
     -0.79006785,  0.56673205,  1.0764427 ,  0.8088951 ,  0.062780412 ,
     1.3388852 , -0.0628543 , -1.0316511 , -0.00989546, -1.9372656 ,
     -0.22357887, -1.1601394 , -0.3700114 ,  1.7975678 ,  1.0467266 ,
     3.1141431 ,  0.94300485,  1.6583519 , -1.7093989 ,  2.5429504 ,
     0.68832475,  0.34303406,  0.07682724,  0.34257945, -0.73666775 ,
     -0.36137632, -2.4643443 ,  2.1202648 , -0.9626736 ,  1.066201 ,
     0.6659465 , -2.0655558 , -0.05406984,  1.7669669 , -0.34843653 ,
     0.8847792 ,  2.154381 , -1.9905096 , -1.648856 , -0.5673742 ,
     -0.2114545 ,  1.0916826 , -2.1258242 ,  1.0461931 , -1.189297 ,
     -1.0961453 , -0.87368864,  1.6943939 ,  2.239041 ,  0.6866053 ,
     1.6443893 ,  1.3791453 , -1.3699174 , -1.7966541 , -0.7384355 ,
     -1.1144236 ,  0.7026626 , -3.880403 ,  0.81487304,  0.49978444 ,
     0.45124447 ,  0.28167865,  0.08474775, -0.07184572, -0.44808546 ,
     0.52201184,  2.5430276 , -0.07826829, -2.7484558 ,  0.3040814 ,
     0.10002457,  0.5922253 ,  1.0136826 ,  1.3562294 , -0.26077184 ,
     -0.56841224, -0.27578914, -0.4959528 , -0.41568708, -2.5684752 ,
     1.1513442 ,  1.2786115 ,  0.18304639, -4.4784603 , -1.5487349 ,
     -0.05792134,  0.6525454 ,  2.38443804 ,  0.61762947,  0.78218585 ,
     -2.838892 , -2.4222577 ,  1.4580363 ,  3.1454701 ,  0.01067893 ,
     1.9920954 , -2.0623145 ,  2.3488998 ,  0.5489348 ,  0.4529288 ],
dtype=float32)
```

ภาพที่ 3.6 แสดงตัวอย่างรูปแทนของคำว่า 'delicious'

text	embedding
Since I'm only in Boston for 24 hours I had to...	[-0.00030611979437398384, 0.001118476656112042...]
A brutal awakening on Sunday morning after an ...	[-0.0007256143491902797, -0.000244333536076031...]
Not knowing my way around Boulder has led to m...	[0.0007086075660659045, 4.818868346330596e-05,...]
Sandwiches, soups and salads, oh my!\n\nThis i...	[0.0017141876525657122, 0.005115869086842204, ...]
For the record, I received no shoulder massage...	[-0.001672707469744374, 0.0005975159402129315,...]
...	...
This is a great place if you enjoy great seafo...	[5.430162210411173e-05, 0.0001412814528476901,...]
When I heard about this new technology i was s...	[-0.0005647290301950354, 0.0009961808198376706...]
I'm giving the celebrity owned "Cuban" restaur...	[-1.0756172474708643e-05, 6.660160583418769e-05...]
Great breakfast option if you're in O-Town! \n...	[-0.0003727840004439952, 6.683559615827511e-05...]
This is your typical airport bar and grill, ex...	[-0.0006272488641082694, 0.0008389429625021208...]

ภาพที่ 3.7 แสดงตัวอย่างของรูปแทนของแต่ละประโยค



ภาพที่ 3.8 แสดงการทำ t-SNE Visualization ของคำว่า 'Delicious'(บน) และคำว่า 'Bad' (ล่าง)

จากรูปภาพที่ 3.8 แสดงให้เห็นถึงการ visualization โดยใช้ t-SNE ของคำว่า ‘Delicious’ และ ‘Bad’ โดยการสร้างรูปแทนด้วยวิธีที่ได้กล่าวไปข้างต้น แสดงให้เห็นว่า Word2Vec สามารถที่จะสร้างรูปแทนที่จับความหมายของคำได้ ซึ่งจะเห็นได้จากตัวอย่างในภาพที่คำที่มีความหมายใกล้เคียงกันจะยังอยู่ใกล้ๆ กัน

### 3.3 วิธีการที่นำเสนอ

จากขั้นตอนการประมวลผลล่วงหน้า ผู้จัดทำได้ทำการนำเวกเตอร์คุณลักษณะของผู้ใช้และรายการมาใช้ในการเป็นข้อมูลนำเข้าในวิธีการที่นำเสนอของผู้จัดทำ และจะทำการคำนวณค่าน้ำหนักใหม่สำหรับแต่ละเส้นเชื่อมความสัมพันธ์ และนำไปแทนค่าน้ำหนักเดิมของ GCN ซึ่งจากเดิมนั้นผู้ใช้แต่ละคนจะมีค่าน้ำหนักของเส้นเชื่อมความสัมพันธ์ระหว่างผู้ใช้ และความสัมพันธ์ระหว่างรายการที่เท่ากันทุกเส้นเชื่อมที่ห้าจำกัดการ  $1/\#neighbors$  โดยที่  $\#neighbors$  คือจำนวนเพื่อนบ้านที่มีเส้นเชื่อมต่อกับผู้ใช้ โดยหลักการทำงานมีทั้งหมด 4 เลเยอร์ แต่ละเลเยอร์มีการทำงานดังนี้

#### 3.3.1 Embedding Layer

Embedding layer เป็นเลเยอร์ที่รับข้อมูลรายละเอียดของคลังข้อมูล (Dataset) ของผู้ใช้ (User) และรายการ (Item) โดยในเลเยอร์นี้จะทำการสร้างรูปแทนของผู้ใช้ ( $p_a$ ) และของรายการ ( $q_i$ ) แบบตั้งต้น โดยจะทำการสุ่มค่าของรูปแทนของผู้ใช้และของรายการขึ้นมาจากการแจกแจงแบบปกติ (Normal Distribution) ใช้โดยมีขนาดของรูปแทนดังนี้

รูปแทนตั้งต้นของผู้ใช้ $p_a$	[จำนวนของผู้ใช้, ขนาดของมิติ]
รูปแทนตั้งต้นของรายการ $q_i$	[จำนวนของรายการ, ขนาดของมิติ]

#### 3.3.2 Fusion Layer

Fusion layer จะรับข้อมูลเข้ามาเป็นรูปแทนของผู้ใช้  $p_a$  และเวกเตอร์คุณสมบัติ (Feature Vector)  $x_a$  โดย เวกเตอร์คุณสมบัติของผู้ใช้แต่ละคนจากการเฉลี่ยรูปแทนของคำทุกคำที่ปรากฏในคำวิจารณ์ของผู้ใช้คนนั้นๆ และเวกเตอร์คุณสมบัติของรายการแต่ละรายการจากการเฉลี่ยรูปแทนของคำทุกคำที่ปรากฏในคำวิจารณ์ที่รายการนั้นๆ ได้รับ โดยในเลเยอร์นี้จะทำการรวมรูปแทนของผู้ใช้ที่ได้จากเลเยอร์ Embedding และเวกเตอร์คุณสมบัติ ซึ่งจะได้เป็นรูปแทนผสม (Fusion Embedding) ของผู้ใช้  $u_a^0$  โดยใช้สมการดังนี้

$$u_a^0 = g(W_1 \times [p_a, x_a]) \quad \text{สมการที่ 15}$$

จากสมการประกอบด้วย

$W_1$  เมทริกซ์การแปลง (Transformation Matrix)

$g(x)$  พิ่งก์ชันการแปลง ในที่นี่จะใช้เป็นพิ่งก์ชันแบบไม่เชิงเส้นตรง (non-linear function)

$p_a$  รูปแทนของผู้ใช้ a ที่ได้จากการ Embedding

$x_a$  เวกเตอร์คุณสมบัติของผู้ใช้ a

$u_a^0$  รูปแทนผู้ใช้ a ที่ระดับชั้นที่ 0 (Initialize State)

และการสร้างรูปแทนผู้ใช้ ที่มีรูปแบบ  $v_i^0$  ที่ทำเช่นเดียวกันดังนี้

$$v_i^0 = g(W_2 \times [q_i, y_i])$$

สมการที่ 16

จากสมการประกอบด้วย

$W_2$  เมทริกซ์การแปลง (Transformation Matrix)

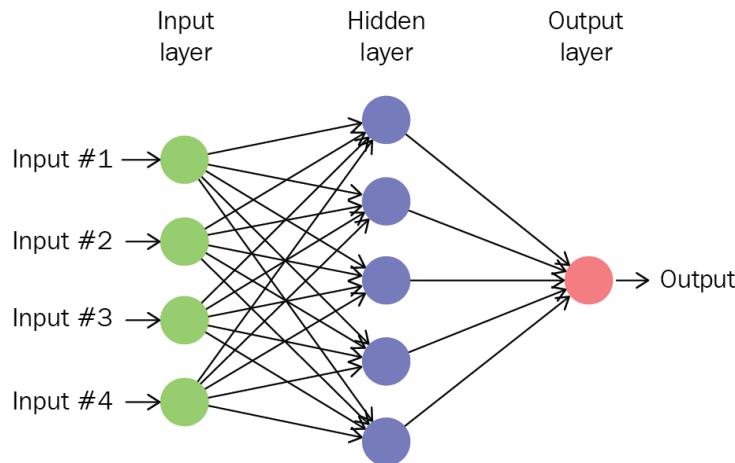
$g(x)$  พิ่งก์ชันการแปลง ในที่นี่จะใช้เป็นพิ่งก์ชันแบบไม่เชิงเส้นตรง (non-linear function)

$q_i$  รูปแทนของรายการ i ที่ได้จากการ Embedding

$y_i$  เวกเตอร์คุณสมบัติของรายการ i

$v_i^0$  รูปแทนผู้ใช้ a ที่ระดับชั้นที่ 0 (Initialize State)

จากสมการจะได้ว่ารูปแทนผู้ใช้  $p_a$  และเวกเตอร์คุณสมบัติ  $x_a$  ของผู้ใช้แต่ละคนเข้าโครงข่ายประสาทเทียม เชื่อมโยงสมบูรณ์แบบ 1 ชั้น (one-layer fully connected neural network) ซึ่งจะได้ออกมาเป็น เวกเตอร์รูปแทนผู้ใช้  $u_a^0$  และทำเช่นเดียวกันกับรูปแทนผู้ใช้  $v_i^0$  โดยนำเข้ารูปแทนของรายการ  $q_i$  และเวกเตอร์คุณสมบัติของรายการ  $y_i$  เข้าโครงข่ายประสาทเทียมเชื่อมโยง สมบูรณ์แบบ 1 ชั้น



อ้างอิง: *Machine Learning Projects for Mobile Applications*. (2022). Retrieved 25 April 2022, from <https://www.oreilly.com/library/view/machine-learning-projects/9781788994590/5961f28e-eb19-42c9-bd69-8bf23d00fa78.xhtml>

ภาพที่ 3.9 แสดงตัวอย่างลักษณะของโครงข่ายประสาทเทียมเชื่อมโยงสมบูรณ์

### 3.3.3 Influence and Interest Diffusion Layers

ในเลเยอร์ Influence and Interest Diffusion จะมีการทำงานแบบเรียกซ้ำเพื่อหารูปแทนของผู้ใช้และการในแต่ละระดับของกราฟ โดยจะทำการรับข้อมูลรูปแทนของผู้ใช้แต่ละคน และรูปแทนของรายการแต่ละรายการเข้าสู่ในเลเยอร์นี้ โดยในแต่ละระดับชั้น  $k+1$  จะทำการรับข้อมูลของรูปแทนผู้ใช้ และรูปแทนของรายการจากระดับชั้น  $k$  ก่อนหน้า และทำการปรับค่ารูปแทนของทั้งผู้ใช้ และรายการในแต่ละเลเยอร์โดยการใช้การดำเนินการของการแพร่กระจาย โดยจะแบ่งออกเป็นสองส่วน ได้แก่ ส่วนของกราฟสนับสนุนระหว่างผู้ใช้และการ และส่วนของกราฟอิทธิพลระหว่างผู้ใช้และผู้ใช้ และทางผู้จัดทำได้ทำการเพิ่มค่าน้ำหนักในส่วนของการทำงานของการวนซ้ำในกราฟ โดยมีรายละเอียดการทำงานในแต่ละส่วนดังนี้

#### 3.3.3.1 ส่วนของกราฟสนับสนุนระหว่างผู้ใช้และการ (Interest Diffusion)

มีสมการการดำเนินการของการแพร่กระจายดังนี้

$$\tilde{v}_i^{k+1} = AGG_u(u_a^k, \forall a \in R_i) = \sum_{a \in R_i} \eta_{ia}^{k+1} u_a^k \quad \text{สมการที่ 17}$$

$$v_i^{k+1} = \tilde{v}_i^{k+1} + v_i^k \quad \text{สมการที่ 18}$$

กำหนดให้

- $G_S$  กราฟอิทธิพลระหว่างผู้ใช้และผู้ใช้ (Influence Social Network Graph)  
 $G_I$  กราฟรสนิยมระหว่างผู้ใช้และรายการ (Interest Network Graph)

จากสมการประกอบด้วย

- $\tilde{v}_i^{k+1}$  รูปแทนของรายการ  $i$  ที่ระดับชั้น  $k+1$  ซึ่งคำนวณมาจากรูปแทนของผู้ใช้ที่มีปฏิสัมพันธ์กับรายการนั้นจากการรสนิยมระหว่างผู้ใช้และรายการ  $G_I$
- $u_a^k$  รูปแทนของผู้ใช้  $a$  ที่ระดับชั้น  $k$  (ชั้นก่อนหน้า  $k+1$ ) โดยผู้ใช้  $a$  ทุกคนคือผู้ใช้ที่มีปฏิสัมพันธ์กับรายการ  $i$  (เช่น ผู้ใช้ทุกคนที่ให้คะแนนรีวิวแก่รายการ  $i$ )
- $\eta_{ia}^{k+1}$  ค่าน้ำหนักรวม (Aggregation Weight) ในการสร้างรูปแทนของรายการ  $i$  ที่มีเส้นเชื่อมกับผู้ใช้  $a$  ที่ระดับชั้น  $k+1$
- $v_i^{k+1}$  รูปแทนของรายการ  $i$  ที่ระดับชั้น  $k+1$  ที่ผ่านกับปรับปรุงค่าแล้ว

จากสมการจะได้ว่าในการปรับค่ารูปแทนของรายการ  $i$  ที่ระดับ  $k+1$  ( $v_i^{k+1}$ ) จะต้องสร้างรูปแทนของรายการ  $i$  ที่ระดับชั้น  $k+1$  ( $\tilde{v}_i^{k+1}$ ) โดยการหาผลรวมของผลคูณระหว่างรูปแทนของผู้ใช้ทุกคนที่มีปฏิสัมพันธ์กับรายการ  $i$  ที่ระดับชั้น  $k$  ( $u_a^k$ ) กับค่าน้ำหนักรวมของความสัมพันธ์แต่ละความสัมพันธ์ ( $\eta_{ia}^{k+1}$ ) จากนั้นทำการปรับค่ารูปแทนของรายการ  $i$  ที่ระดับชั้น  $k+1$  ( $v_i^{k+1}$ ) โดยการนำรูปแทนที่ได้จากระดับชั้น  $k$  ( $v_i^k$ ) บวกกับรูปแทนที่ได้จากระดับชั้น  $k+1$  ( $\tilde{v}_i^{k+1}$ ) ซึ่งจะได้เป็นค่าของรูปแทนรายการ  $i$  ที่ระดับชั้น  $k+1$  ( $v_i^{k+1}$ )

สมการในการหาค่าน้ำหนักรวม เป็นดังนี้

$$\eta_{ia}^{k+1} = MPL_1([v_i^k, u_a^k]) \quad \text{สมการที่ 19}$$

ค่าน้ำหนักรวม หรือเรียกว่าค่าน้ำหนักความสนใจ (Attention Weight) ของรายการที่มีต่อแต่ละความสัมพันธ์ระหว่างผู้ใช้ ซึ่งหาได้จากการใช้โครงข่ายประสาทเทียม (Multilayer Perceptron, MLP) ในการเรียนรู้ค่าน้ำหนักตรงนี้ออกมานำค่าน้ำหนักที่ได้มาทำการปรับให้มีค่าอยู่ในช่วงที่เหมาะสม (Normalization) โดยใช้สมการดังนี้

$$\eta_{ia}^{k+1} = \frac{\exp(\eta_{ia}^{k+1})}{\sum_{b \in R_i} \exp(\eta_{ib}^{k+1})} \quad \text{สมการที่ 20}$$

### 3.3.3.2 ส่วนของกราฟอิทธิพลระหว่างผู้ใช้และผู้ใช้ (Influence Diffusion)

โดยในส่วนของกราฟอิทธิพลระหว่างผู้ใช้และผู้ใช้นั้นจะมีหลักการทำงานที่คล้ายกับ ผังของกราฟสนิยมระหว่างผู้ใช้และรายการ ในการสร้างรูปแทนเพื่อแสดงถึงผู้ใช้แต่ละคน หรืออาจจะแสดงถึงพฤติกรรมของผู้ใช้แต่ละคนนั้นจะเกิดจากปัจจัยที่มาจากการส่องเหล่ ได้แก่ พฤติกรรมของผู้ใช้ที่เกิดจากการได้รับอิทธิพลมาจากผู้ใช้คนอื่นบนกราฟอิทธิพล  $G_S$  และ พฤติกรรมของผู้ใช้ที่เกิดจากการสนิยมของตัวผู้ใช้เองบนกราฟสนิยม  $G_I$  โดยจะทำการรวมรูป แทนของผู้ใช้ที่เกิดจากทั้งสองเหล่เข้าด้วยกัน และเนื่องจากผู้ใช้แต่ละคน อาจจะได้มี พฤติกรรมที่มาจากการส่องเหล่ที่ไม่เท่ากัน จึงได้มีการให้ค่าน้ำหนักที่มาจากการส่องเหล่ที่ แตกต่างกัน หลังจากนั้นจึงนำไปบวกกับรูปแทนของผู้ใช้ที่ได้จากการดับชั้นก่อนหน้า เพื่อให้ได้ ค่าของรูปแทนของผู้ใช้ในระดับชั้นปัจจุบัน

ส่วนของกราฟอิทธิพลระหว่างผู้ใช้และผู้ใช้มีสมการการคำนวณการเผยแพร่องรำจายดังนี้

$$u_a^{k+1} = u_a^k + (\gamma_{a1}^{k+1} \tilde{p}_a^{k+1} + \gamma_{a2}^{k+1} \tilde{q}_a^{k+1}) \quad \text{สมการที่ 21}$$

$$\tilde{p}_a^{k+1} = \sum_{b \in S_a} \alpha_{ab}^{k+1} u_b^k \quad \text{สมการที่ 22}$$

$$\tilde{q}_a^{k+1} = \sum_{i \in R_a} \beta_{ai}^{k+1} v_i^k \quad \text{สมการที่ 23}$$

จากสมการประกอบด้วย

- $u_a^{k+1}$  รูปแทนของผู้ใช้  $a$  ที่ระดับชั้น  $k+1$
- $\tilde{p}_a^{k+1}$  รูปแทนของผู้ใช้  $a$  ที่ระดับชั้น  $k+1$  ที่คำนวณมาจากรูปแทนของผู้ใช้ที่มี ปฏิสัมพันธ์ด้วยทุกคนของผู้ใช้  $a$  ในกราฟอิทธิพลระหว่างผู้ใช้และผู้ใช้  $G_S$
- $\tilde{q}_a^{k+1}$  รูปแทนของผู้ใช้  $a$  ที่ระดับชั้น  $k+1$  ที่คำนวณมาจากรูปแทนของการที่ ผู้ใช้  $a$  มีปฏิสัมพันธ์ด้วยทุกรายการในกราฟสนิยมระหว่างผู้ใช้และการ

$G_I$

- $\alpha_{ab}^{k+1}$  ค่าน้ำหนักที่แสดงถึงระดับอิทธิพลของผู้ใช้ b ที่ส่งผลต่อผู้ใช้ a ที่ระดับชั้น k+1 ในกราฟอิทธิพล  $G_S$
- $\beta_{ai}^{k+1}$  ค่าน้ำหนักที่แสดงถึงระดับความติงดูดของรายการ i ที่มีต่อผู้ใช้ a ที่ระดับชั้น k+1 ในกราฟรสนิยม  $G_I$
- $\gamma_{a1}^{k+1}, \gamma_{a2}^{k+1}$  ค่าน้ำหนักระดับกราฟที่แสดงถึงระดับความสำคัญที่แต่ละผู้ใช้ให้ระหว่างกราฟอิทธิพลกับกราฟรสนิยมตามลำดับ

จากสมการ การหารูปแทนของผู้ใช้ a ที่เกิดจากการได้รับปัจจัยพุทธิกรรมมาจากอิทธิพลของผู้ใช้คนอื่นที่ระดับชั้น k+1 ( $\tilde{p}_a^{k+1}$ ) ได้จากการหาผลรวมของผลคูณระหว่างค่า  
น้ำหนัก  $\alpha_{ab}^{k+1}$  และรูปแทนผู้ใช้  $u_b^k$  โดยที่ b แทนผู้ใช้แต่ละคนที่มีปฏิสัมพันธ์กับผู้ใช้ a ที่ระดับ k และการหารูปแทนของผู้ใช้ a ที่เกิดจากการได้รับปัจจัยพุทธิกรรมมาจากการรสนิยมต่อรายการที่ระดับชั้น k+1 ( $\tilde{q}_a^{k+1}$ ) ได้จากการหาผลรวมของผลคูณระหว่างค่าน้ำหนัก  $\beta_{ai}^{k+1}$  และรูปแทนรายการ  $v_i^k$  โดยที่ i แทนรายการแต่ละรายการที่ผู้ใช้ a มีปฏิสัมพันธ์ด้วยที่ระดับชั้น k หลังจากนั้นจะทำการปรับค่าของรูปแทนผู้ใช้ a ที่ระดับชั้น k+1 ( $u_a^{k+1}$ ) โดยการนำรูปแทนผู้ใช้จากระดับชั้น k และรูปแทนที่มาจากการหั้งสองแหล่ง มาบวกรวมกัน โดยจะมีการกำหนดค่าน้ำหนัก ( $\gamma_{al}^{k+1}$ ) ให้แกerrูปแทนที่มาจากการหั้งสองแหล่งที่ต่างกัน  
สมการที่ใช้ในการคำนวณค่าน้ำหนักระดับกราฟ ( $\gamma_{al}^{k+1}$ ) เป็นดังนี้

$$\gamma_{a1}^{k+1} = MLP_4([u_a^k, \tilde{p}_a^k]) \quad \text{สมการที่ 24}$$

$$\gamma_{a2}^{k+1} = MLP_4([u_a^k, \tilde{q}_a^k]) \quad \text{สมการที่ 25}$$

ค่าน้ำหนักระดับกราฟจะแสดงถึงค่าน้ำหนักที่ผู้ใช้แต่ละคนให้ความสำคัญ หรือได้รับปัจจัยทางพุทธิกรรมมาจากหั้งสองแหล่งที่แตกต่างกัน หากผู้ใช้มีค่าน้ำหนักของรูปแทนผู้ใช้ที่มาจากการฝั่งอิทธิพล ( $\gamma_{a1}^{k+1}$ ) สูง หมายถึงพุทธิกรรมหรือรูปแทนของผู้ใช้คนนั้นค่อนข้างที่จะได้รับอิทธิพลมากจากอิทธิพลระหว่างผู้ใช้มาก ในทางกลับกันหากค่าน้ำหนักของรูปแทนผู้ใช้ที่มาจากการฝั่งรสนิยม ( $\gamma_{a2}^{k+1}$ ) มีค่ามาก จะหมายถึงพุทธิกรรมหรือรูปแทนของผู้ใช้คนนั้นค่อนข้างที่จะได้รับอิทธิพลมาจากอิทธิพลของผู้ใช้ที่มีต่อรายการที่ผู้ใช้ให้ความสนใจมากกว่ามาจากผู้ใช้คนอื่น

จากสมการในการหาค่าน้ำหนักของปัจจัยแต่ละฝั่ง จะหาได้จากการใช้โครงข่ายประสาทเทียม (MLP) และรับข้อมูลเข้าเป็นรูปแทนของผู้ใช้จากระดับชั้นก่อนหน้าที่เชื่อม (concatenate) กับรูปแทนของผู้ใช้ที่ได้รับปัจจัยมาจากการแต่ละฝั่ง

เนื่องจากใน GCN จะทำการปรับปรุงค่าของรูปแทนโดยการนำเข้ารูปแทนที่ได้จากการคำนวณก่อนหน้า และนำมาทำการคุณด้วยเมตริกซ์กระจัดกระจายของความสัมพันธ์ระหว่างผู้ใช้ และผู้ใช้ (user-user sparse matrix) เพื่อปรับค่ารูปแทนของผู้ใช้ที่เกิดจากการอิทธิพลระหว่างผู้ใช้และผู้ใช้ หรือทำการคุณด้วยเมตริกซ์กระจัดกระจายของความสัมพันธ์ระหว่างผู้ใช้และรายการ (user-item sparse matrix) เพื่อปรับค่ารูปแทนของผู้ใช้ที่เกิดจากการรสนิยมระหว่างผู้ใช้และรายการ โดยในการหาค่าน้ำหนัก และปรับค่าน้ำหนักเพื่อให้เกิดค่าน้ำหนักที่แตกต่างกันในแต่ละความสัมพันธ์สามารถทำได้ดังนี้

### 3.3.3.2.1 รูปแทนของผู้ใช้ที่เกิดจากการอิทธิพลระหว่างผู้ใช้และผู้ใช้ $\tilde{p}_a^{k+1}$

เราสามารถแทนค่าน้ำหนักระหว่างความสัมพันธ์ของผู้ใช้และผู้ใช้ที่คำนวณได้โดยการสร้างเมตริกซ์กระจัดกระจายที่มีขนาด  $n \times n$  โดยที่  $n$  คือจำนวนผู้ใช้ทั้งหมด และภายในมีค่าศูนย์ที่หมายถึงไม่มีเส้นเชื่อม และค่าน้ำหนักระหว่างความสัมพันธ์ในตำแหน่งที่ผู้ใช้สองคนมีเส้นเชื่อมถึงกัน การคำนวณค่าน้ำหนักทำได้ดังนี้

ค่าน้ำหนักของผู้ใช้แต่ละคน

$$w_a = \frac{E_a}{\sum_{b \in a's neighbors} E_b} \quad \text{สมการที่ 26}$$

จากสมการประกอบด้วย

$w_a$  ค่าน้ำหนักของผู้ใช้  $a$

$E_a$  จำนวนเส้นเชื่อม (Edge) ของผู้ใช้  $a$

$E_b$  จำนวนเส้นเชื่อมของผู้ใช้  $b$  โดยที่  $b$  เป็นสมาชิกของผู้ใช้ทุกคนที่มีปฏิสัมพันธ์กับ  $a$

จากสมการการคำนวณค่าน้ำหนักของผู้ใช้จะได้ว่า ค่าน้ำหนักของผู้ใช้แต่ละคนจะมาจากการคำนวณเส้นเชื่อมของผู้ใช้คนนั้น หารด้วยผลรวมของจำนวนเส้นเชื่อมของผู้ใช้ที่เป็นเพื่อนบ้านทุกคน โดยการใช้ค่าน้ำหนักเช่นนี้จะสามารถแสดงถึงความสำคัญ หรือระดับของอิทธิพลของผู้ใช้ที่มีต่อผู้ใช้คนอื่น เช่น หากมีผลรวมของจำนวนเส้นเชื่อมของเพื่อนบ้านน้อย จะแสดงถึงความสำคัญที่เพื่อนบ้านมีอิทธิพลต่ำ

เราที่สูง ในทางกลับกันหากผลรวมของจำนวนเส้นเชื่อมของเพื่อนบ้านมีจำนวนมาก จะแสดงถึงระดับความสำคัญที่เพื่อนบ้านมีอิทธิพลต่อตัวเราที่ต่ำ

การคำนวณค่าน้ำหนักของความสัมพันธ์ระหว่างผู้ใช้และผู้ใช้มีสมการดังนี้

ค่าน้ำหนักของความสัมพันธ์ระหว่างผู้ใช้และผู้ใช้

$$w_{ab} = \frac{\frac{E_b}{\sum_{c \in b' \text{ neighbors}} E_c}}{\frac{E_a}{\sum_{b \in a' \text{ neighbors}} E_b}} = \frac{w_b}{w_a} \quad \text{สมการที่ 27}$$

จากสมการประกอบด้วย

$w_{ab}$  ค่าน้ำหนักของความสัมพันธ์ระหว่างผู้ใช้ a และผู้ใช้ b

$w_a, w_b$  ค่าน้ำหนักของผู้ใช้ a และผู้ใช้ b ตามลำดับ

$E_a$  จำนวนเส้นเชื่อมของผู้ใช้ a

จากสมการ ค่าน้ำหนักของแต่ละคนจะมาจากการอิทธิพลของเพื่อนบ้านทุกคน ในการหาค่าน้ำหนักของความสัมพันธ์ระหว่างผู้ใช้และผู้ใช้ เช่น  $w_{ab}$  สามารถทำได้โดยการนำค่าน้ำหนักของผู้ใช้ b ( $w_b$ ) หารด้วยค่าน้ำหนักของผู้ใช้ a ( $w_a$ ) จึงทำให้ได้ค่าน้ำหนักที่ผู้ใช้ b มีอิทธิพลต่อผู้ใช้ a ( $w_{ab}$ )

**3.3.3.2.2 รูปแทนของผู้ใช้ที่เกิดจากการสร้างรากฐานของผู้ใช้และรายการที่คำนวณได้โดยการสร้างเมทริกซ์ประจำตัวที่มีขนาด  $n*m$  โดยที่ n คือจำนวนผู้ใช้ทั้งหมด m คือจำนวนรายการทั้งหมด และภายในมีค่าศูนย์ที่หมายถึงไม่มีเส้นเชื่อมระหว่างผู้ใช้และรายการ และค่าน้ำหนักระหว่างความสัมพันธ์ในตำแหน่งที่ผู้ใช้และการมีเส้นเชื่อมถึงกัน การคำนวณค่าน้ำหนักทำได้ดังนี้**

### ค่า俈หนักของความสัมพันธ์ระหว่างผู้ใช้และรายการ

$$w_{ai} = \frac{r_{ai}}{\sum_{k \in R_a} r_{ak}} \quad \text{สมการที่ 28}$$

จากสมการประกอบด้วย

$w_{ai}$  ค่า俈หนักของความสัมพันธ์ระหว่างผู้ใช้ a และรายการ i

$r_{ai}$  คะแนนวิจารณ์ (Rating) ที่ผู้ใช้ a ให้แก่รายการ i

$r_{ak}$  คะแนนวิจารณ์ที่ผู้ใช้ a ให้แก่รายการ k โดยที่ k เป็นสมาชิกของรายการที่ผู้ใช้ a ได้ให้คะแนนทั้งหมด

#### 3.3.4 Prediction Layer

Prediction layer เป็นเลเยอร์สุดท้าย โดยจะรับข้อมูลต่อมาจากการเลเยอร์ Influence and Interest Diffusion ซึ่งจะอุปกรณ์ในรูปของรูปแทนของผู้ใช้ และรูปแทนของรายการที่ผ่านกระบวนการวนซ้ำมาแล้วเป็นจำนวน K ระดับชั้น โดยจะทำการนำรูปแทนของผู้ใช้แต่ละคนที่หาได้จาก GCN ในแต่ละรอบ หรือในแต่ละระดับ นำรูปแทนที่ได้จากทุกระดับชั้นมาเชื่อมต่อเข้าด้วยกัน ด้วยการ Concatenation เช่นเดียวกันกับรูปแทนของราย โดยการนำรูปแทนของแต่ละรายการที่ได้จาก GCN ในแต่ละระดับชั้นมาทำการเชื่อมต่อเข้าด้วยกันทั้งหมดโดยการ Concatenation หลังจากนั้นจะทำการคำนวณคะแนนที่คาดว่าผู้ใช้จะให้แก่รายการหนึ่งๆโดยการทำผลคูณภายใน (inner product) ระหว่างเวกเตอร์รูปแทนของผู้ใช้ และเวกเตอร์รูปแทนของรายการ และคำนวณค่าคะแนนที่คาดว่าผู้ใช้จะให้แก่รายการ  $\hat{r}_{ai}$  ตามสมการดังนี้

$$\hat{r}_{ai} = [u_a^0 || u_a^1 || \dots || u_a^K]^T [v_i^0 || v_i^1 || \dots || v_i^K] \quad \text{สมการที่ 29}$$

จากสมการประกอบด้วย

$\hat{r}_{ai}$  คะแนนที่ผู้ใช้ a น่าจะให้แก่รายการ i ที่ซึ่งเป็นรายการที่ผู้ใช้ยังไม่เคยให้คะแนนมาก่อน

$u_a^K$  รูปแทนของผู้ใช้ a ที่ระดับชั้น K

$v_i^K$  รูปแทนของรายการ i ที่ระดับชั้น K

## บทที่ 4

### การประเมินการผลทดสอบ

ในบทนี้จะกล่าวถึงผลของการดำเนินการพัฒนาวิธีแนะนำทางสังคมบนพื้นฐานของกราฟแบบกล่าว น้ำหนัก โดยทางผู้จัดทำได้ทำการทดลองบนคลังข้อมูลจริง (real-world dataset) ของ Yelp

#### 4.1 คลังข้อมูลที่ใช้

Yelp คือแพลตฟอร์มออนไลน์ที่ผู้ใช้สามารถทำการค้นหาร้านค้า และร้านอาหารต่างๆตามตำแหน่งที่อยู่ปัจจุบันได้ รวมถึงผู้ใช้ยังสามารถเพิ่มเพื่อนกับผู้ใช้คนอื่นๆได้ และยังสามารถให้คะแนน และคำวิจารณ์แก่ร้านค้าและร้านได้ ทางผู้จัดทำได้ทำการใช้คลังข้อมูลของ Yelp ที่ได้มีการเผยแพร่ในที่สาธารณะ<sup>1</sup> โดยคลังข้อมูลของ Yelp จะประกอบไปด้วยคุณสมบัติต่างๆ เช่น ผู้ใช้ และรายการ โดยนำมาทำการประมวลผล ล่วงหน้าตามที่กล่าวข้างต้น (ในส่วนของ 3.2 การประมวลผลข้อมูลล่วงหน้า) และทำการแปลงค่าคะแนนที่ผู้ใช้ได้ให้แก่รายการเป็นค่าใบหน้าดังนี้ ผู้ใช้ที่ให้คะแนนมากกว่า 3 จะทำการแปลงเป็น 1 นอกเหนือจากนั้นจะถูกแปลงเป็น 0 โดยในคลังข้อมูลจะทำการคัดกรองผู้ใช้ที่ไม่มีจำนวนการให้คะแนน และให้คำวิจารณ์แก่รายการน้อยกว่า 50 ครั้งออก คัดกรองผู้ใช้ที่มีเส้นเชื่อมความสัมพันธ์ระหว่างผู้ใช้น้อยกว่า 50 ความสัมพันธ์ออก และคัดกรองรายการที่มีจำนวนครั้งการถูกให้คะแนนน้อยกว่า 50 ครั้งออก จากนั้นทำการแปลงรหัสของผู้ใช้ (user ID) และรหัสของรายการ (item ID) จากเดิมที่อยู่ในประเภทของข้อความ (String) เป็นรหัสชนิดจำนวนเต็ม (Integer) และเรียงลำดับรหัสของผู้ใช้และรายการตั้งแต่ 1 ถึงจำนวนของผู้ใช้ หรือรายการ ดังที่แสดงในภาพที่ 4.1 โดยจะทำการสุ่มเลือกจากคลังข้อมูลที่ผ่านการประมวลผลล่วงหน้าแล้ว 10% สำหรับทดสอบ (test data) และ 90% สำหรับการเรียนรู้และปรับพารามิเตอร์ (train data) และเลือก 10% จากข้อมูลที่ใช้เรียนรู้สำหรับการตรวจสอบ (validation data) รายละเอียดคลังข้อมูลที่ผ่านการประมวลผล ล่วงหน้าแล้วดังที่แสดงในตารางที่ 4.1 และตารางที่ 4.2

---

<sup>1</sup> <https://www.yelp.com/dataset>

ตารางที่ 4.1 แสดงจำนวนของข้อมูลที่ผ่านการประมวลผลล่วงหน้าแล้ว

คลังข้อมูล	จำนวน
ข้อมูลธุรกิจ(รายการ)	60,881 รายการ
ข้อมูลผู้ใช้	7,268 ผู้ใช้
ข้อมูลคำวิจารณ์	364,753 คำวิจารณ์

ตารางที่ 4.2 แสดงจำนวนของความสัมพันธ์ในคลังข้อมูลที่ผ่านการประมวลผลล่วงหน้าแล้ว

คลังข้อมูล	จำนวน
ความสัมพันธ์ระหว่างผู้ใช้และผู้ใช้	1,445,868 ความสัมพันธ์
ความสัมพันธ์ระหว่างผู้ใช้และรายการ	196,341 ความสัมพันธ์

user_id	friend_id	links		user_id	business_id	stars	
0	1	89	1	0	1	1	1.0
1	1	6756	1	1	1	2	1.0
2	1	460	1	3	1	3	1.0
3	1	1004	1	4	1	4	1.0
4	1	31	1	5	1	5	1.0
...	...	...	...	...	...	...	...
1496355	7267	2380	1	364745	7264	13051	1.0
1496356	7267	6053	1	364746	7264	40411	1.0
1496357	7267	2305	1	364747	7265	4598	1.0
1496358	7267	5297	1	364748	7265	3735	1.0
1496359	7267	3681	1	364751	7267	21314	1.0

1445868 rows × 3 columns                            252114 rows × 3 columns

ภาพที่ 4.1 แสดงตารางความสัมพันธ์ระหว่างผู้ใช้และผู้ใช้ (ซ้าย) และตารางความสัมพันธ์ระหว่างผู้ใช้และการ (ขวา) ที่มีการแปลงรหัสของผู้ใช้และการแล้ว

## 4.2 วิธีการพื้นฐาน และวิธีการประเมินผล

ผู้จัดทำได้ทำการทดสอบประสิทธิภาพของวิธีการที่ได้ทำการปรับปรุงขึ้นโดยทำการเปรียบเทียบกับวิธีการของ DiffNet++ เป็นวิธีพื้นฐาน โดยได้ใช้คลังข้อมูลที่ผ่านการประมวลผลล่วงหน้าแล้วชุดเดียวกันทั้งหมด

สำหรับวิธีการประเมินผล ผู้จัดทำได้ใช้วิธีการวัดผลที่มีการใช้งานอย่างแพร่หลาย 2 วิธีได้แก่วิธี Hit Rate (HR) และวิธี Normalized Discounted Cumulative Gain (NDCG) โดยมีรายละเอียดดังนี้

### 4.2.1 Hit Ratio (HR)

HR จะทำการวัดผลอัตราเร้อยละของรายการที่ถูกต้องที่อยู่ในลิสต์ที่แนะนำ N อันดับแรก โดยมีสมการดังนี้

$$HR = \frac{|U_{hit}^N|}{|U_{all}|} \quad \text{สมการที่ 30}$$

$|U_{hit}^N|$  จำนวนผู้ใช้ที่ทำนายได้ถูกต้องในลิสต์ที่แนะนำ N อันดับแรก

$|U_{all}|$  จำนวนผู้ใช้ทั้งหมดในคลังข้อมูลทดสอบ (Test Dataset)

### 4.2.2 Normalized Discounted Cumulative Gain (NDCG)

NDCG จะทำการวัดผลโดยให้ความสำคัญแก่ลำดับของลิสต์ที่แนะนำ N อันดับแรก โดยมีสมการดังนี้

$$DCG_v = \sum_{i=1}^v \frac{g(rel_i)}{\log(i+1)} \quad \text{สมการที่ 31}$$

$$IDCG_v = \sum_{k \in REL_v} \frac{g(rel_k)}{\log(k+1)} \quad \text{สมการที่ 32}$$

$$NDCG_v = \frac{DCG_v}{IDCG_v} \quad \text{สมการที่ 33}$$

$v$  จำนวนรายการทั้งหมด

$g(\cdot)$  พังก์ชันที่รับค่าเป็นจำนวนจริงบวก  $\mathbb{R}^+$

$rel_i$  คะแนนความกี่ยวข้องของรายการลำดับที่  $i$

$REL_v$  ลิสต์ของอันดับที่เรียงตามค่า  $rel_i$

### 4.3 การตั้งค่าพารามิเตอร์

ผู้จัดทำได้มีการตั้งค่าพารามิเตอร์ดังนี้

4.3.1 อัตราการเรียนรู้ (Learning Rate): 0.0005

4.3.2 ขนาดของแบบที่การเรียนรู้ (Training batch size): 512

4.3.3 จำนวน Epoch: 450

### 4.4 ผลการประเมินผล

ตารางที่ 4.3 แสดงผลการประเมินผลเปรียบเทียบระหว่างวิธีการที่นำเสนอด้วยวิธีการพื้นฐาน โดยมีค่า top-N ที่แตกต่างกัน ( $D=64$ ) บนคลังข้อมูลของ Yelp

Model	Yelp							
	HR (D=64)				NDCG (D=64)			
	N=5	N=10	N=15	N=30	N=5	N=10	N=15	N=30
DiffNet++ (baseline)	0.3781	0.4464	0.4954	0.5912	0.3407	0.3645	0.3806	0.4104
DiffNet++ with weighted graph	0.3771	0.4492	0.5000	0.5936	0.3430	0.3678	0.3844	0.4136

จากตารางที่ 4.3 ผลการประเมินผลพบว่าวิธีการแนะนำทางสังคมบนพื้นฐานของกราฟแบบถ่วงน้ำหนักให้ผลการประเมินที่ดีกว่าในเกือบทุกค่า top-N ทั้ง HR และ NDCG ยกเว้นที่ HR N=5

## บทที่ 5

### ข้อสรุปและข้อเสนอแนะ

ในบทนี้จะกล่าวถึง สรุปผลจากข้อมูลผลการประเมินผลการทดลองในบทที่ 4 ข้อสรุปของวิธีแนะนำทางสังคมบันพื้นฐานของกราฟแบบถ่วงน้ำหนัก รวมถึงข้อเสนอแนะอื่นๆที่ได้จากการทดลอง

#### 5.1 ข้อสรุป

วิธีแนะนำทางสังคมบันพื้นฐานของกราฟแบบถ่วงน้ำหนัก ซึ่งเป็นวิธีการแนะนำที่ผู้จัดทำได้มีการพัฒนาโดยการนำค่าน้ำหนักที่แตกต่างกันมาใช้เพื่อให้ความสำคัญที่แตกต่างกันของแต่ละเส้นเชื่อมความสัมพันธ์บนกราฟ เพื่อช่วยให้การแนะนำรายการแก่ผู้ใช้มีความแม่นยำมากขึ้น โดยค่าน้ำหนักที่ได้นำมาใช้แบ่งเป็นสองแบบ ได้แก่ ค่าน้ำหนักระหว่างผู้ใช้และผู้ใช้ และค่าน้ำหนักระหว่างผู้ใช้และรายการ โดยค่าน้ำหนักระหว่างผู้ใช้และผู้ใช้ (กราฟผู้ใช้อิทธิพล) เกิดจากการใช้จำนวนของเส้นเชื่อม หรือค่าดีกรีมาใช้ในการคำนวณ (สมการที่ 27) ซึ่งจะแสดงถึงระดับของความมีอิทธิพลที่ส่งจากผู้ใช้หนึ่งไปยังผู้ใช้อีกคนหนึ่ง เช่น หากค่าน้ำหนักของความสัมพันธ์ระหว่างผู้ใช้ B ที่ส่งมา向ผู้ใช้ A มีค่าที่มาก จะหมายถึงผู้ใช้ B มีอิทธิพลต่อผู้ใช้ A ที่มาก และยังแสดงถึงระดับของความคล้ายกันในแต่ละอิทธิพลที่มีต่อผู้ใช้เพื่อบ้านคนอื่นๆระหว่างผู้ใช้แต่ละคน ในขณะเดียวกันเนื่องจากผู้ใช้ได้มีปฏิสัมพันธ์ต่อรายการด้วยเช่นกันในกราฟสนับสนุนระหว่างผู้ใช้และรายการ (กราฟผู้ใช้สนับสนุน) ซึ่งค่าน้ำหนักที่เกิดขึ้นบนเส้นเชื่อมความสัมพันธ์ระหว่างผู้ใช้และรายการนั้นๆที่มีต่อผู้ใช้ เช่น หากค่าน้ำหนักของเส้นเชื่อมระหว่างผู้ใช้ A และรายการ | มีค่าที่สูง จะหมายถึงรายการ | มีลักษณะที่ผู้ใช้ A นั้นให้ความสนใจมาก หรือกล่าวอีกมุมหนึ่งได้ว่าผู้ใช้ A มีรสนิยมในลักษณะของรายการ | ที่มาก โดยจากการทดสอบการประเมินผลการทดลอง การใช้กราฟแบบถ่วงน้ำหนักที่แต่ละเส้นมีค่าน้ำหนักที่แตกต่างกันสามารถช่วยให้มีประสิทธิภาพการแนะนำที่ดีขึ้นได้เพียงเล็กน้อย

#### 5.2 ปัญหาและอุปสรรค

ปัญหาและอุปสรรคที่ผู้จัดทำพบเจอระหว่างการพัฒนา มีดังนี้

5.2.1 การทำ Data Preprocessing ที่จำเป็นต้องทำให้เข้ากับวิธีการพื้นฐาน (baseline model) เพื่อให้ตัวโมเดลยังสามารถที่จะทำงานร่วมกับข้อมูลที่นำเข้าได้โดยไม่มีปัญหา

5.2.2 การทำ Data Preprocessing คลังข้อมูลจาก Yelp ที่มีขนาดที่ใหญ่มาก ทำให้การทำงานบางขั้นตอนใช้เวลาที่ค่อนข้างนาน และเกิดปัญหาเรมที่ไม่เพียงพอต่อการทำงาน

5.2.3 การใช้ชอร์สโค้ดของวิธีการพื้นฐาน DiffNet++ ที่เป็นเพื่อนเวอร์ชันเก่า ทำให้เกิดปัญหาการทำงานกับบางไลบรารีที่เป็นคนละเวอร์ชันกัน

5.2.4 การนำ DiffNet++ ไปใช้ (Implementation) ที่ใช้ระยะเวลาในการทำความเข้าใจที่ค่อนข้างนาน

### 5.3 แนวทางการแก้ไขปัญหา

จากการดำเนินงานผู้จัดทำพบปัญหาและอุปสรรคที่เกิดขึ้นดังนี้

5.3.1 ทำการศึกษาจากชอร์สโค้ดของวิธีการพื้นฐาน DiffNet++ ร่วมกับตัวรายงานของวิธีการดังกล่าวร่วมกัน เพื่อทำให้การนำเข้าข้อมูลที่ทำการประมวลผลหัวเหล็กสามารถใช้งานร่วมกันได้

5.3.2 ค้นคว้าวิธีการทำ Data Preprocessing แบบต่างๆเพื่อใช้วิธีการที่เหมาะสมมากที่สุดในการนำมาใช้กับคลังข้อมูลที่มีขนาดใหญ่ และลดปัญหาการใช้งานแรมที่เกินความจำเป็น

5.3.3 ทำการปรับแต่งตัวชอร์สโค้ดของ DiffNet++ ในส่วนที่มีปัญหา ทำการปรับเปลี่ยนเพื่อให้เข้ากับการทำงานของไลบรารีเวอร์ชันล่าสุด โดยไม่ส่งผลกระทบต่อการทำงานด้านอื่นๆ

### 5.4 ข้อเสนอแนะ

5.4.1 ทดลองโดยใช้คลังข้อมูลอื่นๆ

5.4.2 ทดลองโดยการใช้ค่าอื่นมาเป็นค่าสำหรับที่หลากหลายมากขึ้น

## รายการอ้างอิง

- [1] Kipf, T. N., & Welling, M. (2016). Semi-supervised classification with graph convolutional networks. arXiv preprint arXiv:1609.02907.
- [2] Mikolov, T., Sutskever, I., Chen, K., Corrado, G. S., & Dean, J. (2013). Distributed representations of words and phrases and their compositionality. Advances in neural information processing systems, 26.
- [3] Shang, M. S., Fu, Y., & Chen, D. B. (2008, December). Personal recommendation using weighted bipartite graph projection. In 2008 International Conference on Apperceiving Computing and Intelligence Analysis (pp. 198-202). IEEE.
- [4] Wu, L., Li, J., Sun, P., Hong, R., Ge, Y., & Wang, M. (2020). Diffnet++: A neural influence and interest diffusion network for social recommendation. IEEE Transactions on Knowledge and Data Engineering.
- [5] Zhang, R., Liu, Q. D., & Wei, J. X. (2014, November). Collaborative filtering for recommender systems. In 2014 Second International Conference on Advanced Cloud and Big Data (pp. 301-308). IEEE.
- [6] Zhou, J., Cui, G., Hu, S., Zhang, Z., Yang, C., Liu, Z., ... & Sun, M. (2020). Graph neural networks: A review of methods and applications. AI Open, 1, 57-81.

ภาคผนวก

## ภาคผนวก ก

# แบบเสนอหัวข้อโครงการ รายวิชา 2301399 Project Proposal ปีการศึกษา 2564

ชื่อโครงการ (ภาษาไทย) วิธีแนะนำทางสังคมบนพื้นฐานของกราฟแบบถ่วงน้ำหนัก

ชื่อโครงการ (ภาษาอังกฤษ) Social Recommendation Based on Weighted Graph

อาจารย์ที่ปรึกษา รศ.ดร. ศรันญา มณีโรจน์

ผู้ดำเนินการ 1. นาย ปฐมพงษ์ เมืองทอง เลขประจำตัวนิสิต 6133739423

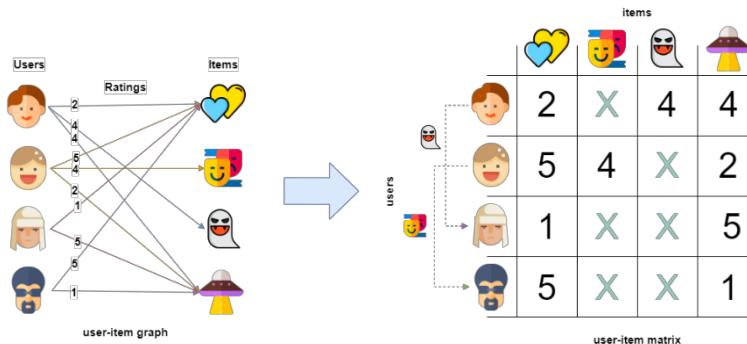
สาขาวิชา วิทยาการคอมพิวเตอร์ ภาควิชาคณิตศาสตร์และวิทยาการ  
คอมพิวเตอร์

คณะวิทยาศาสตร์ จุฬาลงกรณ์มหาวิทยาลัย

### หลักการและเหตุผล

ในปัจจุบัน Recommender System ได้เข้ามามีบทบาทที่สำคัญบนแพลตฟอร์มโซเชียลมีเดียต่างๆ โดยการแนะนำสินค้า หรือบริการต่างๆ เพื่อปรับปรุงและพัฒนาความพึงพอใจสูงสุดให้แก่ผู้ใช้บริการ เช่น ระบบแนะนำคลิปวิดีโอบน YouTube, ระบบแนะนำหนังบน Netflix หรือระบบแนะนำสินค้าบน online market เป็นต้น ด้านนี้เทคนิค Collaborative Filtering(CF) จึงได้ถูกนำมาใช้อย่างแพร่หลายในการเรียนรู้พฤติกรรม การใช้งานของผู้ใช้แต่ละคน โดย CF จะพิจารณาการแนะนำบนพื้นฐานของผู้ใช้ที่มีพฤติกรรมที่คล้ายกัน ก็จะมีแนวโน้มที่จะมีรสนิยมที่คล้ายกันด้วย กล่าวคือ CF จะนำความเห็นหรือปฏิสัมพันธ์ของผู้ใช้ที่รสนิยมคล้ายกันมาแนะนำให้กันและกัน ซึ่งจะทำการหาผู้ใช้ที่มีพฤติกรรมที่คล้ายกันโดยดูจากพฤติกรรมที่ตรงกัน หรือคล้ายกันในอดีต และทำการแนะนำรายการที่ผู้ใช้มีปฏิสัมพันธ์ที่ดีให้แก่ผู้ใช้ที่คล้ายกันแต่ยังไม่เคยมีปฏิสัมพันธ์ต่อรายการนั้นมาก่อน ตามภาพที่ 1 CF สามารถแบ่งได้เป็น 2 ประเภท ประเภทแรกคือ User-based CF คือการสนับสนุนของผู้ใช้ที่คล้ายกัน และทำการแนะนำรายการที่ชอบให้แก่กัน โดยจะพิจารณาว่าผู้ใช้มีรสนิยมคล้ายกันจะมีพฤติกรรมความชอบที่คล้ายกันด้วย ประเภทที่สองคือ Item-based CF โดยจะพิจารณาจากลักษณะของการนำเสนอหัวข้อ หากผู้ใช้ให้คะแนนรายการนั้นในระดับที่ดี ดังนั้นรายการที่เกี่ยวข้อง หรือคล้ายกับรายการนั้นรวมถึงได้คะแนนในระดับใกล้เคียงกันจากผู้ใช้อื่น จึงจะแนะนำรายการนั้นหากผู้ใช้เป้าหมายไม่

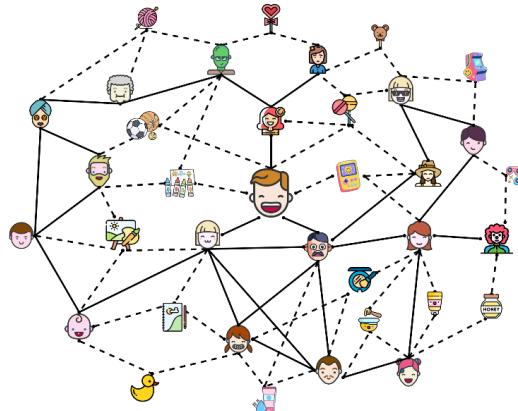
เคยมีปฏิสัมพันธ์ต่อรายการนั้นมาก่อน โดย CF นั้นจำเป็นที่จะต้องใช้ข้อมูลพฤติกรรมของผู้ใช้ เช่น คะแนนของรายการต่างๆที่ผู้ใช้ได้ให้คะแนนมาเรียนรู้ แต่เนื่องจากการมีข้อมูลเหล่านี้อย่างจำกัด ส่งผลให้ CF มีปัญหาการกระจายของข้อมูล จึงทำให้ประสิทธิภาพการแนะนำของ CF นั้นลดลง อย่างไรก็ตาม ได้มีงานวิจัยด้าน CF บางส่วนที่ได้มีการนำแหล่งข้อมูลอื่นมาใช้เพื่อลดปัญหานี้ หนึ่งในแหล่งข้อมูลที่เป็นที่นิยม คือแหล่งข้อมูลจากเครือข่ายโซเชียลเน็ตเวิร์ค โดยได้มีการใช้แหล่งข้อมูลนี้เพื่อมาปรับปรุง และพัฒนา CF ให้มีประสิทธิภาพที่ดีขึ้น



ภาพออกแบบโดยใช้แหล่งข้อมูลจาก Flaticon.com

ภาพที่ 1 แสดงถึงปฏิสัมพันธ์ระหว่างผู้ใช้ต่อประเภทของหนังในรูปแบบของเมทริกซ์ โดยผู้ใช้ที่ให้คะแนนคล้ายกันในประเภทหนังเดียวกันจะมีรสนิยมที่คล้ายกัน จึงทำการแนะนำประเภทหนังที่ไม่เคยดูให้แก่ผู้ใช้ที่คล้ายกันที่ไม่เคยดูหนังประเภทนั้นมาก่อน

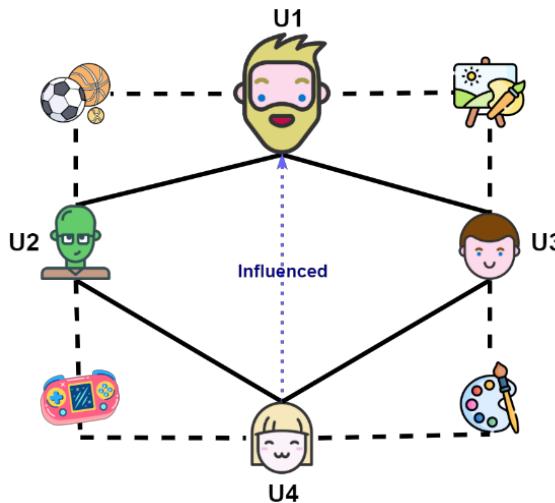
โซเชียลเน็ตเวิร์ค หรือเครือข่ายทางสังคม ซึ่งประกอบไปด้วยโหนดต่างๆของผู้คน หรือรายการ ซึ่งแต่ละโหนดจะมีเส้นเชื่อมระหว่างโหนดหนึ่งไปอีกโหนดหนึ่งที่แสดงถึงความสัมพันธ์ระหว่างโหนดแต่ละโหนด เช่น โซเชียลเน็ตเวิร์คบนแพลตฟอร์มโซเชียลมีเดียที่ผู้ใช้และเพื่อนแต่ละคนจะเชื่อมโยงกันด้วยความสัมพันธ์ของความเป็นเพื่อน โซเชียลเน็ตเวิร์คสามารถแสดงเส้นเชื่อมความสัมพันธ์ที่ซับซ้อน และสามารถแสดงความสัมพันธ์ที่หลากหลายด้วยตัวตัวได้ เช่น เพื่อนของเพื่อนของเพื่อน เป็นต้น และแต่ละคนสามารถเชื่อมต่อกันจนเป็นเน็ตเวิร์คที่มีขนาดใหญ่ได้ ตามภาพที่ 2 ดังนั้นจะเห็นได้ว่าผู้ใช้นั้นมีบทบาทที่สำคัญต่อโซเชียลเน็ตเวิร์ค ในการเป็นส่วนหนึ่งของการเชื่อมต่อเครือข่ายสังคมขนาดใหญ่ ซึ่งส่งผลให้สามารถแสดงถึงความสัมพันธ์ในหลายระดับได้ นอกจากนี้ในบางแพลตฟอร์มสามารถที่จะแสดงความสัมพันธ์ระหว่างผู้ใช้และการได้เชื่อมต่อ แพลตฟอร์ม YouTube ที่ผู้ใช้แต่ละคนสามารถติดตามผู้ใช้คนอื่นๆได้ รวมถึงสามารถมีปฏิสัมพันธ์กับรายการคลิปวิดีโอได้ ดังนั้นเครือข่ายโซเชียลสามารถมีได้ทั้งความสัมพันธ์ระหว่างผู้ใช้กับผู้ใช้ และผู้ใช้กับรายการได้คล้ายกับ CF เช่นกัน เนื่องจาก CF นั้นพยายามที่จะแสดงความสัมพันธ์ทั้งสองแบบนี้ในรูปแบบของเมทริกซ์ ด้วยเหตุนี้จึงทำให้การอธิบายความสัมพันธ์ด้วยเมทริกซ์นั้นยังไม่ดีเท่าที่ควร จึงได้มีงานที่มีการนำความสามารถของกราฟมาช่วยในการอธิบายความสัมพันธ์ที่หลายระดับนี้



ภาพประกอบแบบโดยใช้เหล่าข้อมูลจาก Flaticon.com

ภาพที่ 3 กราฟโซเชียลเน็ตเวิร์ค (Social Network) ที่ผู้ใช้และรายการต่อ กันจนเป็นเครือข่ายขนาดใหญ่ และมีหลายระดับ

การแสดงความสัมพันธ์ของผู้ใช้ต่อผู้ใช้ และผู้ใช้ต่อรายการจากความสัมพันธ์บนโซเชียลเน็ตเวิร์คโดยใช้กราฟนั้นจะช่วยให้สามารถมองในระดับความสัมพันธ์อื่นๆได้ด้วย เนื่องจากกราฟสามารถมีการเข้ามายังความสัมพันธ์ได้หลายลำดับ ซึ่งจากการลดความสัมพันธ์หลายระดับในโซเชียลเน็ตเวิร์คเหลือเพียงความสัมพันธ์ระหว่างคู่ผู้ใช้ที่คล้ายกันมากที่สุดแบบใน CF นั้นไม่สามารถที่จะแสดงถึงผลกระทบ หรืออิทธิพลของความสัมพันธ์ในระดับอื่นๆซึ่งอาจจะส่งผลต่อพฤติกรรมของผู้ใช้ได้ เนื่องจากการสร้างเครือข่ายโดยมีผู้ใช้แต่ละคนเป็นศูนย์กลางนั้นเริ่มจากการมีปฏิสัมพันธ์กับผู้ใช้เพื่อนบ้านลำดับแรก และเพื่อนบ้านก็จะขยายความสัมพันธ์ต่อไปอีกเรื่อยๆ ดังนั้นผู้ใช้แต่ละคนนอกจากจะได้รับอิทธิพลทางพฤติกรรมจากผู้ใช้เพื่อนบ้านลำดับแรกแล้ว ยังได้รับอิทธิพลจากผู้ใช้ลำดับที่สูงกว่าด้วย เช่นดังภาพที่ 3 หากผู้ใช้ U1 ซึ่งสินค้าตาม U2 และ U3 และ U2 กับ U3 ซึ่งสินค้าตาม U4 ดังนั้นจึงได้ว่าผู้ใช้ U1 นั้นได้รับอิทธิพลจากผู้ใช้ U4 เช่นกัน เนื่องจาก มีความสัมพันธ์ลำดับที่สูงกว่าของ U1 ที่เข้มไปยัง U4 ดังนี้ U1 - U2 - U4 และ U1 - U3 - U4 จะเห็นได้ว่าถึงแม้ผู้ใช้จะไม่เคยมีปฏิสัมพันธ์กับผู้ใช้ในลำดับที่สูงกว่าก็ตาม แต่ก็ยังได้รับอิทธิพลต่อพฤติกรรมผ่านผู้ใช้ที่เป็นเพื่อนบ้านลำดับแรกทั้งหมด เช่นกัน ดังนั้นการนำความสัมพันธ์ หรืออิทธิพลต่อพฤติกรรมของผู้ใช้ในลำดับที่สูงกว่า มาช่วยในการแนะนำทางสังคมจะสามารถช่วยในการเรียนรู้ปัจจัยที่ส่งผลต่อพฤติกรรมของผู้ใช้แต่ละคนได้ จึงไม่มีการนำโครงสร้างในลำดับที่สูงกว่าของผู้ใช้มาใช้ช่วยในการวิเคราะห์ด้วยในบางงาน



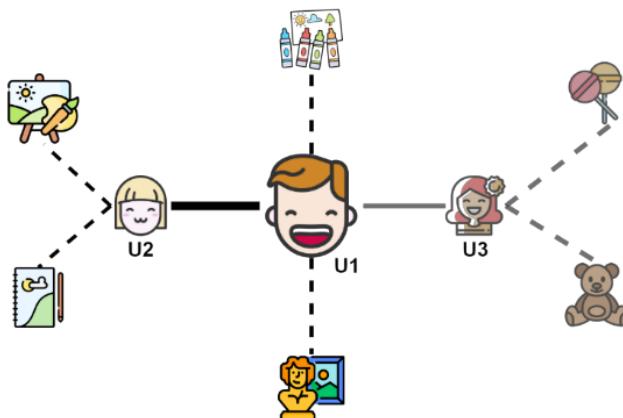
ภาพออกแบบโดยใช้แหล่งข้อมูลจาก Flaticon.com

ภาพที่ 4 กราฟแสดงความสัมพันธ์ระหว่างผู้ใช้ U1 และผู้ใช้ U2 และ U3 โดยผู้ใช้ U1 ได้รับอิทธิพลจากผู้ใช้ U4 ผ่านผู้ใช้ U2 และ U3

จากการค้นคว้าข้อมูล ได้มีงานวิจัย A Neural Influence and Interest Diffusion Network for Social Recommendation (DiffNet++) ได้มีการนำประโยชน์ของโซเชียลเน็ตเวิร์คหลายระดับมาใช้ปรับปรุงการสร้างรูปแทนของผู้ใช้ (user modeling) โดยจะพิจารณาว่าพฤติกรรมของผู้ใช้แต่ละคนนั้น จะขึ้นอยู่กับสองด้าน ได้แก่ ด้านอิทธิพลระหว่างผู้ใช้ และด้านสนับสนุนของตัวผู้ใช้เอง ซึ่ง DiffNet++ ได้มีการวิเคราะห์สนับสนุนต่อรายการของผู้ใช้ รวมกับการวิเคราะห์อิทธิพลจากผู้ใช้อื่น เพื่อวิเคราะห์ว่าผู้ใช้แต่ละคนนั้นมีแนวโน้มที่จะมีพฤติกรรมไปตามด้านใดในอัตราส่วนเท่าไหร ซึ่ง DiffNet++ แบ่งออกเป็นสองเลเยอร์ได้แก่ เลเยอร์เครือข่ายของอิทธิพลและสนับสนุน และเลเยอร์การแนะนำ ในเลเยอร์แรกจะมีการแบ่งเครือข่ายออกเป็นสองส่วน ได้แก่ ส่วนของกราฟเครือข่ายสนับสนุนของผู้ใช้ และส่วนของกราฟเครือข่ายอิทธิพลของผู้ใช้ ซึ่งจะมีการสร้างรูปแทนของผู้ใช้จากการรวมกันของกราฟทั้งสองส่วน และสร้างรูปแทนของรายการจากกราฟเครือข่ายสนับสนุนของผู้ใช้ โดยรูปแทนของผู้ใช้และรายการจะสร้างโดยใช้ Graph Convolutional Network(GCN)[1] จากการวนซ้ำแต่ละรอบ โดยจะเริ่มจากการสร้างรูปแทนของเพื่อนบ้านลำดับแรก และจะเพิ่มลำดับบนกราฟไปเรื่อยๆ  $k$  ลำดับ ซึ่งจะได้รูปแทนมา  $k$  แบบ และนำรูปแทนในแต่ละลำดับมารวมกันและทำการแนะนำในเลเยอร์การแนะนำ โดยการนำรูปแทนของผู้ใช้และรูปแทนของรายการมาทำการคูณแบบเวกเตอร์

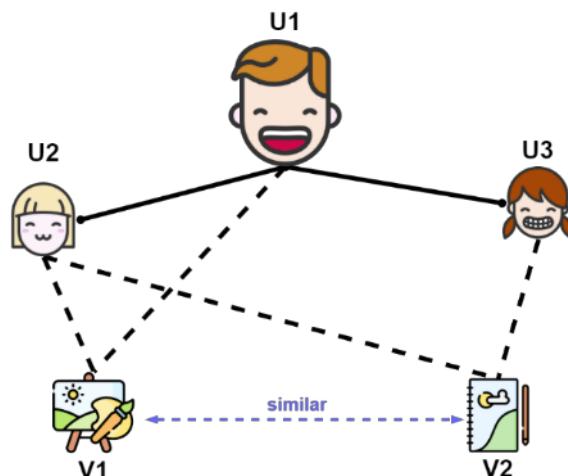
กราฟถ่วงน้ำหนัก เป็นกราฟที่เส้นเชื่อมระหว่างแต่ละโหนดจะมีค่าน้ำหนักของแต่ละเส้น โดยน้ำหนักแต่ละเส้นจะแสดงถึงอิทธิพลของโหนดหนึ่งที่ส่งผลต่ออีกโหนดหนึ่ง โดยในเชิงของระบบแนะนำ เราสามารถใช้คณานน หรือจำนวนครั้งการมีปฏิสัมพันธ์ของผู้ใช้แทนน้ำหนักของความสัมพันธ์ระหว่างผู้ใช้ต่อผู้ใช้หรือผู้ใช้ต่อรายการได้ เพื่อแสดงถึงระดับของอิทธิพล หรือความสำคัญระหว่างผู้ใช้ต่อผู้ใช้ และผู้ใช้ต่อรายการ อย่างไรก็ตาม DiffNet++ นั้นถึงแม้จะมีการนำความสัมพันธ์ทั้งแบบผู้ใช้ต่อผู้ใช้ และผู้ใช้ต่อรายการมาใช้ในการสร้างรูปแทนของผู้ใช้ เพื่อที่จะทำความสัมพันธ์ระหว่างผู้ใช้ต่อผู้ใช้ และผู้ใช้ต่อรายการในหลายระดับแล้วก็ตาม แต่เส้นเชื่อมความสัมพันธ์นั้นได้มีการให้ค่าน้ำหนักระหว่างเส้นเชื่อมที่เท่ากัน ในความเป็นจริงแล้ว ถึงแม้ว่าผู้ใช้จะมี

บุคคลสัมพันธ์กับผู้ใช้ยืนๆหรือรายการต่างๆ แต่รูปแบบของความสำคัญของความสัมพันธ์นั้นแตกต่างกันถึงแม้ว่าจะอยู่ในลำดับเดียวกันบนโซเชียลเน็ตเวิร์คก็ตาม ตัวอย่างเช่นดังภาพที่ 4 ผู้ใช้ U1 เป็นเพื่อนกับผู้ใช้ U2 และ U3 แต่ U1 มีรสนิยมต่อรายการที่คล้ายกับ U2 ดังนั้น U1 อาจจะมีแนวโน้มที่จะมีพฤติกรรมตาม U2 หากกว่า U3 ถึงจะเป็นเพื่อนบ้านลำดับแรกบนโซเชียลเน็ตเวิร์คเหมือนกันก็ตาม รวมถึงการใช้น้ำหนักบนเส้นเชื่อมความสัมพันธ์ยังสามารถใช้ในการหาผู้ใช้หรือรายการที่อาจจะมีลักษณะที่คล้ายกันในลำดับที่สูงขึ้นบนโซเชียลเน็ตเวิร์คได้อีกด้วย ตัวอย่างเช่นดังภาพที่ 5 ให้ผู้ใช้ U1 ชอบใช้สินค้า V1 และเป็นเพื่อนกับ U2 และ U3 โดยที่ U2 ชอบใช้สินค้า V1 และ V2 และ U3 ชอบใช้สินค้า V2 ดังนั้นสินค้า V1 และ V2 จึงอาจจะมีความคล้ายกัน และการหาผู้ใช้ที่มีรสนิยมคล้ายกันแต่อยู่ในลำดับอื่นก็ได้ เช่นกัน การมีค่าน้ำหนักบนความสัมพันธ์อาจจะสามารถเพิ่มประสิทธิภาพการแนะนำ และสร้างความพึงพอใจให้แก่ผู้ใช้มากขึ้นได้



ภาพออกแบบโดยใช้แหล่งข้อมูลจาก Flaticon.com

ภาพที่ 4 ผู้ใช้ U1 เป็นเพื่อนกับผู้ใช้ U2 และ U3 แต่มีรสนิยมที่คล้ายกับ U2 หากกว่า จึงมีแนวโน้มที่จะมีพฤติกรรมตาม U2 หากกว่า U3



ภาพออกแบบโดยใช้แหล่งข้อมูลจาก Flaticon.com

ภาพที่ 5 ผู้ใช้ U1 เป็นเพื่อนกับ U2 และ U3 โดยที่ U1 และ U2 ชอบใช้สินค้า V1 และ U2 กับ U3 ชอบใช้สินค้า V2 ดังนั้นสินค้า V1 และ V2 จึงมีความคล้ายกัน

ตั้งนั้นในงานนี้ เราจึงได้เสนอวิธีแนะนำทางสังคมบนพื้นฐานของกราฟถ่วงน้ำหนัก ที่มีการใช้แหล่งข้อมูลจากโซเชียลเน็ตเวิร์ค โดยภายในกราฟโซเชียลเน็ตเวิร์คแบ่งออกเป็น 2 ส่วน ได้แก่ กราฟความสัมพันธ์ด้านอิทธิพลต่อผู้ใช้ และกราฟสนับสนุนของผู้ใช้ ซึ่งทั้งสองแบบจะถูกนำมาเสนอเป็นกราฟแบบถ่วงน้ำหนัก เพื่อแสดงถึงระดับความสัมพันธ์ระหว่างผู้ใช้ต่อผู้ใช้ กับผู้ใช้ต่อรายการที่อยู่ในกราฟเดียวกัน ดังนี้

1. กราฟผู้ใช้อิทธิพลระหว่างผู้ใช้และผู้ใช้ โดยจะมีค่าของระดับอิทธิพลที่ส่งผลจากผู้ใช้หนึ่งไปยังอีกผู้ใช้หนึ่ง ซึ่งได้จากการเปรียบเทียบค่าน้ำหนักระหว่างผู้ใช้สองคน โดยค่าน้ำหนักของผู้ใช้จะคำนวณได้จากการเปรียบเทียบอัตราส่วนระหว่างจำนวนเส้นเชื่อมทั้งหมดของผู้ใช้ และจำนวนเส้นเชื่อมทั้งหมดของเพื่อนบ้านของผู้ใช้ทุกคน เป็นน้ำหนักของเส้นเชื่อมระหว่างผู้ใช้กับผู้ใช้

2. กราฟผู้ใช้สนับสนุนระหว่างผู้ใช้และรายการ โดยจะมีค่าที่แสดงถึงระดับของความน่าสนใจที่รายการมีต่อผู้ใช้ ซึ่งได้จากการเปรียบเทียบอัตราส่วนกันระหว่างคะแนนที่ผู้ใช้ให้แก่รายการนั้นๆ และผลรวมของคะแนนทั้งหมดที่ผู้ใช้ได้ให้แก่รายการทุกรายการมาเป็นน้ำหนักของเส้นเชื่อมระหว่างผู้ใช้กับรายการ

## วัตถุประสงค์

เพื่อเสนอวิธีแนะนำทางสังคมบนพื้นฐานของกราฟแบบถ่วงน้ำหนัก จากแหล่งข้อมูลดังนี้

1. กราฟผู้ใช้อิทธิพลผู้ใช้ต่อผู้ใช้ โดยจะมีค่าของระดับของความอิทธิพลที่ส่งผลจากผู้ใช้หนึ่งไปยังอีกผู้ใช้หนึ่งเป็นน้ำหนักของเส้นเชื่อมระหว่างผู้ใช้กับผู้ใช้
2. กราฟผู้ใช้สนับสนุนของผู้ใช้ต่อรายการ โดยจะมีค่าที่แสดงถึงระดับของความน่าสนใจที่รายการมีต่อผู้ใช้เปรียบเทียบกับรายการอื่นๆ เป็นน้ำหนักของเส้นเชื่อมระหว่างผู้ใช้กับรายการ

## ขอบเขตของโครงงาน

1. เปรียบเทียบกับวิธีการ DiffNet++ บนคลังข้อมูล Yelp<sup>2</sup> เท่านั้น
2. ใช้จำนวนผู้ใช้ไม่ต่ำกว่า 5,000 ผู้ใช้ และรายการไม่ต่ำกว่า 40,000 รายการ
3. การแทนผู้ใช้จะสร้างมาจากกราฟอิทธิพลระหว่างผู้ใช้ และกราฟสนับสนุนของผู้ใช้

## วิธีการดำเนินงาน

- ศึกษาและค้นคว้าข้อมูลที่เกี่ยวกับระบบ และวิธีแนะนำแบบต่างๆ
  - ศึกษาและค้นคว้าข้อมูลแบบวิธีต่างๆที่มีการใช้กราฟ
  - ทำการนำแบบวิธีพื้นฐานมาใช้
  - ทำการพัฒนาวิธีแนะนำ
  - ทดสอบและวัดประสิทธิภาพของวิธีที่พัฒนา
  - ปรับปรุงวิธีเพื่อเพิ่มประสิทธิภาพ
  - สรุปผลการดำเนินงาน ข้อเสนอแนะ และการจัดทำเอกสาร

## ตารางเวลาการดำเนินการ

## ประโยชน์ที่คาดว่าจะได้รับ

- ก. ในด้านความรู้และประสบการณ์ต่อตัวนิสิตเอง
  - 1. ได้รับความรู้เกี่ยวกับระบบแนะนำ (Recommender System)
  - 2. ได้รับความรู้ และประสบการณ์เกี่ยวกับการใช้งานเครื่องมือที่เกี่ยวข้อง
- ข. ความรู้ ความเข้าใจที่นำไปสู่การแก้ไขปัญหาของสังคมหรือสภาพแวดล้อม
  - 1. สามารถทำการแนะนำรายการให้แก่ผู้ใช้แต่ละคนได้
  - 2. สามารถสร้างประสบการณ์และความพึงพอใจแก่ผู้ใช้

## อุปกรณ์และเครื่องมือที่ใช้

- ก. ฮาร์ดแวร์ (Hardware)
  - 1. HP Pavilion Power 15 Laptop
  - 2. Apple iPad 2018
- ข. ซอฟต์แวร์ (Software)
  - 1. Google Colaboratory<sup>3</sup>
  - 2. Google Drive
  - 3. Microsoft OneDrive
  - 4. Google Document
  - 5. Python 3.6
  - 6. Machine Learning Libraries TensorFlow<sup>4</sup>

## งบประมาณ

ก. Google Colab Pro	1,600 บาท
ข. SSD	2,000 บาท
ค. RAM DDR3L BUS1600 8GB	2,500 บาท

## เอกสารอ้างอิง

- [1] Kipf, T. N., & Welling, M. (2016). Semi-supervised classification with graph convolutional networks. arXiv preprint arXiv:1609.02907.
- [2] Mikolov, T., Sutskever, I., Chen, K., Corrado, G. S., & Dean, J. (2013). Distributed representations of words and phrases and their compositionality. Advances in neural information processing systems, 26.
- [3] Shang, M. S., Fu, Y., & Chen, D. B. (2008, December). Personal recommendation using weighted bipartite graph projection. In 2008 International Conference on Apperceiving Computing and Intelligence Analysis (pp. 198-202). IEEE.
- [4] Wu, L., Li, J., Sun, P., Hong, R., Ge, Y., & Wang, M. (2020). Diffnet++: A neural influence and interest diffusion network for social recommendation. IEEE Transactions on Knowledge and Data Engineering.
- [5] Zhang, R., Liu, Q. D., & Wei, J. X. (2014, November). Collaborative filtering for recommender systems. In 2014 Second International Conference on Advanced Cloud and Big Data (pp. 301-308). IEEE.
- [6] Zhou, J., Cui, G., Hu, S., Zhang, Z., Yang, C., Liu, Z., ... & Sun, M. (2020). Graph neural networks: A review of methods and applications. AI Open, 1, 57-81.

<sup>2</sup> <https://www.yelp.com/dataset>

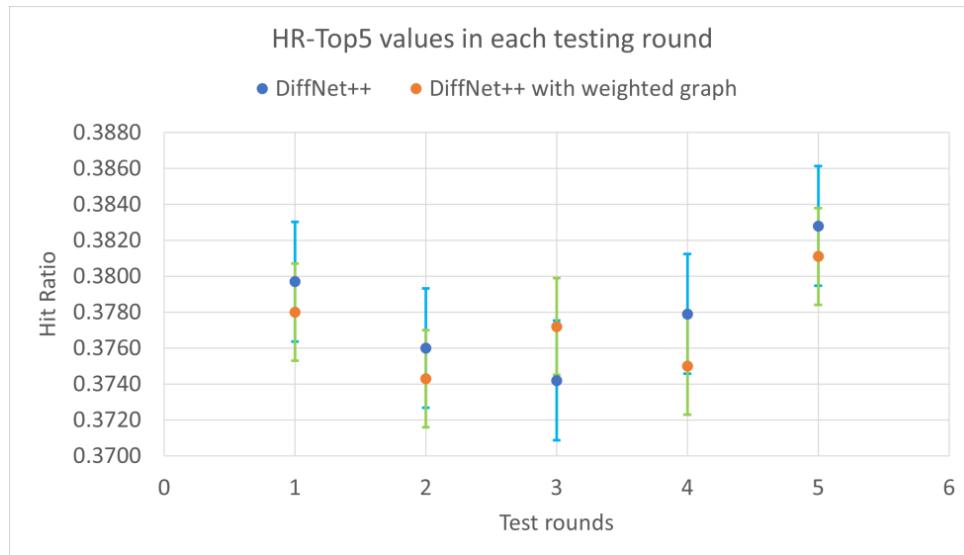
<sup>3</sup> <https://colab.research.google.com>

<sup>4</sup> <https://www.tensorflow.org>

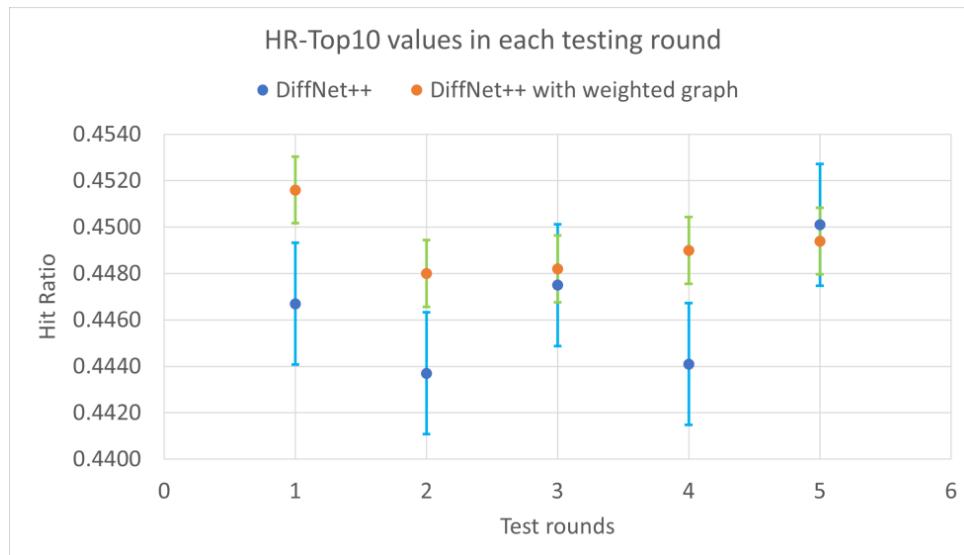
## ภาคผนวก ข

### ตารางแสดงผลการประเมินในแต่ละรอบของการทดสอบ

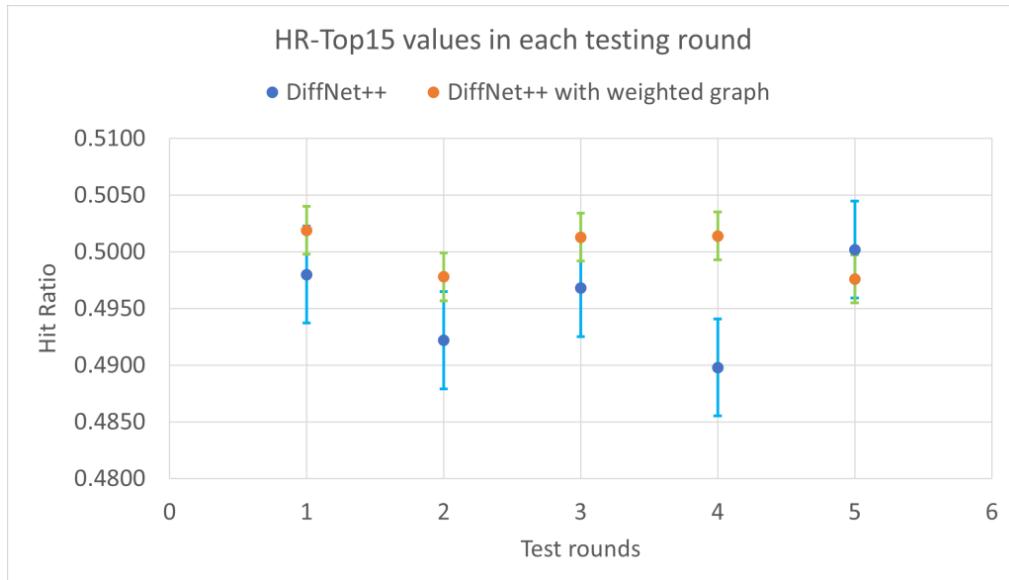
ตารางที่ ข.1 แสดงผลการประเมินผล HR-Top5 เปรียบเทียบระหว่างวิธีการที่นำเสนอและวิธีการพื้นฐาน  
ในแต่ละรอบของการทดสอบ



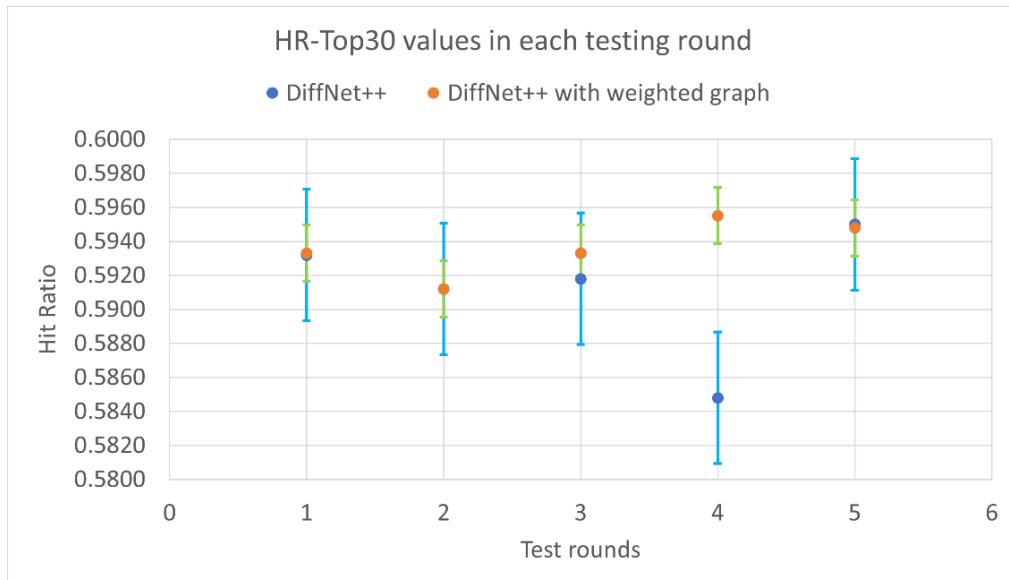
ตารางที่ ข.2 แสดงผลการประเมินผล HR-Top10 เปรียบเทียบระหว่างวิธีการที่นำเสนอและวิธีการ  
พื้นฐานในแต่ละรอบของการทดสอบ



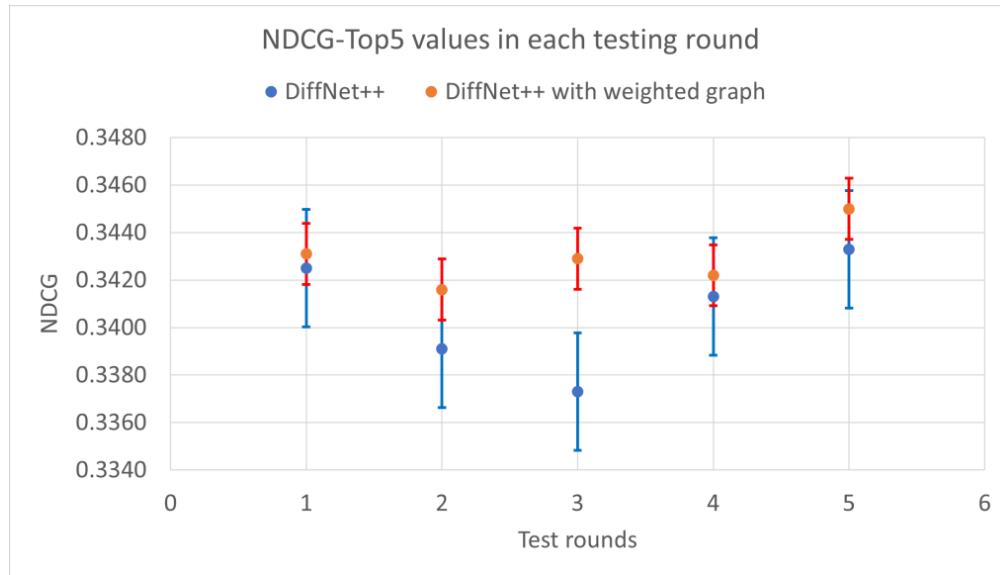
ตารางที่ ข.3 แสดงผลการประเมินผล HR-Top15 เปรียบเทียบระหว่างวิธีการที่นำเสนอและวิธีการพื้นฐานในแต่ละรอบของการทดสอบ



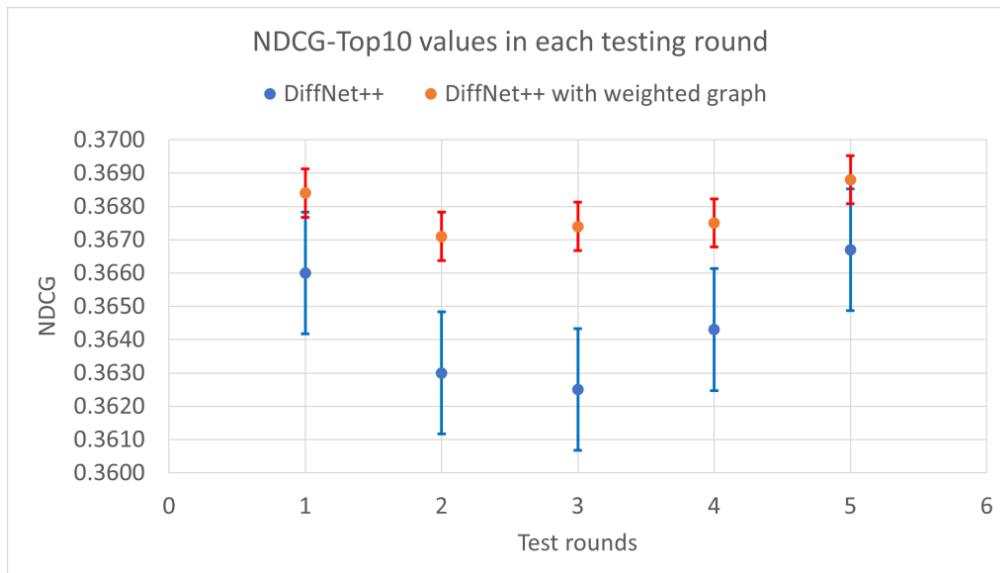
ตารางที่ ข.4 แสดงผลการประเมินผล HR-Top30 เปรียบเทียบระหว่างวิธีการที่นำเสนอและวิธีการพื้นฐานในแต่ละรอบของการทดสอบ



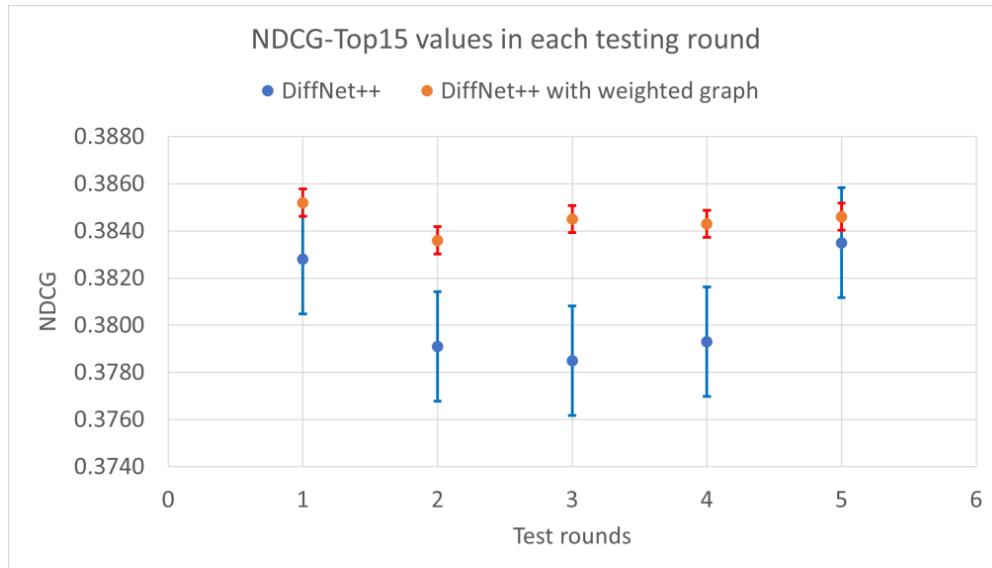
ตารางที่ ข.5 แสดงผลการประเมินผล NDCG-Top5 เปรียบเทียบระหว่างวิธีการที่นำเสนอและวิธีการพื้นฐานในแต่ละรอบของการทดสอบ



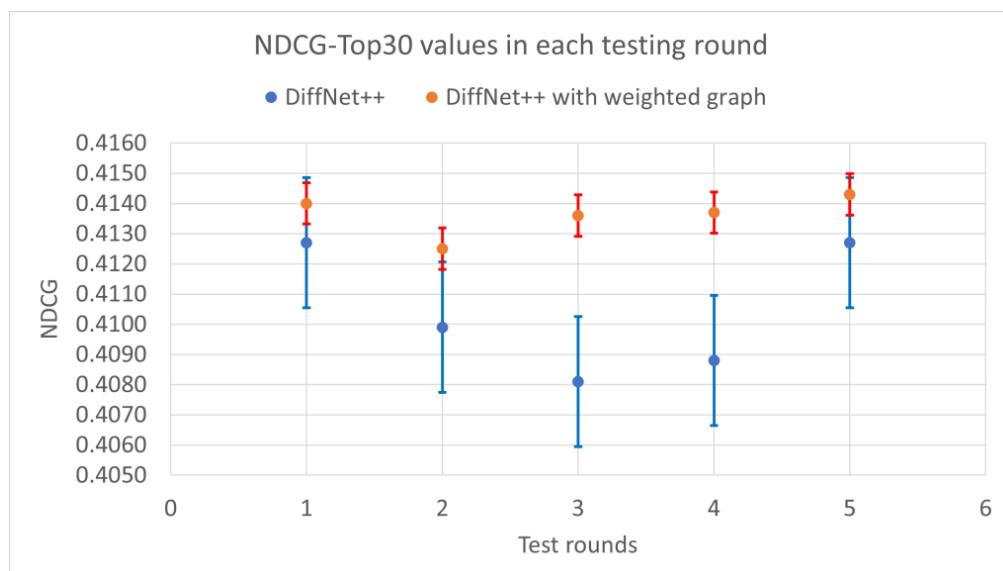
ตารางที่ ข.6 แสดงผลการประเมินผล NDCG-Top10 เปรียบเทียบระหว่างวิธีการที่นำเสนอและวิธีการพื้นฐานในแต่ละรอบของการทดสอบ



ตารางที่ ข.7 แสดงผลการประเมินผล NDCG-Top15 เปรียบเทียบระหว่างวิธีการที่นำเสนอและวิธีการพื้นฐานในแต่ละรอบของการทดสอบ



ตารางที่ ข.8 แสดงผลการประเมินผล NDCG-Top30 เปรียบเทียบระหว่างวิธีการที่นำเสนอและวิธีการพื้นฐานในแต่ละรอบของการทดสอบ



### ประวัติผู้เขียน



นายปฐมพงษ์ เมืองทอง  
ภาควิชาคณิตศาสตร์และวิทยาการคอมพิวเตอร์  
สาขาวิทยาการคอมพิวเตอร์  
จุฬาลงกรณ์มหาวิทยาลัย  
Email: p.s3xxy@gmail.com